ESCUELA POLITÉCNICA SUPERIOR DE CÓRDOBA
Universidad de Córdoba

EPSC

TRABAJO FIN DE GRADO

Grado en Ingeniería Informática
Mención en Ingeniería del Software

Ampliación y mejora de un Dashboard interactivo para el análisis de supervivencia aplicado al Abandono Escolar Universitario

Autor: Alfonso Muñoz Cuesta
Director: D. Juan Alfonso Lara Torralbo

Manual Técnico

mayo, 2026

UNIVERSIDAD DE CÓRDOBA

DECLARACIÓN DE ORIGINALIDAD DEL TFG

D./D.ª: Antonio Merichal Granados
DNI: 31027739A
Estudiante del Grado en: Ingeniería Informática

DECLARA:

Que es el autor y asume la originalidad, entendida esta última en el sentido de que no ha utilizado fuentes sin citarlas debidamente, del Trabajo Fin de Grado titulado:

"Diseño e implementación de una aplicación para la gestión de personal en el sector hostelero".

Asimismo, es consciente de que el plagio, entendido como la presentación de un trabajo u obra realizada por otra persona como propio o la copia de textos sin citar su procedencia, conllevará automáticamente la calificación numérica de cero, y que esta consecuencia se entiende sin perjuicio de las responsabilidades disciplinarias en las que pudiera incurrir en caso de plagio, al tener este la consideración de infracción muy grave, de conformidad con el artículo 11.g de la Ley 3/2022, de Convivencia Universitaria, y el artículo 8.g del Reglamento 5/2023 de Convivencia Universitaria de la Universidad de Córdoba.

En Córdoba, a 8 de febrero de 2026.

El/la estudiante

Fdo.: Antonio Merichal Granados

Diseño e implementación de una aplicación para la gestión de personal en el sector hostelero

Merichal Granados, Antonio(2025). Trabajo de Fin de Grado. Córdoba: Universidad de Córdoba.

Resumen

Este Trabajo Fin de Grado tiene como objetivo el desarrollo de una aplicación para la gestión de turnos de empleados en elsector hostelero, especialmente en eventos como bodas y celebraciones con servicios de catering. La solución propuesta permite la gestión multicompañía, con roles diferenciados para administradores y trabajadores, y funcionalidades para la planificación de eventos, asignación de personal según criterios configurables, y comunicación interna mediante notificaciones. Además, centraliza la información del personal, facilita el seguimiento de pagos y genera informes personalizados.

Palabras clave

Gestion personal, planificación eventos, aplicación web.

Design and implementation of an application for staff management in the hospitality sector

Merichal Granados, Antonio(2025). Trabajo de Fin de Grado. Córdoba: Universidad de Córdoba.

Abstract

This Final Degree Project aims to develop an application for managing employee shifts in the hospitality sector, particularly for events such as weddings and celebrations with catering services. The proposed solution enables multi-company management, with clearly differentiated roles for administrators and employees, as well as functionalities for event planning, staff assignment based on configurable criteria, and internal communication through notifications. Additionally, it centralizes personnel information, facilitates payment tracking, and generates customized reports.

Keywords

Personnel management, event planning, web application.

Dedicado a
mi familia

Agradecimientos

En primer lugar, me gustaría expresar...

Índice general

Índice de figuras **X**

Índice de tablas **XIV**

1. Introducción **1**

2. Objetivos **3**

3. Antecedentes **5**

4. Planificación temporal **7**

5. Marco teórico **10**
5.1. Fundamentos del análisis de supervivencia 10
5.2. Técnicas clásicas de análisis de supervivencia 11
5.2.1. Kaplan-Meier 11
5.2.2. Regresión de Cox 12
5.2.3. Test de Log-Rank 12
5.3. Técnicas incorporadas en la ampliación 13
5.3.1. Modelo exponencial 13
5.3.2. Modelo de Weibull 14
5.3.3. Random Survival Forest 15

6. Recursos **17**
6.1. Recursos humanos 17
6.2. Recursos hardware 18
6.3. Recursos software 19
6.4. Recursos de datos 20

7. Especificación de requisitos **21**
7.1. Requisitos funcionales 21
7.2. Requisitos no funcionales 22
7.3. Requisitos de información 23

8. Análisis del problema **24**
8.1. Identificación de actores . . . 24
8.2. Identificación de casos de uso . . . 25
8.3. Variables utilizadas en el análisis . . . 27
8.4. Diagrama de casos de uso . . . 29
8.5. Especificación de los casos de uso . . . 30
8.5.1. CU-1: EjecutarModeloExponencial . . . 30
8.5.2. CU-2: EjecutarModeloWeibull . . . 32
8.5.3. CU-3: EjecutarRandomSurvivalForest . . . 34
8.5.4. CU-4: ConsultarComparacionDeTecnicas . . . 36
8.5.5. CU-5: ExportarInformesYResultados . . . 39
8.5.6. CU-6: CambiarIdiomaInterfaz . . . 41
8.5.7. CU-7: AnalizarVariablesNoBinarias . . . 42
8.5.8. CU-8: MejorarInterpretacionIA . . . 44
8.5.9. CU-9: AmpliarVisualizacionesCoxTestLogRank . . . 45
8.6. Matriz de trazabilidad . . . 46
8.7. Diagramas de actividad . . . 47
8.7.1. CU-1: EjecutarModeloExponencial . . . 47
8.7.2. CU-2: EjecutarModeloWeibull . . . 47
8.7.3. CU-3: EjecutarRandomSurvivalForest . . . 48
8.7.4. CU-4: ConsultarComparacionDeTecnicas . . . 48
8.7.5. CU-5: ExportarInformesYResultados . . . 49
8.7.6. CU-6: CambiarIdiomaInterfaz . . . 50
8.7.7. CU-7: AnalizarVariablesNoBinarias . . . 50
8.7.8. CU-8: MejorarInterpretacionIA . . . 51
8.7.9. CU-9: AmpliarVisualizacionesCoxTestLogRank . . . 51

9. Diseño del sistema **52**
9.1. Arquitectura del sistema . . . 52
9.2. Diseño de la interfaz . . . 54
9.2.1. Interfaz de usuario (UI) . . . 54
9.3. Diagrama de clases y componentes . . . 71
9.4. Diagramas de secuencia . . . 72

10. Implementación **81**
10.1. Tecnologías y librerías utilizadas . . . 81
10.2. Estructura del código fuente . . . 82
10.3. Carga y preprocesamiento de datos . . . 84
10.4. Implementación de los modelos . . . 84
10.4.1. Modelo exponencial . . . 84

10.4.2. Modelo de Weibull 85
10.4.3. Random Survival Forest 86
10.4.4. Regresión de Cox y Test de Log-Rank 88
10.5. Generación de gráficas 89
10.6. Integración con callbacks 89
10.7. Interpretación mediante inteligencia artificial 90
10.8. Exportación de informes 91
10.9. Internacionalización del Dash 92
10.10Aspectos destacables de la implementación 93

11.Pruebas 95
11.1. CU-1: EjecutarModeloExponencial 95
11.2. CU-2: EjecutarModeloWeibull 96
11.3. CU-3: EjecutarRandomSurvivalForest 98
11.4. CU-4: ConsultarComparacionDeTecnicas 100
11.5. CU-5: ExportarInformesYResultados 102
11.6. CU-6: CambiarIdiomaInterfaz 104
11.7. CU-7: AnalizarVariablesNoBinarias 106
11.8. CU-8: MejorarInterpretacionIA 108
11.9. CU-9: AmpliarVisualizacionesCoxTestLogRank 112

12.Discusión y conclusiones finales 115
12.1. Análisis de los objetivos iniciales 115
12.2. Problemas encontrados en el desarrollo 116
12.3. Conclusiones y posibles mejoras 117

Bibliografía 119

A. Anexo del Manual de Usuario 122
A.1. Introducción 122
A.2. Instalación 122
A.2.1. Requisitos previos 122
A.2.2. Descarga del código 123
A.2.3. Instalación de las librerías de Python requeridas 124
A.2.4. Ejecución de la aplicación 125
A.2.5. Ejecución del módulo de inteligencia artificial 125
A.2.6. Desinstalación del proyecto 126
A.3. Interfaz de usuario 126
A.3.1. Pantalla principal 127
A.3.2. Selector de idioma 128
A.3.3. Carga del dataset 128

A.3.4. Preprocesamiento del dataset 129
A.3.5. Navegación entre módulos 130
A.4. Visualización del dataset 130
A.4.1. Consulta del dataset cargado 130
A.4.2. Consulta del dataset preprocesado 131
A.5. Análisis de covariables 132
A.5.1. Selección de covariables 132
A.5.2. Interpretación de tablas y gráficas 132
A.6. Técnicas de análisis de supervivencia 133
A.6.1. Kaplan-Meier 133
A.6.2. Regresión de Cox 134
A.6.3. Test Log-Rank 135
A.6.4. Modelo Weibull 136
A.6.5. Modelo Exponencial 137
A.6.6. Random Survival Forest 138
A.6.7. Comparación de técnicas 138
A.7. Interpretación con inteligencia artificial 139
A.7.1. Arranque del servidor local de IA 139
A.7.2. Generación de explicaciones automáticas 140
A.7.3. Limitaciones de las interpretaciones generadas 140
A.8. Exportación de informes PDF 141
A.8.1. Selección de contenido del informe 141
A.8.2. Generación y descarga del PDF 142
A.8.3. Ubicación de los informes generados 143
A.9. Errores frecuentes 143
A.9.1. Problemas al cargar el dataset 144
A.9.2. Problemas al acceder a módulos sin preprocesar 144
A.9.3. Problemas durante la instalación de dependencias 145
A.9.4. Problemas al arrancar la aplicación 145
A.9.5. Problemas con el módulo de inteligencia artificial 146
A.9.6. Problemas al generar informes PDF 146
A.10. Flujo completo recomendado 146

B. Anexo del Manual de código fuente 149
B.1. Introducción 149

Índice de figuras

1. Ejemplo de funciones de supervivencia exponenciales 14
2. Ejemplo de distribuciones de Weibull 15
3. Ejemplo de curvas predichas mediante Random Survival Forest 16

4. Diagrama de casos de uso de la ampliación del sistema 29
5. Diagrama de actividad del CU-1: EjecutarModeloExponencial 47
6. Diagrama de actividad del CU-2: EjecutarModeloWeibull 47
7. Diagrama de actividad del CU-3: EjecutarRandomSurvivalForest . . . 48
8. Diagrama de actividad del CU-4: ConsultarComparacionDeTecnicas . 48
9. Diagrama de actividad del CU-5: ExportarInformesYResultados . . . 49
10. Diagrama de actividad del CU-6: CambiarIdiomaInterfaz 50
11. Diagrama de actividad del CU-7: AnalizarVariablesNoBinarias 50
12. Diagrama de actividad del CU-8: MejorarInterpretacionIA 51
13. Diagrama de actividad del CU-9: AmpliarVisualizacionesCoxTestLogRank 51

14. Pantalla principal del dashboard 55
15. Visualización del archivo bruto cargado en el sistema 55
16. Visualización del archivo limpio tras el preprocesamiento 56
17. Vista inicial de la sección Ver dataset 56
18. Detalle de la visualización del dataset dentro del dashboard 57
19. Sección de análisis de covariables 57
20. Sección de análisis de supervivencia 58
21. Vista general del análisis Kaplan-Meier 58
22. Curva de supervivencia generada mediante Kaplan-Meier 59
23. Filtros disponibles en el análisis Kaplan-Meier 59
24. Exportación a PDF de los resultados de Kaplan-Meier 60
25. Vista principal de la regresión de Cox 61
26. Filtros utilizados en la regresión de Cox 61
27. Gráfica generada a partir del modelo de regresión de Cox 61
28. Botón de exportación a PDF utilizado en Cox y también en el Test de Log-Rank 62
29. Vista principal del Test de Log-Rank 62
30. Filtros compartidos por Cox y el Test de Log-Rank 63
31. Ejemplo de resultado generado mediante el Test de Log-Rank 63
32. Vista inicial del análisis mediante el modelo de Weibull 64

33. Resultados y visualizaciones del modelo de Weibull 64
34. Botón de exportación combinada utilizado en Weibull y Exponencial, ya que ambos modelos exportan el mismo tipo de resultados 65
35. Vista inicial del análisis mediante el modelo exponencial 66
36. Resultados y visualizaciones del modelo exponencial 66
37. Vista inicial del análisis mediante Random Survival Forest 67
38. Resultados generales generados por Random Survival Forest 67
39. Visualización complementaria del análisis Random Survival Forest . . 68
40. Página de comparación de técnicas de supervivencia 68
41. Detalle explicativo de la comparación de técnicas 69
42. Botón para consultar el dataset bruto 69
43. Botón para consultar el dataset limpio 69
44. Botón para solicitar una interpretación mediante inteligencia artificial 70
45. Botón de exportación de resultados 70
46. Botón de confirmación para generar y descargar el informe PDF . . . 70
47. Botón de exportación combinada para Weibull y Exponencial 70
48. Botón de simulación de perfiles en Random Survival Forest 71
49. Diagrama de secuencia del CU-1: EjecutarModeloExponencial 73
50. Diagrama de secuencia del CU-2: EjecutarModeloWeibull 74
51. Diagrama de secuencia del CU-3: EjecutarRandomSurvivalForest . . . 75
52. Diagrama de secuencia del CU-4: ConsultarComparacionDeTecnicas . 76
53. Diagrama de secuencia del CU-5: ExportarInformesYResultados . . . 77
54. Diagrama de secuencia del CU-6: CambiarIdiomaInterfaz 78
55. Diagrama de secuencia del CU-7: AnalizarVariablesNoBinarias 79
56. Diagrama de secuencia del CU-8: MejorarInterpretacionIA 79
57. Diagrama de secuencia del CU-9: AmpliarVisualizacionesCoxTestLogRank 80

58. Fragmento de la implementación del modelo de Weibull, donde se ajustan los modelos paramétricos y se obtienen métricas de comparación 86
59. Fragmento de la implementación de Random Survival Forest, incluyendo la construcción del objeto de supervivencia y el ajuste del modelo 88
60. Definición del prompt académico utilizado para orientar las respuestas generadas por el módulo de inteligencia artificial 91
61. Llamada al modelo local de inteligencia artificial mediante una petición HTTP y tratamiento posterior de la respuesta generada . . . 91
62. Ejemplos de informes PDF generados por el sistema a partir de distintos análisis 92
63. Implementación del sistema de traducciones empleado en la internacionalización del dashboard 93

64. Evidencia de ejecución correcta del CU-1: EjecutarModeloExponencial 96
65. Evidencia de ejecución correcta del CU-2: EjecutarModeloWeibull . . 97
66. Evidencia de ejecución correcta del CU-3: EjecutarRandomSurvivalForest 99
67. Evidencia de ejecución correcta del CU-4: ConsultarComparacionDeTecnicas101
68. Evidencia de exportación correcta del CU-5: ExportarInformesYResultados103
69. Evidencia de análisis de variables en el CU-7: AnalizarVariablesNoBinarias107
70. Evidencia de acceso a la interpretación mediante IA del CU-8: MejorarInterpretacionIA 109
71. Evidencia de visualización ampliada del CU-9: AmpliarVisualizacionesCoxTestLogRank11

72. Descarga del proyecto desde GitHub como archivo ZIP 124
73. Pantalla principal de la aplicación 127
74. Botón que cambia el idioma de la aplicación 128
75. Archivo CSV cargado antes de iniciar el preprocesamiento 129
76. Confirmación del dataset preprocesado 129
77. Consulta del dataset limpio desde la sección de visualización 131
78. Descripción de variables disponible para interpretar el dataset 131
79. Selección de covariables para la exploración descriptiva 132
80. Página de acceso a las técnicas de análisis de supervivencia 133
81. Resultado esperado al generar una curva Kaplan-Meier estratificada . 134
82. Visualización de los efectos obtenidos tras ejecutar la regresión de Cox 135
83. Resultado mostrado al comparar grupos mediante el Test Log-Rank . 136
84. Resultados que debe revisar el usuario tras ejecutar el modelo Weibull 137
85. Resultados que debe revisar el usuario tras ejecutar el modelo Exponencial 137
86. Curvas y métricas generadas por Random Survival Forest 138
87. Vista utilizada para consultar la comparación entre técnicas disponibles 139
88. Botón de interpretación mediante inteligencia artificial 140
89. Ejemplo de explicación generada para apoyar la interpretación de resultados 140
90. Botón que inicia la exportación desde un módulo de análisis 141
91. Opciones de contenido para el informe PDF 142
92. Ejemplo de informe PDF generado a partir de los resultados seleccionados 143
93. Mensaje mostrado cuando el archivo cargado no corresponde al dataset esperado 144
94. Aviso mostrado al acceder a una sección que requiere el dataset preprocesado 145

Índice de tablas

1. Identificación de casos de uso de la ampliación del sistema 26
2. Variables principales utilizadas y justificación de su selección 28
3. Especificación del CU-1: Ejecutar modelo exponencial 30
4. Especificación del CU-2: Ejecutar modelo Weibull 32
5. Especificación del CU-3: Ejecutar Random Survival Forest 34
6. Especificación del CU-4: Consultar comparación de técnicas 36
7. Especificación del CU-5: Exportar informes y resultados 39
8. Especificación del CU-6: Cambiar idioma de la interfaz 41
9. Especificación del CU-7: Analizar variables no binarias 42
10. Especificación del CU-8: Mejorar interpretación mediante IA 44
11. Especificación del CU-9: Ampliar visualizaciones Cox y Test de Log-Rank 45
12. Matriz de trazabilidad entre requisitos funcionales y casos de uso . . . 46

13. Componentes principales de la arquitectura del sistema 53
14. Vista de diseño basada en clases y componentes del sistema 72

15. Tecnologías con mayor peso en la ampliación implementada 82
16. Distribución de responsabilidades en el código fuente 83

17. Prueba válida del CU-1: EjecutarModeloExponencial 95
18. Prueba errónea del CU-1: EjecutarModeloExponencial 96
19. Prueba válida del CU-2: EjecutarModeloWeibull 97
20. Prueba errónea del CU-2: EjecutarModeloWeibull 98
21. Prueba válida del CU-3: EjecutarRandomSurvivalForest 99
22. Prueba errónea del CU-3: EjecutarRandomSurvivalForest 100
23. Prueba válida del CU-4: ConsultarComparacionDeTecnicas 101
24. Prueba errónea del CU-4: ConsultarComparacionDeTecnicas 102
25. Prueba válida del CU-5: ExportarInformesYResultados 103
26. Prueba errónea del CU-5: ExportarInformesYResultados 104
27. Prueba válida del CU-6: CambiarIdiomaInterfaz 105
28. Prueba errónea del CU-6: CambiarIdiomaInterfaz 106
29. Prueba válida del CU-7: AnalizarVariablesNoBinarias 107
30. Prueba errónea del CU-7: AnalizarVariablesNoBinarias 108
31. Prueba válida del CU-8: MejorarInterpretacionIA 109

32. Prueba errónea del CU-8: MejorarInterpretacionIA 110
33. Configuración utilizada para medir el rendimiento del módulo de inteligencia artificial 111
34. Resultados de rendimiento del modelo de inteligencia artificial por técnica de análisis 111
35. Prueba válida del CU-9: AmpliarVisualizacionesCoxTestLogRank . . 112
36. Prueba errónea del CU-9: AmpliarVisualizacionesCoxTestLogRank . . 114

1 Introducción

El estudio del comportamiento académico del alumnado universitario ha ido ganando peso en los últimos años dentro del ámbito de la educación superior. No es una preocupación menor. Detrás de cada caso de abandono hay una trayectoria interrumpida, una inversión de recursos que no llega a completarse y, muchas veces, una oportunidad de mejora que la institución no ha sabido detectar a tiempo. Por ello, analizar los factores que influyen en la continuidad académica resulta especialmente relevante, ya que permite comprender con más detalle el fenómeno del abandono y, además, plantear estrategias orientadas a mejorar la permanencia y el éxito de los estudiantes.

En este contexto, las técnicas de análisis de datos se han convertido en una herramienta muy valiosa, porque permiten observar el problema con una mirada cuantitativa y más objetiva. Entre ellas, el análisis de supervivencia resulta especialmente interesante, ya que no se limita a estudiar si un estudiante abandona o no, sino que también permite analizar cuándo puede producirse ese abandono. Aunque esta técnica se ha utilizado tradicionalmente en ámbitos como la medicina o la ingeniería, su aplicación en educación abre una vía muy útil para comprender mejor las trayectorias académicas y detectar momentos de mayor riesgo.

Este Trabajo Fin de Grado plantea la mejora y ampliación de un sistema previamente desarrollado, con el propósito de optimizar los procesos de análisis e incorporar nuevas funcionalidades. La idea principal es avanzar desde un enfoque principalmente descriptivo hacia otro con mayor capacidad predictiva, capaz de identificar patrones de comportamiento y anticipar posibles situaciones de abandono antes de que sea demasiado tarde.

Para conseguirlo, se proponen mejoras tanto a nivel de arquitectura software como de funcionalidad. Por un lado, se introducirán cambios orientados a reforzar la escalabilidad, el rendimiento y la usabilidad de la aplicación. Por otro, se trabajará con las fuentes de datos disponibles y se desarrollarán herramientas de visualización más claras, pensadas para que los resultados no se queden solo en números o gráficas aisladas, sino que puedan interpretarse con mayor facilidad por parte de quienes necesitan tomar decisiones.

En conjunto, el objetivo es transformar el dashboard original en una herramienta más completa, capaz no solo de mostrar información, sino también de aportar conocimiento útil para la prevención del abandono académico. La verdad es que este punto es clave: una visualización puede resultar atractiva, pero su verdadero valor aparece cuando ayuda a entender qué está ocurriendo y qué podría hacerse a continuación. De este modo, se busca contribuir a la toma de decisiones por parte de los responsables académicos y a la mejora de la retención del alumnado en el entorno universitario.

2 Objetivos

El objetivo principal de este Trabajo de Fin de Grado es ampliar y mejorar una aplicación interactiva orientada al análisis de supervivencia, aplicada al estudio del abandono académico en el ámbito universitario. No se trata solo de añadir nuevas funciones por añadirlas, sino de hacer que la herramienta sea más útil, más clara y más capaz de ayudar a interpretar un problema que, en la práctica, afecta tanto a los estudiantes como a las instituciones. Para ello, se plantea el desarrollo de nuevas funcionalidades que permitan analizar con mayor precisión los factores que influyen en este fenómeno.

La solución propuesta, al igual que en el trabajo previo, se desarrollará utilizando tecnologías como Python y Dash. A partir de estas herramientas, se busca construir una plataforma que facilite la realización de análisis interactivos, la visualización de resultados y la aplicación de técnicas estadísticas sobre datos educativos reales. Como punto de partida se utilizará el conjunto de datos empleado en el Trabajo de Fin de Grado anterior, lo que permitirá mantener una base común para comparar resultados y valorar con más justicia las mejoras introducidas.

Además, el proyecto no se limita únicamente al análisis del abandono académico. La idea es ir un paso más allá y mejorar la utilidad real de la herramienta desarrollada. En este sentido, se pretende evolucionar la aplicación hacia un sistema más completo, capaz de servir como apoyo en la toma de decisiones por parte de responsables académicos y de contribuir al diseño de estrategias orientadas a mejorar la retención del alumnado.

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

- Implementar y probar una inteligencia artificial más rápida que la del trabajo previo, con el fin de optimizar los tiempos de generación y visualización de resultados. Para comprobar esta mejora, se medirán aspectos como el tiempo de respuesta, el tiempo de generación de resultados y el consumo de recursos.

- Incorporar soporte multilingüe, permitiendo que la aplicación pueda utilizarse en distintos idiomas, concretamente castellano e inglés. Además, se verificará que los elementos de la interfaz estén correctamente traducidos, de forma que la herramienta resulte más accesible para distintos perfiles de usuario.

- Ampliar el conjunto de variables utilizadas en el modelo, incorporando nuevos atributos y variables no binarias que permitan enriquecer el análisis y mejorar la capacidad explicativa de los modelos. Asimismo, se justificará la selección de dichas variables, explicando los criterios seguidos para incluirlas y valorando su relevancia frente a otros posibles atributos no considerados.

- Incluir gráficos y métodos estadísticos complementarios basados en el Test de Log-Rank y en el modelo de riesgos proporcionales de Cox. Con ello se pretende facilitar el análisis comparativo entre distintos grupos de estudiantes y ofrecer una interpretación más completa de los resultados.

- Explorar e integrar nuevas técnicas de análisis de supervivencia, como modelos paramétricos del tipo Weibull y Exponencial, junto con enfoques basados en aprendizaje automático como Random Survival Forest. La finalidad será comparar distintos enfoques, estudiar sus factores asociados y mejorar la precisión y versatilidad del sistema.

- Permitir la exportación automática de informes, imágenes y representaciones gráficas, facilitando la documentación de los resultados y su uso en contextos de investigación o gestión académica.

En conjunto, estos objetivos marcan el camino del proyecto y permiten comprobar, de forma ordenada, si las mejoras introducidas cumplen realmente con lo planteado en el anteproyecto. Además, este proceso de validación ayudará a evaluar la fiabilidad, la utilidad y el alcance de la herramienta desarrollada, evitando que la mejora quede solo en una ampliación técnica sin impacto práctico.

3 Antecedentes

El análisis del abandono universitario ha ido ganando presencia en los últimos años dentro del ámbito de la analítica educativa. No se trata solo de medir cuántos estudiantes abandonan, sino de comprender en qué momento ocurre, qué señales aparecen antes y qué factores pueden estar influyendo en esa trayectoria. Esta forma de mirar el problema resulta especialmente valiosa para las instituciones, porque permite pasar de una lectura puramente descriptiva a una visión más preventiva.

Dentro de este contexto, el análisis de supervivencia se ha consolidado como una aproximación adecuada para estudiar fenómenos educativos que dependen del tiempo. Su aplicación al abandono académico permite observar la permanencia del alumnado a lo largo de distintos periodos y comparar comportamientos entre grupos. Además, ofrece una base metodológica sólida sobre la que pueden apoyarse técnicas clásicas, modelos paramétricos y enfoques más recientes basados en aprendizaje automático.

Los trabajos relacionados con este campo suelen abordar el problema desde varias perspectivas. Algunos se centran en identificar causas personales, académicas o institucionales que pueden influir en la continuidad del estudiante. Otros ponen el foco en la predicción y en la detección temprana de perfiles de riesgo. Esta segunda línea conecta directamente con el propósito de este proyecto, ya que la herramienta desarrollada no busca únicamente mostrar resultados, sino ayudar a interpretarlos y convertirlos en información útil para la toma de decisiones.

El antecedente más directo de este proyecto es el Trabajo Fin de Grado de Lucía Cabezuelo Pérez (2025), titulado “Análisis, Diseño e Implementación de un Dashboard Interactivo para el Análisis de Supervivencia aplicado al Abandono Escolar Universitario”. En dicho trabajo se desarrolló una aplicación web basada en Python y Dash que integraba modelos clásicos de análisis de supervivencia, como Kaplan-Meier, regresión de Cox y Test de Log-Rank. Además, incorporaba visualizaciones interactivas y un módulo de inteligencia artificial basado en Llama 3, a través de Ollama, para generar interpretaciones automáticas de los resultados estadísticos.

El presente proyecto parte de esa base y plantea una evolución del sistema, incorporando mejoras tanto a nivel metodológico como tecnológico. En particular, se

introducen nuevos modelos de análisis de supervivencia, se refuerza el componente predictivo, se mejora la interpretación mediante inteligencia artificial, se añade soporte multilingüe y se amplían las posibilidades de exportación de resultados. El objetivo final es desarrollar una plataforma más completa, capaz de combinar técnicas estadísticas avanzadas y herramientas de inteligencia artificial para facilitar la interpretación de los resultados, anticipar posibles situaciones de abandono y apoyar la toma de decisiones en el ámbito universitario.

4 Planificación temporal

La planificación temporal de este Trabajo Fin de Grado se organiza en varias fases, pensadas para abordar de forma ordenada la ampliación y mejora de la aplicación existente. La verdad es que, en un proyecto de este tipo, contar con una planificación clara ayuda mucho: permite avanzar sin perder de vista los objetivos principales y evita que las mejoras técnicas queden desconectadas entre sí. Cada fase se centra en un conjunto de tareas concretas, desde la preparación inicial del entorno hasta la validación final de los resultados obtenidos.

1. **Preparación del entorno y revisión del sistema existente**
   En esta primera fase se realizará una revisión completa del TFG original y de la aplicación desarrollada previamente. El objetivo será comprender con calma su funcionamiento interno, sus dependencias, la estructura del código y la forma en la que se organizan los datos. Además, se configurará el entorno de trabajo en el equipo local, incluyendo las herramientas de desarrollo necesarias, las bibliotecas de Python, el entorno de Dash y los archivos de datos empleados por la aplicación.
   Esta etapa servirá como punto de partida técnico. Antes de incorporar nuevas funcionalidades, resulta necesario asegurarse de que el sistema base funciona correctamente y de que se conocen sus límites.

2. **Análisis inicial y planificación**
   En esta fase se identificarán las limitaciones del sistema original y las áreas que requieren una mejora más clara. También se definirán los nuevos requisitos funcionales, no funcionales y de información, así como los objetivos técnicos y metodológicos del proyecto. Además, se elaborará un plan de trabajo que permita repartir mejor los recursos, los tiempos y las herramientas que se utilizarán durante el desarrollo.

3. **Diseño de mejoras y ampliaciones**
   A partir del análisis previo, se planificarán las mejoras principales de la aplicación. En esta parte se estudiará cómo incorporar el soporte multilingüe, la implementación de gráficos adicionales basados en el Test de Log-Rank y en la regresión de Cox, y los cambios necesarios en la interfaz para que la experiencia de uso resulte más clara. También se valorará el tratamiento de atributos no binarios del dataset, junto con la integración de una inteligencia artificial más rápida y eficiente.

4. **Desarrollo e implementación**
   Durante esta fase se llevará a cabo la programación de las mejoras diseñadas. Será, previsiblemente, la parte más extensa del trabajo, ya que aquí las ideas definidas en las fases anteriores se convierten en funcionalidades reales. Se implementarán nuevos módulos, se integrarán funcionalidades interactivas y se añadirán modelos de análisis de supervivencia adicionales. Asimismo, se actualizará la interfaz de usuario en Dash y se optimizará el código para mejorar el rendimiento general del sistema.

5. **Pruebas y validación**
   En esta fase se realizarán pruebas para comprobar la estabilidad y fiabilidad del sistema mejorado. No basta con que la aplicación funcione una vez; debe responder de forma coherente ante distintos escenarios. Por ello, se evaluará el comportamiento de las nuevas funcionalidades, la precisión de los modelos estadísticos, la exportación de informes e imágenes y la velocidad de respuesta de la inteligencia artificial. Se emplearán datos reales y, cuando sea necesario, datos de prueba para comprobar la calidad de los resultados.

6. **Documentación técnica y manuales**
   Se elaborará la documentación completa del proyecto, incluyendo el manual técnico, el manual de usuario y una guía de instalación y ejecución. En estos documentos se explicará la estructura de la aplicación, el funcionamiento de las nuevas funcionalidades y las instrucciones necesarias para utilizar el sistema. Además, se documentará el código fuente de forma clara, de manera que el trabajo pueda entenderse y mantenerse en el futuro.

7. **Evaluación final y conclusiones**
   En la última fase se analizará el cumplimiento de los objetivos planteados y se evaluará el impacto de las mejoras implementadas sobre la aplicación original. También se expondrán las conclusiones generales del trabajo, los problemas encontrados durante el desarrollo y las posibles líneas de mejora que podrían abordarse en el futuro.

Cronograma de trabajo:

A continuación se presenta una estimación de la distribución temporal del proyecto, con una duración total aproximada de 300 horas:

FASE	TIEMPO (HORAS)
Preparación	30
Análisis y diseño	60
Desarrollo e implementación	120
Pruebas y validación	50
Documentación y manuales	25
Evaluación final y conclusiones	15
TOTAL ESTIMADO	**300 HORAS**

La tabla muestra cómo se reparten las horas de trabajo entre las distintas fases del proyecto. Como es lógico, la parte que más dedicación requiere es la de desarrollo e implementación, ya que en ella se concentran la mayoría de las mejoras de la aplicación. También tienen un peso importante las fases de análisis, diseño y validación, porque ayudan a definir bien el camino antes de programar y a comprobar después que los resultados obtenidos son fiables. En conjunto, esta distribución ofrece una visión realista del esfuerzo previsto y permite organizar el proyecto con mayor claridad.

5 Marco teórico

En este capítulo se presentan los conceptos teóricos sobre los que se apoya el proyecto. Al tratarse de una ampliación de un dashboard ya existente, no se parte desde cero, sino desde una base previa centrada en el análisis de supervivencia aplicado al abandono académico universitario. Por ello, el marco teórico se organiza comenzando por los fundamentos generales de esta técnica, continúa con los modelos clásicos ya presentes en el sistema original y, finalmente, introduce las técnicas incorporadas en esta nueva versión.

5.1. Fundamentos del análisis de supervivencia

El análisis de supervivencia es un conjunto de técnicas estadísticas orientadas al estudio del tiempo que transcurre hasta que ocurre un determinado evento. Aunque el término "supervivencia" procede principalmente del ámbito médico, donde se utiliza para analizar el tiempo hasta el fallecimiento, la recuperación o la recaída de un paciente, su aplicación no se limita a ese contexto. También se emplea en ingeniería para estudiar la vida útil de componentes, en economía para analizar la duración de determinados procesos y, más recientemente, en educación para estudiar fenómenos como el abandono académico.

En el contexto de este Trabajo Fin de Grado, el evento de interés es el abandono universitario. La idea principal no consiste únicamente en saber si un estudiante abandona o no, sino en analizar cuándo se produce ese abandono y qué factores pueden estar relacionados con él. Este matiz es importante, porque permite observar el fenómeno como un proceso temporal y no como un resultado aislado. Dicho de forma sencilla, no es lo mismo detectar que un estudiante abandona al inicio de sus estudios que observar que lo hace tras un periodo prolongado de permanencia.

Uno de los conceptos clave en este tipo de análisis es la función de supervivencia. Esta función representa la probabilidad de que un individuo, en este caso un estudiante, continúe en el sistema más allá de un instante determinado. Aplicado al abandono académico, permite estimar la probabilidad de permanencia del alumnado a lo largo del tiempo. A partir de esta información se pueden identificar momentos de mayor riesgo y estudiar si ciertos grupos presentan comportamientos diferentes.

Otro concepto fundamental es el de censura. En muchos estudios no se observa el evento para todos los individuos durante el periodo analizado. Por ejemplo, puede ocurrir que un estudiante siga matriculado al finalizar el periodo de observación. En ese caso, no se puede afirmar que nunca vaya a abandonar, pero sí se sabe que no lo ha hecho hasta ese momento. El análisis de supervivencia permite aprovechar este tipo de información, algo especialmente valioso en el ámbito educativo, donde las trayectorias académicas no siempre finalizan dentro del intervalo de estudio disponible.

Además, el análisis de supervivencia permite incorporar variables explicativas, también denominadas covariables, que ayudan a estudiar qué factores pueden influir en el tiempo hasta el evento. En el caso del abandono universitario, estas variables pueden estar relacionadas con aspectos académicos, personales o administrativos, como el rendimiento, la edad, el género, la discapacidad, el nivel educativo previo o los créditos cursados. Gracias a ello, el análisis no se limita a describir una curva general de permanencia, sino que puede aportar una visión más rica y útil del comportamiento de distintos perfiles de estudiantes.

5.2. Técnicas clásicas de análisis de supervivencia

El sistema desarrollado en el Trabajo Fin de Grado previo ya incorporaba varias técnicas clásicas de análisis de supervivencia. Estas técnicas constituyen la base sobre la que se apoya la ampliación actual, ya que permiten estimar la permanencia del alumnado, comparar grupos y estudiar el efecto de diferentes covariables. Aunque cada método tiene un propósito distinto, todos ellos ayudan a entender mejor el abandono académico desde una perspectiva temporal.

5.2.1. Kaplan-Meier

El estimador de Kaplan-Meier es una de las técnicas más utilizadas dentro del análisis de supervivencia. Su objetivo principal es estimar la función de supervivencia a partir de los datos observados, teniendo en cuenta tanto los casos en los que ocurre el evento como aquellos que están censurados. En el contexto de este proyecto, permite representar de forma gráfica la probabilidad de que los estudiantes permanezcan en el sistema universitario a medida que avanza el tiempo.

Una de sus ventajas es que ofrece una interpretación visual bastante directa. La curva de supervivencia permite observar en qué momentos se producen descensos más marcados, lo que puede indicar periodos de mayor riesgo de abandono. Además,

puede aplicarse a distintos grupos de estudiantes, por ejemplo según género, tramo de edad o nivel educativo previo, facilitando una primera comparación entre perfiles.

No obstante, Kaplan-Meier tiene también ciertas limitaciones. Principalmente, describe la supervivencia de forma general o por grupos, pero no permite modelar de manera conjunta el efecto de varias covariables. Por ello, suele utilizarse como una herramienta inicial de exploración y visualización, complementándose con otros métodos más adecuados para analizar factores explicativos.

5.2.2. Regresión de Cox

El modelo de riesgos proporcionales de Cox permite estudiar la relación entre el tiempo hasta el evento y un conjunto de covariables. A diferencia de Kaplan-Meier, que se centra en estimar curvas de supervivencia, la regresión de Cox permite analizar cómo ciertas variables influyen en el riesgo de que ocurra el evento. En este proyecto, dicho evento se corresponde con el abandono académico.

Este modelo resulta especialmente útil porque permite interpretar el efecto de cada variable mediante razones de riesgo. De forma simplificada, una variable puede asociarse con un aumento o una disminución del riesgo de abandono. Por ejemplo, determinadas características académicas podrían estar relacionadas con una mayor probabilidad de abandonar antes, mientras que otras podrían estar asociadas con una mayor permanencia.

La regresión de Cox es una técnica muy valiosa cuando se desea estudiar el papel de varios factores al mismo tiempo. Sin embargo, parte de una hipótesis importante: los riesgos entre grupos deben ser proporcionales a lo largo del tiempo. Esto significa que el efecto relativo de las covariables se mantiene aproximadamente constante durante el periodo analizado. Si esta condición no se cumple, la interpretación del modelo puede verse afectada.

5.2.3. Test de Log-Rank

El Test de Log-Rank se utiliza para comparar curvas de supervivencia entre dos o más grupos. Su finalidad es determinar si existen diferencias estadísticamente significativas entre las curvas observadas. En el contexto del abandono universitario, puede emplearse para analizar si distintos grupos de estudiantes presentan comportamientos de permanencia diferentes a lo largo del tiempo.

Por ejemplo, esta prueba puede ayudar a comparar la supervivencia académica entre estudiantes de diferentes tramos de edad, niveles educativos previos o categorías de una variable determinada. Si el resultado muestra diferencias significativas, se obtiene una señal de que la variable analizada podría estar relacionada con el abandono. No explica por sí sola la causa, pero sí ayuda a detectar diferencias relevantes que merecen ser estudiadas con más detalle.

En el dashboard, el Test de Log-Rank complementa a Kaplan-Meier y a la regresión de Cox. Mientras Kaplan-Meier facilita la visualización de las curvas y Cox permite analizar covariables, el Test de Log-Rank aporta una prueba estadística para comparar grupos. Esta combinación ofrece una base sólida para el análisis inicial del abandono académico.

5.3. Técnicas incorporadas en la ampliación

La ampliación desarrollada en este Trabajo Fin de Grado incorpora nuevas técnicas de análisis de supervivencia con el fin de enriquecer la capacidad analítica del sistema. La idea no es sustituir los métodos clásicos, sino complementarlos. Cada modelo aporta una forma distinta de mirar los datos, y esa variedad permite comparar enfoques, detectar patrones y ofrecer una interpretación más completa del fenómeno estudiado.

5.3.1. Modelo exponencial

El modelo exponencial es un modelo paramétrico de análisis de supervivencia. A diferencia de métodos como Kaplan-Meier, que no imponen una forma concreta a la función de supervivencia, los modelos paramétricos asumen una determinada distribución para describir el tiempo hasta el evento [1, 2]. En el caso del modelo exponencial, se supone que el riesgo de que ocurra el evento permanece constante a lo largo del tiempo.

Esta característica lo convierte en un modelo sencillo y fácil de interpretar. Si el riesgo de abandono se considera estable durante el periodo analizado, el modelo exponencial puede ofrecer una aproximación útil. Sin embargo, esa misma simplicidad puede convertirse en una limitación cuando el riesgo cambia con el tiempo, algo que puede ocurrir en contextos educativos. Por ejemplo, puede haber periodos iniciales con mayor incertidumbre o momentos concretos del curso en los que el abandono sea más probable.

Dentro del proyecto, el modelo exponencial permite incorporar una primera aproximación paramétrica al análisis y sirve como punto de comparación frente a modelos más flexibles. Además, facilita la generación de métricas y resultados que pueden contrastarse con otras técnicas implementadas en el dashboard.

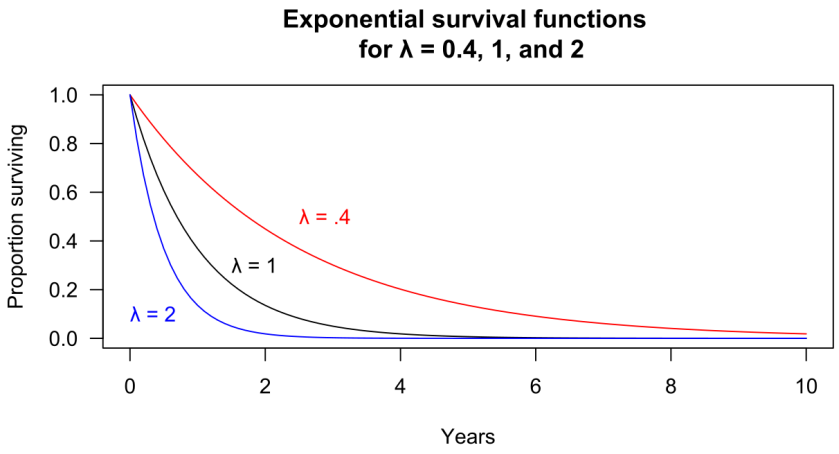

Figura 1: Ejemplo de funciones de supervivencia exponenciales con distintos valores del parámetro λ. Fuente: Michaelg2015, Wikimedia Commons [3].

5.3.2. Modelo de Weibull

El modelo de Weibull es también un modelo paramétrico, pero ofrece mayor flexibilidad que el modelo exponencial. Su principal ventaja es que permite representar situaciones en las que el riesgo no permanece constante, sino que puede aumentar o disminuir a lo largo del tiempo [1, 2]. Esta característica resulta especialmente interesante en el análisis del abandono académico, donde el riesgo puede variar según la etapa en la que se encuentre el estudiante.

Por ejemplo, es posible que algunos estudiantes presenten mayor riesgo de abandono durante los primeros periodos de observación, mientras que otros lo hagan más adelante. El modelo de Weibull permite capturar este tipo de comportamientos de una forma más flexible. Por ello, su incorporación al dashboard amplía las posibilidades de análisis y permite comparar si una aproximación paramétrica más compleja se ajusta mejor a los datos que el modelo exponencial.

Además, la comparación entre los modelos Exponencial y Weibull puede aportar información útil sobre la naturaleza del riesgo observado. Si Weibull ofrece un mejor

ajuste, podría indicar que el riesgo de abandono no se mantiene constante, sino que evoluciona con el tiempo. Esta interpretación resulta valiosa para comprender mejor el fenómeno y para plantear estrategias de intervención más ajustadas.

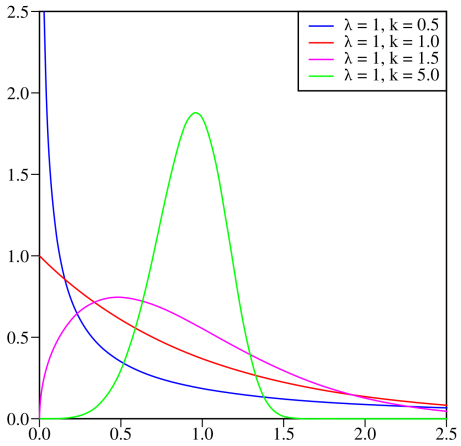

Figura 2: Ejemplo de distribuciones de Weibull con diferentes valores del parámetro de forma. Fuente: Calimo, Wikimedia Commons [4].

5.3.3. Random Survival Forest

Random Survival Forest es una técnica basada en aprendizaje automático adaptada al análisis de supervivencia. Parte de la idea de los bosques aleatorios, pero incorpora la capacidad de trabajar con tiempos hasta evento y datos censurados [5]. A diferencia de los modelos clásicos o paramétricos, este enfoque no exige asumir una forma concreta para la función de supervivencia ni una relación lineal entre las variables.

Una de sus principales ventajas es su capacidad para capturar relaciones complejas entre covariables. En un contexto como el abandono universitario, donde pueden intervenir muchos factores de forma simultánea, esta flexibilidad resulta especialmente útil. El modelo puede aprender patrones no evidentes y ofrecer estimaciones de supervivencia para distintos perfiles de estudiantes.

Además, Random Survival Forest permite obtener información sobre la importancia de las variables, lo que ayuda a identificar qué factores tienen mayor peso en la predicción del abandono. Esta característica conecta directamente con uno de los objetivos del proyecto: mejorar la capacidad de interpretación y análisis de los factores asociados al abandono académico. Aun así, al tratarse de un modelo más complejo, sus resultados deben interpretarse con cuidado y, siempre que sea

posible, compararse con los obtenidos mediante técnicas más clásicas. En este proyecto se utiliza a través de `scikit-survival`, una librería especializada en análisis de tiempo hasta evento sobre el ecosistema de `scikit-learn` [6].

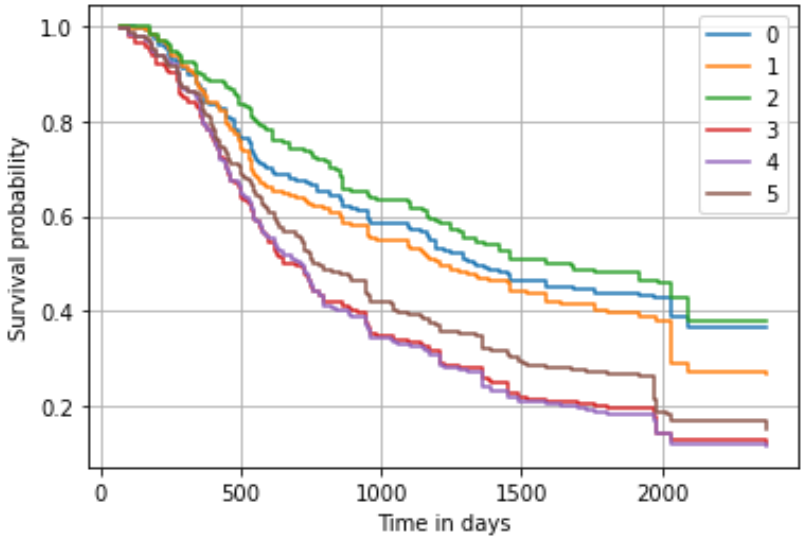

Figura 3: Ejemplo de curvas de supervivencia predichas mediante Random Survival Forest. Fuente: documentación oficial de scikit-survival [7].

6 Recursos

6.1. Recursos humanos

El desarrollo de este Trabajo Fin de Grado ha sido realizado por Alfonso Muñoz Cuesta, estudiante del Grado de Ingeniería Informática. Su papel dentro del proyecto abarca el análisis, diseño, implementación, pruebas y documentación de la aplicación. En la práctica, esto implica no solo programar nuevas funcionalidades, sino también entender con detalle el sistema previo, detectar sus limitaciones y decidir qué mejoras aportan realmente valor.

Entre las tareas principales desarrolladas por el estudiante se encuentran las siguientes:

- Revisión del sistema desarrollado en el Trabajo Fin de Grado previo, con el fin de comprender su estructura, su funcionamiento interno y sus posibilidades de ampliación.
- Análisis de los requisitos necesarios para mejorar la aplicación y adaptar sus funcionalidades al nuevo alcance del proyecto.
- Diseño y programación de nuevas funcionalidades del dashboard interactivo, incluyendo la integración de modelos adicionales de análisis de supervivencia.
- Preparación y tratamiento de los datos utilizados por el sistema, prestando especial atención a las variables necesarias para los modelos estadísticos.
- Realización de pruebas para comprobar el correcto funcionamiento de la aplicación, la estabilidad del sistema y la coherencia de los resultados obtenidos.
- Mejora de la interfaz y de los elementos de visualización, con el objetivo de que la información generada sea más fácil de interpretar por parte del usuario.
- Redacción de la documentación asociada al proyecto, incluyendo la memoria, los manuales y los informes finales.

El proyecto ha contado además con la supervisión del Dr. Juan Alfonso Lara Torralbo, profesor del Departamento de Ciencia de la Computación e Inteligencia Artificial de la Universidad de Córdoba. Su labor ha sido especialmente importante para orientar el trabajo, revisar los avances y mantener el proyecto dentro de un enfoque académico y técnicamente coherente. Entre sus funciones principales destacan:

- Ayuda en la definición de los objetivos y del alcance del proyecto.
- Revisión periódica de los avances en el diseño y desarrollo de la herramienta.
- Propuesta de mejoras basadas en su experiencia académica y técnica.
- Resolución de dudas relacionadas con la implementación de funcionalidades y con las decisiones metodológicas del trabajo.

6.2. Recursos hardware

El proyecto se ha desarrollado en un ordenador personal con capacidad suficiente para ejecutar la aplicación web, procesar los conjuntos de datos y realizar los análisis estadísticos necesarios. Aunque no se trata de una infraestructura especialmente compleja, sí es importante contar con un equipo estable, ya que durante el desarrollo se ejecutan servicios locales, procesos de análisis, generación de gráficos y exportación de informes.

Las características principales del equipo utilizado son las siguientes:

- Equipo: Lenovo 82KU.
- Procesador: AMD Ryzen 7 5700U with Radeon Graphics.
- Memoria RAM: 8 GB.
- Sistema operativo: Windows 11 Home de 64 bits.
- Tarjeta gráfica: AMD Radeon Graphics integrada.

6.3. Recursos software

Para el desarrollo de la aplicación se han empleado distintos recursos software que forman la base tecnológica del sistema. El núcleo del proyecto está desarrollado en Python, mientras que la interfaz web y la interacción con el usuario se han implementado mediante Dash. Esta combinación permite construir un dashboard interactivo sin separar en exceso la parte de análisis de datos y la parte visual, algo especialmente útil en un proyecto de carácter académico y experimental.

Para la construcción de gráficos dinámicos y representaciones analíticas se utiliza Plotly. El procesamiento, limpieza y transformación de datos se realiza principalmente mediante Pandas y NumPy, dos bibliotecas fundamentales dentro del ecosistema de análisis de datos en Python. Además, para la parte estadística se emplean librerías especializadas como Lifelines, utilizada en modelos como Kaplan-Meier, Cox, Weibull y Exponencial, junto con Scikit-survival para la implementación de Random Survival Forest.

En la parte de presentación, la aplicación incorpora una hoja de estilos CSS personalizada, que permite ajustar el aspecto visual del dashboard y mejorar la experiencia de uso. Además, se utilizan ReportLab y Kaleido para la exportación de informes y gráficos en formato PDF, una funcionalidad importante porque facilita conservar y compartir los resultados obtenidos.

Como funcionalidad complementaria, el sistema incluye un módulo de interpretación asistida por inteligencia artificial ejecutado en entorno local. Para ello se utiliza un servidor compatible con una API de estilo OpenAI, mediante *llama-server*, junto con un modelo ligero de lenguaje configurado para generar explicaciones sobre los resultados estadísticos. En concreto, la configuración actual del proyecto utiliza el modelo *qwen2.5-1.5b-instruct*. Esta parte aporta una capa adicional de interpretación, de forma que los resultados no queden únicamente como tablas o gráficas, sino que puedan acompañarse de explicaciones más comprensibles.

También se han empleado herramientas de apoyo al desarrollo, como Visual Studio Code para la edición del código, Git para el control de versiones y scripts de arranque en Windows para facilitar la ejecución tanto de la aplicación como del servidor local de inteligencia artificial.

6.4. Recursos de datos

Los datos utilizados proceden del conjunto de información heredado del Trabajo Fin de Grado previo, relacionado con el abandono académico universitario. Este conjunto de datos permite trabajar con información de estudiantes y con variables relevantes para el análisis de supervivencia, como el identificador del estudiante, el tiempo observado, el resultado final y distintos atributos académicos o personales.

Dentro del proyecto se emplean archivos de datos preparados para la carga y el análisis, como *dataset_limpio.csv* y *data/temp_data.csv*. Estos archivos permiten probar el flujo completo de la aplicación: carga, validación, preprocesamiento, análisis estadístico, visualización de resultados e interpretación posterior.

Un aspecto especialmente importante es la presencia de datos censurados. En este contexto, estos datos representan estudiantes para los que no se ha observado el abandono durante el periodo analizado. La verdad es que este punto es clave, porque el análisis de supervivencia no solo estudia a quienes abandonan, sino también a quienes permanecen en el sistema durante el tiempo de observación. Gracias a ello, el modelo puede aprovechar mejor la información disponible y ofrecer una visión más ajustada del fenómeno.

Por último, la documentación del proyecto se desarrolla mediante LaTeX, utilizando la plantilla oficial proporcionada para la memoria. El código fuente de la aplicación, donde se incluyen los archivos utilizados para la carga, procesamiento, análisis de datos y generación de informes, está disponible en el repositorio de GitHub del proyecto [8].

7 Especificación de requisitos

En este capítulo se llevará a cabo un análisis más detallado y técnico de los requisitos que componen el sistema. Partiendo de los requisitos ya definidos en el TFG anterior, este trabajo mantiene las funcionalidades generales básicas del sistema, como la carga, limpieza y visualización de datos, así como la interacción con el asistente de inteligencia artificial. No obstante, los requisitos específicos asociados a los modelos clásicos ya implementados en el sistema base no se redefinen de forma individual, puesto que forman parte de la solución previa. A partir de dicha base bien fundamentada, este TFG incorpora nuevos requisitos orientados a la ampliación funcional y a la mejora de la capacidad analítica del dashboard.

7.1. Requisitos funcionales

- **RF1.** El sistema debe permitir la interacción del usuario con el asistente de inteligencia artificial integrado.
- **RF2.** El sistema debe incorporar soporte multilingüe en la interfaz, permitiendo al menos el uso en castellano e inglés.
- **RF3.** El sistema debe permitir trabajar con nuevas variables del conjunto de datos, además de las ya contempladas en el sistema anterior.
- **RF4.** El sistema debe admitir el análisis de variables no binarias dentro del flujo de estudio.
- **RF5.** El sistema debe ampliar las visualizaciones disponibles para mejorar la interpretación de los resultados en los métodos de regresión de Cox y Test de Log-Rank.
- **RF6.** El sistema debe incorporar nuevas técnicas de análisis de supervivencia que amplíen la capacidad analítica del dashboard, cada una con sus respectivas interpretaciones.
- **RF7.** El sistema debe incorporar el modelo exponencial como nueva técnica de análisis de supervivencia.
- **RF8.** El sistema debe incorporar el modelo de Weibull como nueva técnica de análisis de supervivencia.

- **RF9.** El sistema debe incorporar Random Survival Forest como nueva técnica de análisis de supervivencia.
- **RF10.** El sistema debe permitir la comparación de resultados entre las distintas técnicas de análisis implementadas.
- **RF11.** El sistema debe incorporar una nueva solución de inteligencia artificial más rápida que la utilizada en el TFG anterior, manteniendo la generación de interpretaciones sobre los resultados estadísticos.
- **RF12.** El sistema debe mejorar la calidad de las explicaciones generadas por la inteligencia artificial a partir de los resultados estadísticos obtenidos.
- **RF13.** El sistema debe permitir la exportación de resultados, gráficas, tablas e informes en formato PDF para su uso en documentación o análisis posteriores.

7.2. Requisitos no funcionales

- **RNF1.** El sistema debe ofrecer tiempos de respuesta adecuados durante la carga, limpieza y visualización de los datos.
- **RNF2.** El sistema debe ejecutar los análisis en un tiempo razonable, incluso tras la incorporación de nuevas técnicas de análisis de supervivencia.
- **RNF3.** El sistema debe reducir el tiempo de respuesta del módulo de inteligencia artificial con respecto a la solución utilizada en el TFG anterior, teniendo en cuenta métricas como el tiempo de respuesta, el tiempo de generación y el consumo de recursos.
- **RNF4.** El sistema debe garantizar la confidencialidad de los datos académicos utilizados en el análisis.
- **RNF5.** El sistema debe validar los archivos cargados para evitar la incorporación de contenido malicioso o no válido.
- **RNF6.** El sistema debe ofrecer una interfaz clara, comprensible y fácil de utilizar para facilitar la navegación y la comprensión de la información mostrada.
- **RNF7.** El sistema debe mostrar correctamente las visualizaciones y resultados en los navegadores de uso habitual.
- **RNF8.** El sistema debe mantener la estabilidad de las funcionalidades ya implementadas en la versión previa.

- **RNF9.** El sistema debe asegurar la coherencia entre los resultados estadísticos obtenidos, las gráficas generadas y las explicaciones producidas por la inteligencia artificial.
- **RNF10.** El sistema debe facilitar futuras ampliaciones funcionales sin necesidad de modificar por completo la estructura principal de la aplicación.
- **RNF11.** El sistema debe permitir un despliegue reproducible en entorno local con las dependencias necesarias correctamente definidas.

7.3. Requisitos de información

- **RI1.** El sistema debe gestionar un conjunto de datos estructurado que contenga información académica de los estudiantes, incluyendo variables relevantes para el análisis de supervivencia.
- **RI2.** El sistema debe permitir la incorporación de nuevas variables al conjunto de datos, incluyendo variables no binarias.
- **RI3.** El sistema debe almacenar y procesar correctamente las variables necesarias para la aplicación de modelos de análisis de supervivencia.
- **RI3.1.** El sistema debe identificar correctamente las variables mínimas necesarias para el análisis, incluyendo un identificador del estudiante, una variable temporal y una variable que represente el evento o resultado observado.
- **RI3.2.** El sistema debe representar correctamente la información asociada a datos censurados, diferenciando los casos en los que el abandono se ha producido de aquellos en los que no se ha observado durante el periodo de estudio.
- **RI4.** El sistema debe generar y mantener los resultados derivados de los distintos modelos aplicados, incluyendo métricas, estimaciones y representaciones gráficas.
- **RI5.** El sistema debe proporcionar información interpretativa sobre los resultados obtenidos, facilitando su comprensión mediante el módulo de inteligencia artificial.
- **RI6.** El sistema debe permitir la exportación de la información generada, incluyendo resultados, tablas y gráficos, en formatos reutilizables.

8 Análisis del problema

En este capítulo se presenta el análisis funcional del sistema desarrollado en el marco de este Trabajo de Fin de Grado. Al tratarse de una ampliación del dashboard desarrollado en un Trabajo de Fin de Grado previo, se mantienen sus características principales y se incorporan nuevas capacidades orientadas a mejorar el análisis, la comparación de técnicas y la interpretación de resultados.

El objetivo principal de esta ampliación es proporcionar una herramienta más flexible y completa para el estudio del abandono académico en el ámbito universitario. Para ello, se profundiza en los factores que influyen en este fenómeno mediante la incorporación de nuevas técnicas de análisis de supervivencia y funcionalidades complementarias.

El análisis parte de los requisitos funcionales, no funcionales y de información definidos en el capítulo anterior. A partir de ellos, se identifican los actores que interactúan con la aplicación y los casos de uso asociados a la ampliación propuesta. De este modo, las funcionalidades se describen desde la perspectiva del usuario y se representa su comportamiento mediante diagramas de casos de uso y diagramas de actividad, lo que facilita comprender el flujo de interacción entre los distintos componentes del sistema.

8.1. Identificación de actores

En esta primera fase de análisis del problema se mantienen los mismos actores principales que en el Trabajo de Fin de Grado anterior, ya que la aplicación está orientada al mismo tipo de público: profesorado, personal administrativo, alumnado o cualquier miembro interesado en utilizar estas técnicas a partir de los datos propuestos. Aunque la interacción principal recae sobre el usuario, también se considera el asistente de inteligencia artificial, encargado de procesar las consultas y generar respuestas o interpretaciones relacionadas con los resultados obtenidos.

- **Usuario**: Representa a cualquier persona que utiliza la aplicación para cargar datos, ejecutar análisis de supervivencia, visualizar resultados, comparar modelos y exportar la información generada por el sistema.

- **Sistema de Inteligencia Artificial (IA)**: Actúa como un componente externo que interactúa con el usuario proporcionando explicaciones, sugerencias e interpretaciones de los resultados obtenidos. En esta nueva versión del sistema, este actor adquiere especial relevancia debido a las mejoras introducidas en la calidad y rapidez de las respuestas generadas.

8.2. Identificación de casos de uso

Dado que este Trabajo Fin de Grado supone una ampliación y mejora del dashboard desarrollado previamente, no resulta necesario incluir en la lista de casos de uso las funcionalidades ya implementadas en el proyecto anterior. Tras el análisis de los objetivos generales del proyecto y la elicitación de requisitos correspondiente, en esta fase se identifican y documentan las principales acciones que los actores previamente definidos pueden llevar a cabo sobre el sistema.

Id	Nombre	Descripción
CU-1	Ejecutar modelo exponencial	Permite al usuario aplicar el modelo exponencial como técnica de análisis de supervivencia para estudiar el tiempo hasta el evento.
CU-2	Ejecutar modelo Weibull	Permite al usuario aplicar el modelo de Weibull para analizar el comportamiento del riesgo en función del tiempo mediante un enfoque paramétrico.
CU-3	Ejecutar Random Survival Forest	Permite al usuario aplicar el modelo Random Survival Forest para realizar análisis de supervivencia basados en técnicas de aprendizaje automático.
CU-4	Consultar comparación de técnicas	Permite al usuario acceder a una página específica del dashboard dedicada a la comparación de técnicas de análisis de supervivencia, mostrando una tabla comparativa, visualizaciones y un bloque explicativo automático.
CU-5	Exportar informes y resultados	Permite al usuario exportar resultados, gráficas y tablas generadas por el sistema en formato reutilizable para documentación o análisis posteriores.
CU-6	Cambiar idioma de la interfaz	Permite al usuario seleccionar y cambiar el idioma de la interfaz del sistema, facilitando su uso en distintos contextos lingüísticos.
CU-7	Analizar variables no binarias	Permite incorporar y analizar nuevas variables del conjunto de datos, incluyendo variables no binarias, ampliando las posibilidades de estudio del sistema.
CU-8	Mejorar interpretación con IA	Permite generar explicaciones más precisas, coherentes y rápidas mediante la mejora del sistema de inteligencia artificial integrado.
CU-9	Ampliar visualizaciones Cox y Test de Log-Rank	Permite generar nuevas visualizaciones asociadas a los modelos de regresión de Cox y Test de Log-Rank, mejorando la interpretación visual de los resultados.

Tabla 1: Identificación de casos de uso de la ampliación del sistema

8.3. Variables utilizadas en el análisis

La ampliación del sistema se apoya en un conjunto de variables que permiten estudiar el abandono académico desde una perspectiva temporal y, además, relacionarlo con características concretas del estudiante. Algunas de ellas son imprescindibles para cualquier modelo de supervivencia, mientras que otras actúan como covariables y permiten comparar perfiles o alimentar modelos más complejos, como la regresión de Cox, el Test de Log-Rank o Random Survival Forest.

La selección de estas variables no se ha realizado de forma arbitraria. Se han priorizado aquellas que cumplen tres criterios principales: que estén disponibles de forma estable en el conjunto de datos, que tengan una interpretación clara dentro del contexto académico y que puedan aportar información útil sobre la permanencia o el abandono del estudiante. También se ha buscado mantener un equilibrio razonable entre riqueza analítica y claridad, ya que incluir demasiadas variables puede hacer que los resultados sean más difíciles de explicar.

Variable o grupo	**Qué representa**	**Motivo de selección**
Identificador del estudiante `id_student`	Identifica de forma única a cada estudiante dentro del conjunto de datos.	Se utiliza para consolidar registros y evitar duplicidades durante el preprocesamiento. No es una covariable explicativa, pero resulta necesaria para construir un dataset limpio y coherente.
Tiempo observado `date`	Indica el tiempo de seguimiento utilizado por los modelos de supervivencia.	Es una variable imprescindible, ya que el objetivo del análisis no es solo saber si se produce el abandono, sino estudiar cuándo ocurre.
Evento de abandono `final_result`	Recoge el resultado final del estudiante y permite identificar si se produce el evento de abandono.	Es la variable que define el evento analizado. Se transforma en una variable binaria para diferenciar abandono y no abandono dentro de los modelos.
Género `gender_F`	Representa el género del estudiante mediante una codificación binaria.	Se incluye porque permite analizar si existen diferencias de permanencia entre grupos. Además, es una variable sencilla de interpretar y útil para segmentar resultados.

Variable o grupo	**Qué representa**	**Motivo de selección**
Discapacidad `disability_N`	Indica si el estudiante aparece registrado con o sin discapacidad.	Se selecciona por su relevancia en el contexto educativo, ya que puede estar relacionada con necesidades de apoyo, accesibilidad o condiciones que influyen en la trayectoria académica.
Tramo de edad `age_band_*`	Agrupa al alumnado en rangos de edad: `0-35`, `35-55` y `55<=`.	Se incluye porque la edad puede reflejar perfiles académicos distintos: estudiantes jóvenes, personas que retoman estudios o alumnado con otras responsabilidades. Esto permite comparar curvas y riesgos entre grupos.
Nivel educativo previo `highest_education_*`	Describe la formación máxima alcanzada antes de acceder al curso o programa analizado.	Se considera relevante porque la preparación académica previa puede influir en la adaptación al entorno universitario y, por tanto, en la probabilidad de permanencia o abandono.
Créditos estudiados `studied_credits`	Refleja la carga académica asumida por el estudiante.	Se incorpora porque permite estudiar si la dedicación académica o el volumen de créditos se relaciona con el abandono. Además, es una variable no binaria, por lo que ayuda a cumplir el objetivo de ampliar el análisis más allá de variables simples.

Tabla 2: Variables principales utilizadas y justificación de su selección

Aunque el conjunto de datos puede contener más atributos procedentes del sistema original, como actividad en recursos, módulos, presentaciones, regiones o intentos previos, esta ampliación se centra especialmente en las variables anteriores. La razón es que permiten cubrir los objetivos del trabajo sin perder claridad: se conserva la información mínima necesaria para los modelos de supervivencia y se incorporan covariables personales y académicas que enriquecen la interpretación de los resultados. Otras variables podrían ser útiles en futuros análisis, pero en esta versión se ha optado por un conjunto más controlado, comprensible y directamente relacionado con los casos de uso definidos.

8.4. Diagrama de casos de uso

Tras la identificación de los casos de uso y los actores, se procede a la creación del diagrama de casos de uso. Este diagrama, elaborado mediante la herramienta Visual Paradigm, representa de forma visual las funcionalidades del sistema y las interacciones que los actores pueden realizar sobre él. Dicho diagrama se centra únicamente en los casos de uso asociados a la ampliación desarrollada, manteniendo implícitas las funcionalidades del sistema base.

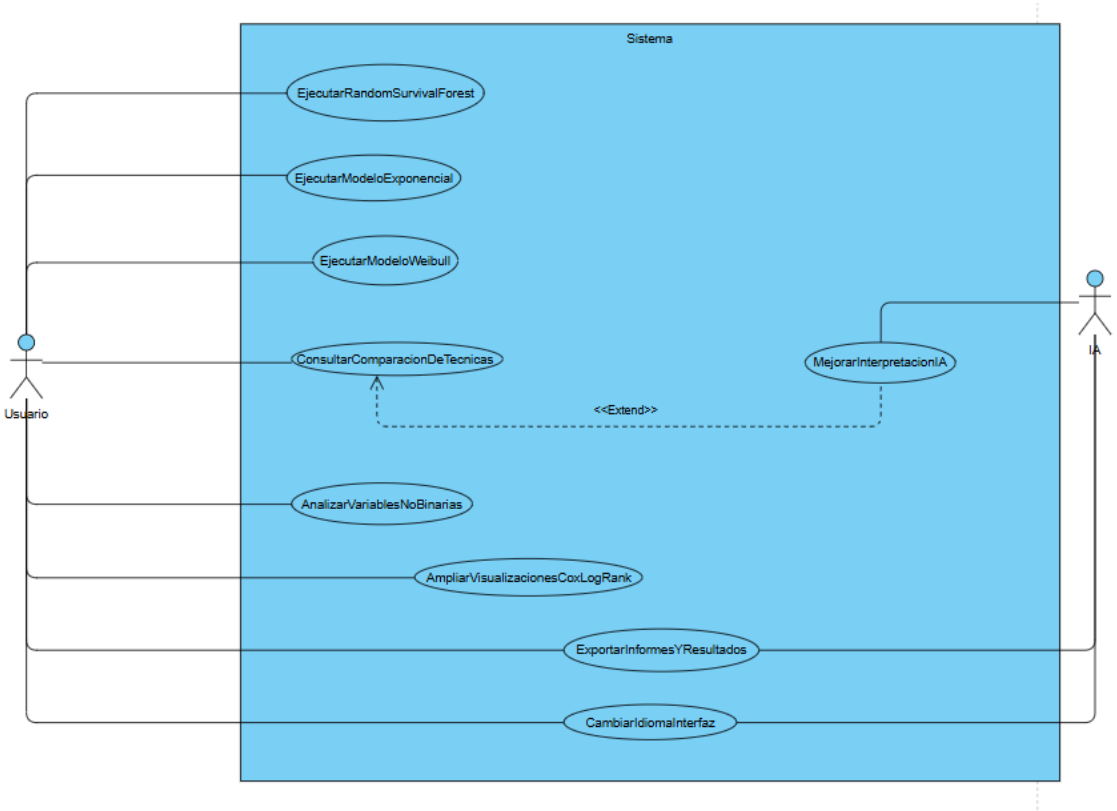

Figura 4: Diagrama de casos de uso de la ampliación del sistema

8.5. Especificación de los casos de uso

Una vez definidos los casos de uso, los actores del sistema y el diagrama general, se procede a la especificación de cada uno de ellos. En dicha especificación se describe con detalle cómo funciona cada funcionalidad desde el punto de vista del usuario, incluyendo condiciones iniciales, resultados esperados y posibles errores. Además, se identifican los actores implicados en cada caso de uso.

8.5.1. CU-1: EjecutarModeloExponencial

Tabla 3: Especificación del CU-1: Ejecutar modelo exponencial

Id	CU-1
Nombre	EjecutarModeloExponencial
Descripción	Este caso de uso describe el proceso mediante el cual el usuario aplica el modelo exponencial como técnica de análisis de supervivencia, con el objetivo de estudiar el tiempo hasta la ocurrencia del evento analizado.
Actor principal	Usuario
Actores secundarios	Sistema
Precondiciones	▪ El dataset debe haber sido cargado y preprocesado correctamente. ▪ El usuario debe haber accedido a la sección correspondiente al modelo exponencial.

Flujo principal	1. El caso de uso comienza cuando el usuario accede al módulo de Análisis de Supervivencia y selecciona el botón "Análisis Exponencial". 2. El sistema carga la vista del modelo exponencial y verifica que exista un dataset previamente cargado y preprocesado. 3. El sistema detecta que hay un dataset disponible y calcula automáticamente el resultado del modelo. 4. El sistema muestra en pantalla las salidas del módulo: tabla resumen, gráfica y comparativa de ajuste. 5. El usuario decide una acción posterior: ▪ Pulsar botón "Explicar". ▪ Pulsar botón "Exportar a PDF". ▪ Pulsar botón "Exportar informe combinado". 6. El sistema ejecuta la acción seleccionada y muestra la confirmación o resultado correspondiente.
Postcondiciones	El análisis mediante el modelo exponencial queda completado y los resultados quedan disponibles para su visualización, comparación o exportación posterior.
Flujos alternativos	**FA1 (Ejecución del modelo):** El sistema no puede ejecutar el modelo debido a datos insuficientes o incompatibles. El sistema muestra un mensaje de error indicando la imposibilidad de realizar el análisis.

8.5.2. CU-2: EjecutarModeloWeibull

Tabla 4: Especificación del CU-2: Ejecutar modelo Weibull

Id	CU-2
Nombre	EjecutarModeloWeibull
Descripción	Este caso de uso describe el proceso mediante el cual el usuario aplica el modelo de Weibull como técnica de análisis de supervivencia, permitiendo analizar el comportamiento del riesgo a lo largo del tiempo mediante un enfoque paramétrico.
Actor principal	Usuario
Actores secundarios	Sistema
Precondiciones	▪ El dataset debe haber sido cargado y preprocesado correctamente. ▪ El usuario debe haber accedido a la sección correspondiente al modelo de Weibull.
Flujo principal	1. El caso de uso comienza cuando el usuario accede al módulo de Análisis de Supervivencia y selecciona el botón "Análisis Weibull". 2. El sistema carga la vista del modelo de Weibull y verifica que exista un dataset previamente cargado y preprocesado. 3. El sistema detecta que hay un dataset disponible y calcula automáticamente el resultado del modelo. 4. El sistema muestra en pantalla las salidas del módulo: tabla resumen, gráfica y comparativa de ajuste. 5. El usuario decide una acción posterior: ▪ Pulsar botón "Explicar". ▪ Pulsar botón "Exportar a PDF". ▪ Pulsar botón "Exportar informe combinado". 6. El sistema ejecuta la acción seleccionada y muestra la confirmación o resultado correspondiente.

Postcondiciones	Los resultados quedan disponibles para su visualización, comparación o exportación.
Flujos alternativos	**FA1 (Ejecución del modelo):** El sistema detecta un error en los datos o parámetros seleccionados. El sistema muestra un mensaje indicando la imposibilidad de ejecutar el modelo.

8.5.3. CU-3: EjecutarRandomSurvivalForest

Tabla 5: Especificación del CU-3: Ejecutar Random Survival Forest

Id	CU-3
Nombre	EjecutarRandomSurvivalForest
Descripción	Este caso de uso describe el proceso mediante el cual el usuario aplica el modelo Random Survival Forest para realizar análisis de supervivencia mediante técnicas de aprendizaje automático.
Actor principal	Usuario
Actores secundarios	Sistema
Precondiciones	▪ El dataset debe haber sido cargado y preprocesado correctamente. ▪ El usuario debe haber accedido a la sección correspondiente a Random Survival Forest.

Flujo principal	1. El caso de uso comienza cuando el usuario accede al módulo de Análisis de Supervivencia y selecciona el botón "Random Survival Forest". 2. El sistema detecta la ruta correspondiente y ejecuta automáticamente el análisis utilizando el dataset en sesión. 3. El sistema muestra en pantalla los resultados del modelo, incluyendo: ▪ Tabla resumen del modelo. ▪ Gráfica de curvas de supervivencia estimadas por niveles de riesgo. ▪ Gráfica de importancia de variables. 4. El sistema muestra el panel de simulación de perfil con valores por defecto (género, discapacidad, edad, educación, créditos) junto con una primera estimación del perfil. 5. El usuario revisa los resultados obtenidos y, si lo desea, modifica los valores del perfil. 6. El usuario puede pulsar el botón "Simular perfil" para recalcular y visualizar el detalle del perfil, incluyendo curva de supervivencia, interpretación y métricas asociadas. 7. El usuario decide una acción posterior: ▪ Pulsar el botón "Explicar". ▪ Pulsar el botón "Exportar a PDF". 8. El sistema ejecuta la acción seleccionada y muestra la confirmación o resultado correspondiente.
Postcondiciones	Los resultados quedan disponibles para su visualización, comparación o exportación.
Flujos alternativos	**FA1 (Ejecución del modelo):** El sistema no puede completar el entrenamiento o ejecución del modelo. El sistema informa al usuario mediante un mensaje de error.

8.5.4. CU-4: ConsultarComparacionDeTecnicas

Tabla 6: Especificación del CU-4: Consultar comparación de técnicas

Id	CU-4
Nombre	ConsultarComparacionDeTecnicas
Descripción	Este caso de uso describe el proceso mediante el cual el usuario accede a una página específica del dashboard dedicada a la comparación de técnicas de análisis de supervivencia, con el objetivo de consultar información comparativa entre los distintos métodos implementados en el sistema.
Actor principal	Usuario
Actores secundarios	Sistema de Inteligencia Artificial (IA)
Precondiciones	▪ El usuario debe haber accedido previamente a la sección "Análisis de supervivencia" del dashboard. ▪ La página "Comparación de técnicas" debe estar integrada en el sistema de rutas de la aplicación. ▪ La opción de acceso a esta funcionalidad debe estar disponible en el menú superior únicamente cuando el usuario se encuentre en la sección correspondiente.

Flujo principal	1. El caso de uso comienza cuando el usuario accede a la página "Comparación de técnicas". 2. El sistema valida que exista un dataset disponible en la sesión. 3. El sistema carga automáticamente una tabla comparativa de técnicas que incluye información como el tipo de modelo, hipótesis, ventajas, limitaciones y contexto de uso recomendado. 4. El sistema genera una visualización comparativa en forma de gráfico de barras, mostrando puntuaciones orientativas (capacidad predictiva, interpretabilidad y flexibilidad en una escala de 0 a 5). 5. El sistema genera un bloque explicativo textual mediante el módulo de inteligencia artificial, en el que se resumen las principales diferencias entre técnicas y se propone una estrategia metodológica de uso. 6. El usuario consulta la información mostrada y la utiliza como apoyo para el análisis e interpretación de los resultados.
Postcondiciones	La página de comparación de técnicas queda cargada correctamente y la información comparativa permanece disponible para su consulta, interpretación o posible exportación posterior.

Flujos alternativos	▪ **FA1 (Carga de la página):** el sistema no puede cargar correctamente la página de comparación. En ese caso, muestra un mensaje de error al usuario indicando la imposibilidad de acceder a dicha funcionalidad. ▪ **FA2 (Generación de visualización comparativa):** no es posible generar el gráfico comparativo debido a la falta de datos o a incompatibilidades entre las técnicas. El sistema mantiene visible la tabla comparativa y el bloque explicativo automático, pero omite la visualización gráfica. ▪ **FA3 (Generación del bloque explicativo):** el sistema no puede generar el texto explicativo automático. El sistema mantiene visible la tabla comparativa y, en su caso, la visualización gráfica, mostrando un aviso al usuario.

8.5.5. CU-5: ExportarInformesYResultados

Tabla 7: Especificación del CU-5: Exportar informes y resultados

Id	CU-5
Nombre	ExportarInformesYResultados
Descripción	Este caso de uso describe el proceso mediante el cual el usuario exporta los resultados, gráficas y tablas generadas por el sistema en un formato reutilizable.
Actor principal	Usuario
Actores secundarios	Sistema
Precondiciones	▪ Deben existir resultados generados previamente en el sistema. ▪ El usuario debe haber accedido a la funcionalidad de exportación.
Flujo principal	1. El caso de uso comienza cuando el usuario pulsa el botón "Exportar a PDF" del módulo correspondiente. 2. El sistema abre un modal de exportación. 3. El usuario introduce, de forma opcional, el nombre del archivo y selecciona el contenido a incluir en el informe. 4. El usuario confirma la operación pulsando "Descargar PDF". 5. El sistema valida que existan datos o resultados suficientes para realizar la exportación. 6. El sistema genera el informe en formato PDF con los bloques seleccionados (resumen, tabla, gráfica e interpretación, según el módulo). 7. El sistema entrega el archivo generado para su descarga.
Postcondiciones	El archivo de resultados queda generado correctamente y puede ser utilizado en documentación o análisis posteriores.

Flujos alternativos	**FA1 (Generación del archivo):** El sistema no puede generar el archivo. El sistema muestra un mensaje de error al usuario.

8.5.6. CU-6: CambiarIdiomaInterfaz

Tabla 8: Especificación del CU-6: Cambiar idioma de la interfaz

Id	CU-6
Nombre	CambiarIdiomaInterfaz
Descripción	Este caso de uso describe el proceso mediante el cual el usuario cambia el idioma de la interfaz del sistema.
Actor principal	Usuario
Actores secundarios	Sistema
Precondiciones	▪ El sistema debe estar en ejecución. ▪ Deben existir varios idiomas disponibles.
Flujo principal	1. El caso de uso comienza cuando el usuario accede al selector de idioma de la barra de navegación. 2. El sistema muestra los idiomas disponibles. 3. El usuario selecciona el idioma deseado. 4. El sistema procesa la selección y recarga los textos visibles de la interfaz en el idioma seleccionado. 5. Finalmente, la interfaz se muestra completamente actualizada en el idioma elegido.
Postcondiciones	El idioma de la interfaz queda actualizado correctamente.
Flujos alternativos	**FA1 (Cambio de idioma):** El sistema no puede aplicar el idioma seleccionado. El sistema mantiene el idioma anterior y muestra un mensaje de aviso al usuario.

8.5.7. CU-7: AnalizarVariablesNoBinarias

Tabla 9: Especificación del CU-7: Analizar variables no binarias

Id	CU-7
Nombre	AnalizarVariablesNoBinarias
Descripción	Este caso de uso describe el proceso mediante el cual el usuario incorpora y analiza nuevas variables del conjunto de datos, incluyendo variables no binarias.
Actor principal	Usuario
Actores secundarios	Sistema
Precondiciones	▪ El dataset debe haber sido cargado correctamente. ▪ Deben existir variables adicionales o no binarias en el conjunto de datos.
Flujo principal	1. El caso de uso comienza cuando el usuario carga un archivo CSV y pulsa la opción “Preprocesar CSV”. 2. El sistema valida la estructura del dataset y conserva las variables no binarias soportadas por el pipeline. 3. El usuario accede al módulo de análisis de covariables o supervivencia y selecciona una variable no binaria disponible. 4. El sistema transforma la variable según la técnica aplicada (por ejemplo, agrupación por categorías o discretización por cuantiles en variables como créditos). 5. El sistema ejecuta el análisis correspondiente utilizando las variables seleccionadas. 6. El sistema muestra en pantalla los resultados actualizados, incluyendo tablas, métricas y representaciones gráficas. 7. El usuario consulta los resultados y los utiliza para interpretar el efecto de las variables analizadas.
Postcondiciones	Las nuevas variables quedan integradas en el análisis y los resultados quedan disponibles para su interpretación.

Flujos alternativos	**FA1 (Validación de variables):** El sistema detecta que alguna variable no es compatible con el análisis seleccionado. El sistema informa al usuario mediante un mensaje de error.

8.5.8. CU-8: MejorarInterpretacionIA

Tabla 10: Especificación del CU-8: Mejorar interpretación mediante IA

Id	CU-8
Nombre	MejorarInterpretacionIA
Descripción	Este caso de uso describe el proceso mediante el cual el sistema genera explicaciones más precisas, coherentes y rápidas mediante una mejora del módulo de inteligencia artificial.
Actor principal	Sistema de Inteligencia Artificial (IA)
Actores secundarios	Usuario
Precondiciones	▪ Deben existir resultados generados previamente en el sistema. ▪ El módulo de inteligencia artificial debe estar disponible.
Flujo principal	1. El caso de uso comienza cuando el usuario solicita una interpretación de los resultados obtenidos. 2. El sistema recopila la información relevante del análisis ejecutado. 3. El sistema envía dicha información al módulo de inteligencia artificial. 4. El módulo de inteligencia artificial procesa los datos y genera una explicación. 5. El sistema recibe la respuesta generada y la presenta en la interfaz para su consulta por parte del usuario.
Postcondiciones	La explicación generada queda disponible para el usuario, facilitando la interpretación de los resultados.
Flujos alternativos	**FA1 (Generación de respuesta):** La inteligencia artificial no puede generar una respuesta adecuada. El sistema muestra un mensaje de error al usuario.

8.5.9. CU-9: AmpliarVisualizacionesCoxTestLogRank

Tabla 11: Especificación del CU-9: Ampliar visualizaciones Cox y Test de Log-Rank

Id	CU-9
Nombre	AmpliarVisualizacionesCoxTestLogRank
Descripción	Este caso de uso describe el proceso mediante el cual el sistema genera nuevas visualizaciones asociadas a los modelos de regresión de Cox y Test de Log-Rank.
Actor principal	Usuario
Actores secundarios	Sistema
Precondiciones	▪ Deben haberse ejecutado previamente análisis mediante regresión de Cox o Test de Log-Rank. ▪ Los resultados correspondientes deben estar disponibles en el sistema.
Flujo principal	1. El caso de uso comienza cuando el usuario accede al módulo de análisis de supervivencia y selecciona "Regresión de Cox" o "Test de Log-Rank". 2. El sistema muestra las opciones de visualización disponibles. 3. El usuario selecciona la visualización deseada. 4. El sistema obtiene los resultados del análisis correspondientes a la configuración activa. 5. El sistema procesa la información y genera la representación gráfica solicitada. 6. El sistema muestra la visualización en pantalla para su consulta por parte del usuario.
Postcondiciones	La visualización queda generada correctamente y disponible para su interpretación o exportación.
Flujos alternativos	**FA1 (Disponibilidad de datos):** No existen resultados previos de Cox o Test de Log-Rank. El sistema informa al usuario de que debe ejecutar previamente dichos análisis.

8.6. Matriz de trazabilidad

La siguiente matriz muestra la relación entre los Requisitos Funcionales (RF) definidos para el sistema y los Casos de Uso (CU) que los implementan. De este modo se garantiza la cobertura de todos los requisitos dentro del diseño y desarrollo de la aplicación.

Req	**CU-1**	**CU-2**	**CU-3**	**CU-4**	**CU-5**	**CU-6**	**CU-7**	**CU-8**	**CU-9**
RF1				X				X	
RF2						X			
RF3							X		
RF4							X		
RF5									X
RF6	X	X	X						
RF7	X								
RF8		X							
RF9			X						
RF10				X					
RF11								X	
RF12								X	
RF13	X	X	X		X				

Tabla 12: Matriz de trazabilidad entre requisitos funcionales y casos de uso

Como puede observarse en la matriz, todos los requisitos funcionales definidos para la ampliación del sistema quedan cubiertos por al menos un caso de uso. Esto permite comprobar que no existen requisitos funcionales aislados sin representación en el análisis. En el caso concreto de RF13, la trazabilidad se asocia al caso de uso general de exportación y también a los modelos Exponencial, Weibull y Random Survival Forest, ya que estas vistas incorporan acciones específicas para generar informes o exportar resultados. Asimismo, cada caso de uso se relaciona con una o varias necesidades concretas del sistema, lo que facilita mantener la trazabilidad entre los objetivos planteados, los requisitos especificados y las funcionalidades que finalmente se desarrollan en la aplicación.

8.7. Diagramas de actividad

8.7.1. CU-1: EjecutarModeloExponencial

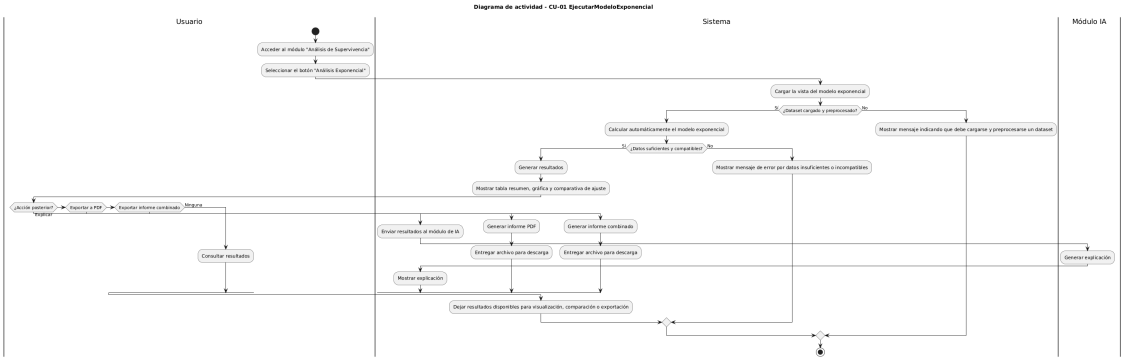

Figura 5: Diagrama de actividad del CU-1: EjecutarModeloExponencial

8.7.2. CU-2: EjecutarModeloWeibull

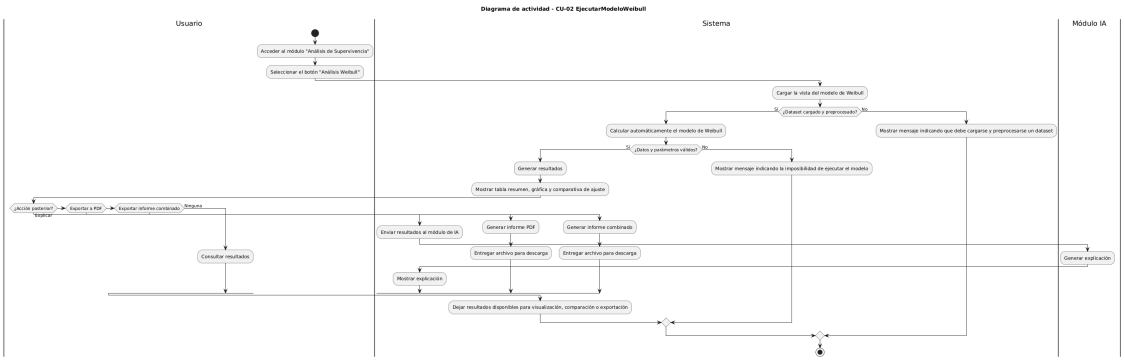

Figura 6: Diagrama de actividad del CU-2: EjecutarModeloWeibull

8.7.3. CU-3: EjecutarRandomSurvivalForest

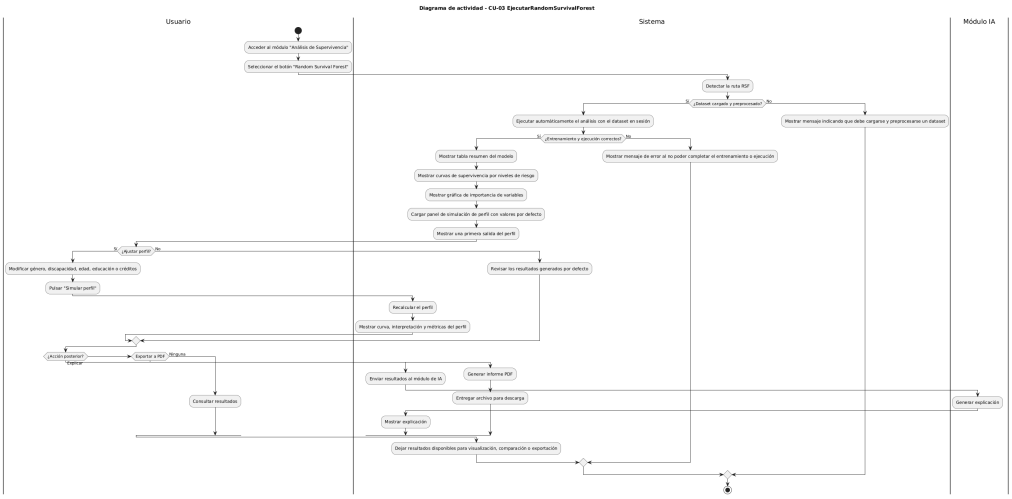

Figura 7: Diagrama de actividad del CU-3: EjecutarRandomSurvivalForest

8.7.4. CU-4: ConsultarComparacionDeTecnicas

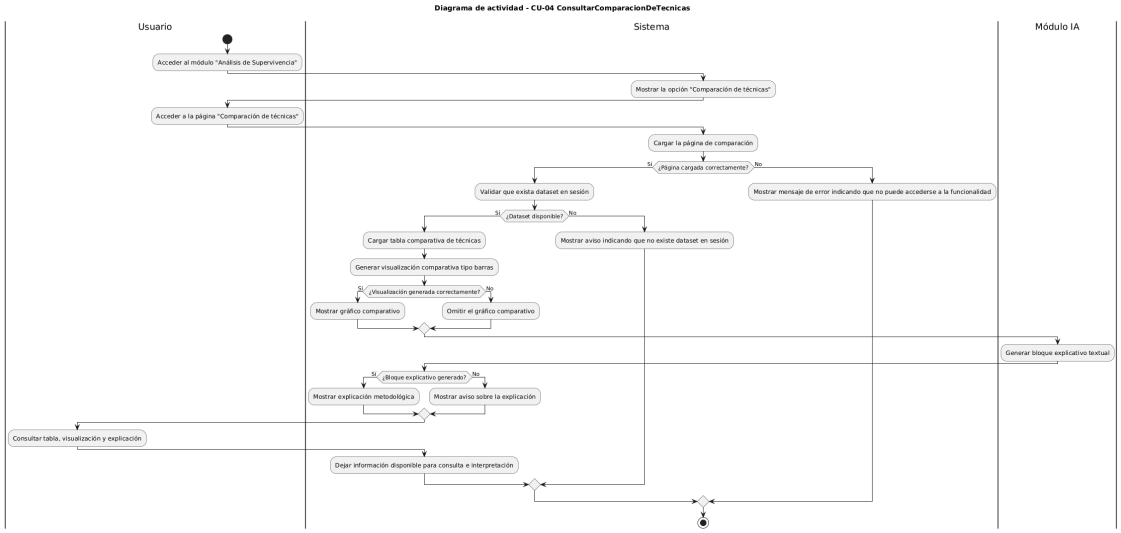

Figura 8: Diagrama de actividad del CU-4: ConsultarComparacionDeTecnicas

8.7.5. CU-5: ExportarInformesYResultados

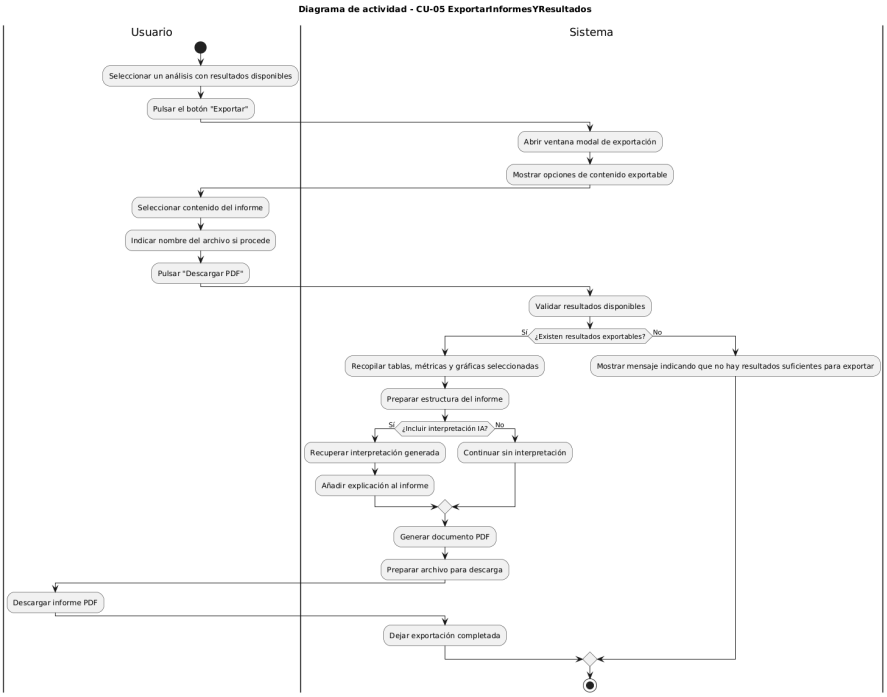

Figura 9: Diagrama de actividad del CU-5: ExportarInformesYResultados

8.7.6. CU-6: CambiarIdiomaInterfaz

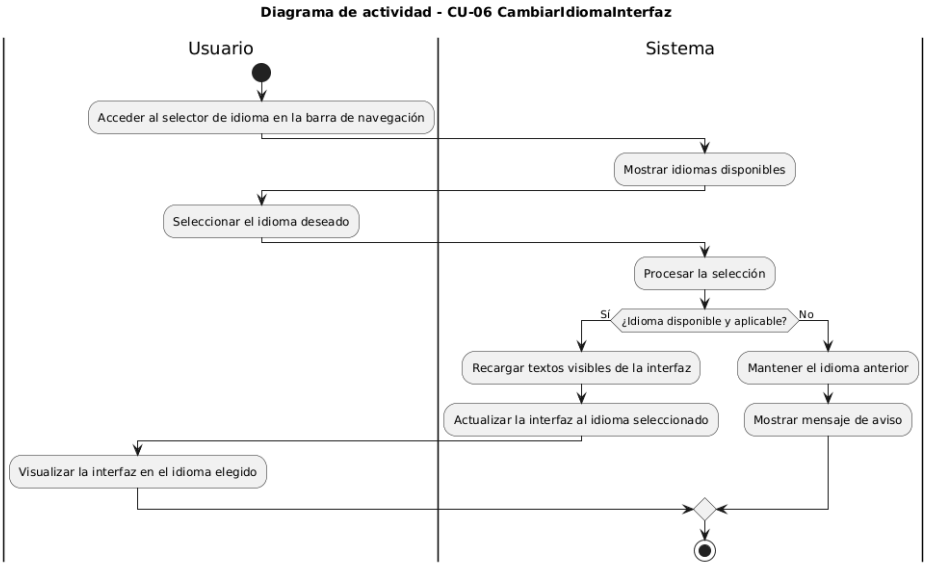

Figura 10: Diagrama de actividad del CU-6: CambiarIdiomaInterfaz

8.7.7. CU-7: AnalizarVariablesNoBinarias

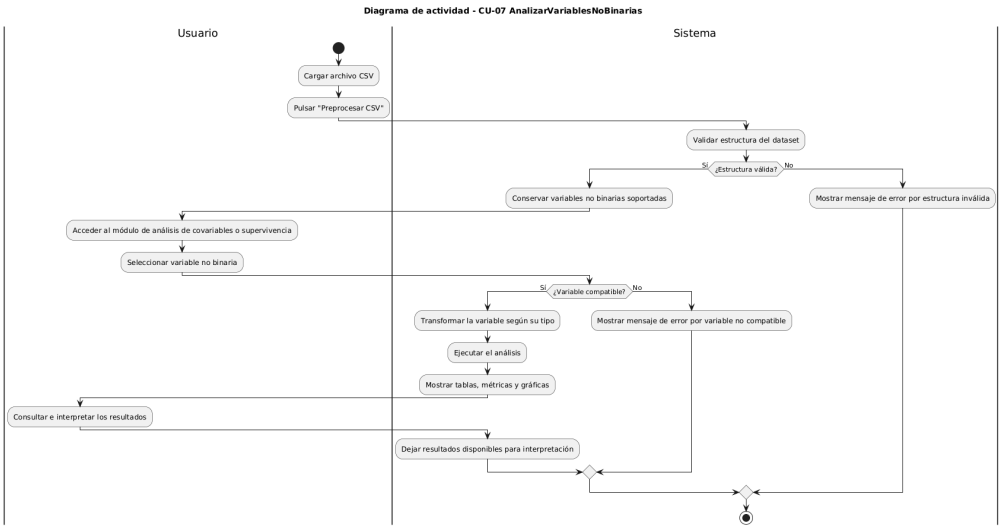

Figura 11: Diagrama de actividad del CU-7: AnalizarVariablesNoBinarias

8.7.8. CU-8: MejorarInterpretacionIA

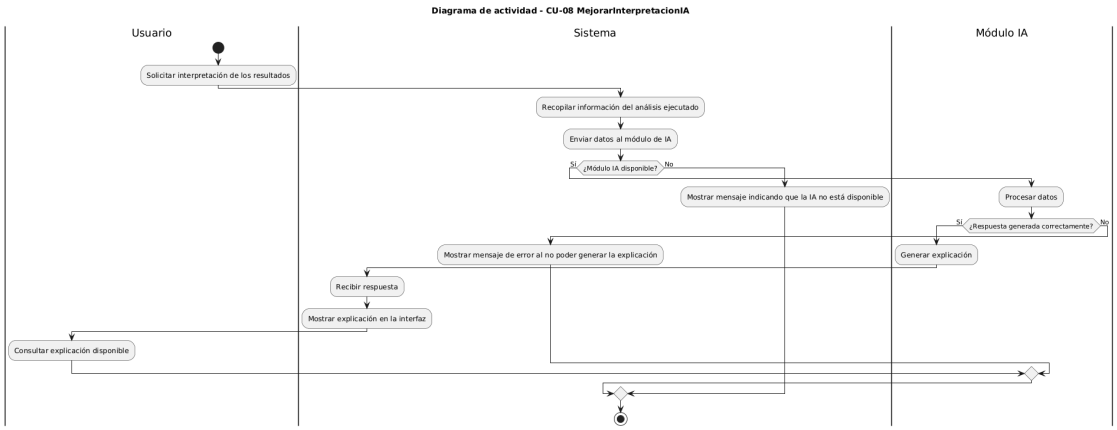

Figura 12: Diagrama de actividad del CU-8: MejorarInterpretacionIA

8.7.9. CU-9: AmpliarVisualizacionesCoxTestLogRank

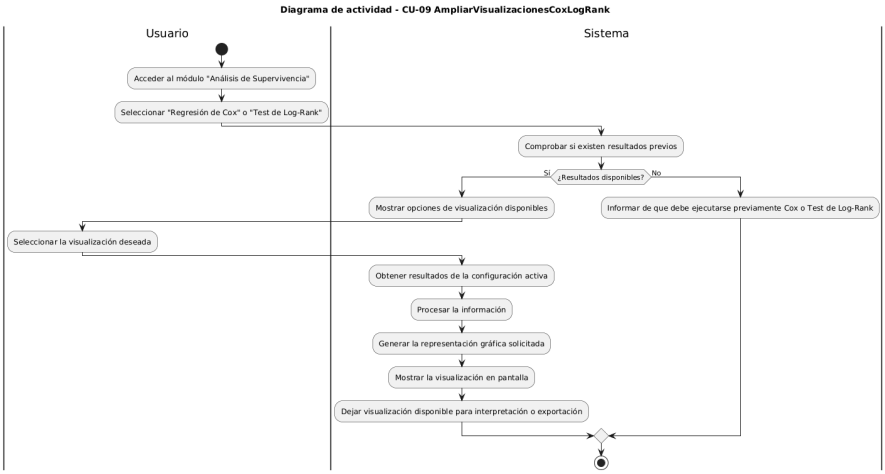

Figura 13: Diagrama de actividad del CU-9: AmpliarVisualizacionesCoxTestLogRank

9 Diseño del sistema

La etapa de diseño es una fase clave dentro del desarrollo de la aplicación, ya que permite transformar los requisitos definidos anteriormente en una solución técnica concreta [9]. En este punto el proyecto deja de ser solo una lista de necesidades y empieza a tomar forma: se decide cómo se organiza el sistema, cómo se comunican sus partes y de qué manera el usuario va a interactuar con los resultados.

En este Trabajo Fin de Grado, además, el diseño tiene una particularidad importante. La aplicación no se construye desde cero, sino que parte de un dashboard previo que ya ofrecía funcionalidades de carga de datos, preprocesamiento y análisis de supervivencia. Por tanto, la solución diseñada se plantea como una ampliación ordenada del sistema existente. La idea no es romper la base anterior, sino aprovecharla y hacerla crecer con nuevos modelos, nuevas visualizaciones, soporte multilingüe, exportación de informes e interpretación asistida por inteligencia artificial.

9.1. Arquitectura del sistema

La arquitectura del sistema se organiza siguiendo una estructura modular. Esta decisión resulta bastante natural para una aplicación desarrollada en Python y Dash, ya que permite separar la interfaz, la lógica de análisis, la generación de informes y los servicios auxiliares. Gracias a esta división, cada parte del sistema tiene una responsabilidad concreta y es más sencillo mantener el proyecto, localizar errores o incorporar nuevas técnicas de análisis en el futuro.

Desde un punto de vista general, el sistema puede entenderse como una aplicación web local compuesta por varias capas. En primer lugar, se encuentra la capa de presentación, construida con Dash, HTML y componentes interactivos. Esta capa es la que ve el usuario: menús, formularios, botones, tablas, gráficas y modales de exportación. En segundo lugar, aparece la capa de control, formada principalmente por los callbacks de Dash, que conectan las acciones del usuario con la lógica interna de la aplicación. Por último, se encuentra la capa de procesamiento, donde se ejecutan los modelos estadísticos, las transformaciones de datos, la generación de visualizaciones, la creación de PDFs y las peticiones al módulo de inteligencia artificial.

La separación por capas se completa con una distribución por componentes. En lugar de concentrar toda la lógica en una única parte de la aplicación, el diseño distingue entre navegación, presentación visual, gestión de eventos, preparación de datos, ejecución

de modelos, visualización de resultados, generación de informes, traducción de textos e interpretación mediante inteligencia artificial. Esta visión resulta más clara para entender el sistema en conjunto, mientras que los archivos concretos que materializan cada responsabilidad se detallan más adelante en el capítulo de implementación.

Esta organización también facilita la ampliación del dashboard. Si se incorpora una nueva técnica de supervivencia, no es necesario replantear toda la aplicación: basta con integrarla dentro del componente de análisis, conectarla con la interfaz y, si procede, añadir sus visualizaciones y su exportación. La verdad es que esta idea es importante, porque el proyecto parte de un sistema previo y necesita crecer sin perder estabilidad ni coherencia.

Componente de diseño	**Responsabilidad principal**
Interfaz de usuario	Presenta las pantallas, controles, tablas, gráficas, botones y modales con los que interactúa el usuario.
Gestor de navegación	Organiza el acceso a las distintas secciones del dashboard y mantiene un recorrido coherente entre carga, análisis, comparación y exportación.
Gestor de interacción	Recibe las acciones del usuario y coordina la respuesta del sistema, conectando la interfaz con los procesos internos.
Gestor de datos	Controla la carga, validación, limpieza y preparación del dataset antes de ejecutar los modelos.
Motor de análisis	Agrupa las técnicas estadísticas y predictivas utilizadas para estudiar la supervivencia académica.
Generador de visualizaciones	Transforma los resultados de los modelos en gráficas, curvas, tablas y comparaciones interpretables.
Generador de informes	Prepara la exportación de resultados en documentos reutilizables, incorporando tablas, gráficos e interpretaciones.
Módulo de inteligencia artificial	Produce explicaciones textuales de apoyo a partir de los resultados obtenidos en los análisis.
Sistema de internacionalización	Gestiona los textos de la interfaz y permite adaptar la aplicación a castellano e inglés.

Tabla 13: Componentes principales de la arquitectura del sistema

9.2. Diseño de la interfaz

El diseño de la interfaz mantiene la idea principal del dashboard original: ofrecer al usuario un entorno visual desde el que pueda cargar datos, ejecutar análisis y consultar resultados sin tener que trabajar directamente con código. La verdad es que este punto es importante, porque el sistema está pensado para facilitar el análisis de supervivencia en un contexto académico, donde no siempre se parte de un perfil técnico avanzado.

La navegación se estructura mediante diferentes páginas o secciones. Cada una agrupa funcionalidades relacionadas: carga y visualización del dataset, análisis de covariables, técnicas de supervivencia, comparación de modelos y exportación de resultados. Esta organización evita mezclar demasiada información en una sola pantalla y permite que el usuario avance poco a poco, como si siguiera un pequeño recorrido: primero carga los datos, después los prepara, luego ejecuta modelos y finalmente interpreta o exporta los resultados.

En las páginas de análisis se ha seguido un patrón común. Primero se presenta la técnica seleccionada, después se muestran los controles necesarios y, finalmente, se generan tablas, métricas, gráficas e interpretaciones. Este patrón se repite en modelos como Exponencial, Weibull y Random Survival Forest, lo que aporta coherencia al uso de la aplicación. Cuando el usuario aprende cómo funciona una sección, puede moverse por las demás con menos esfuerzo.

También se ha cuidado el diseño de los modales de exportación. Estos permiten seleccionar qué contenido se desea incluir en el informe, como tablas, gráficos o explicaciones generadas por IA. De esta forma, la exportación no se limita a descargar una captura rígida de la pantalla, sino que ofrece cierto control sobre el resultado final. Además, la interfaz incorpora soporte multilingüe, permitiendo alternar entre castellano e inglés y adaptando los textos visibles de la aplicación al idioma seleccionado.

9.2.1. Interfaz de usuario (UI)

A continuación se muestran las principales pantallas de la interfaz desarrollada. Estas capturas permiten ver el recorrido básico que sigue el usuario dentro del dashboard: desde la entrada inicial al sistema, pasando por la carga y limpieza del archivo de datos, hasta llegar a las secciones de análisis de covariables y análisis de supervivencia.

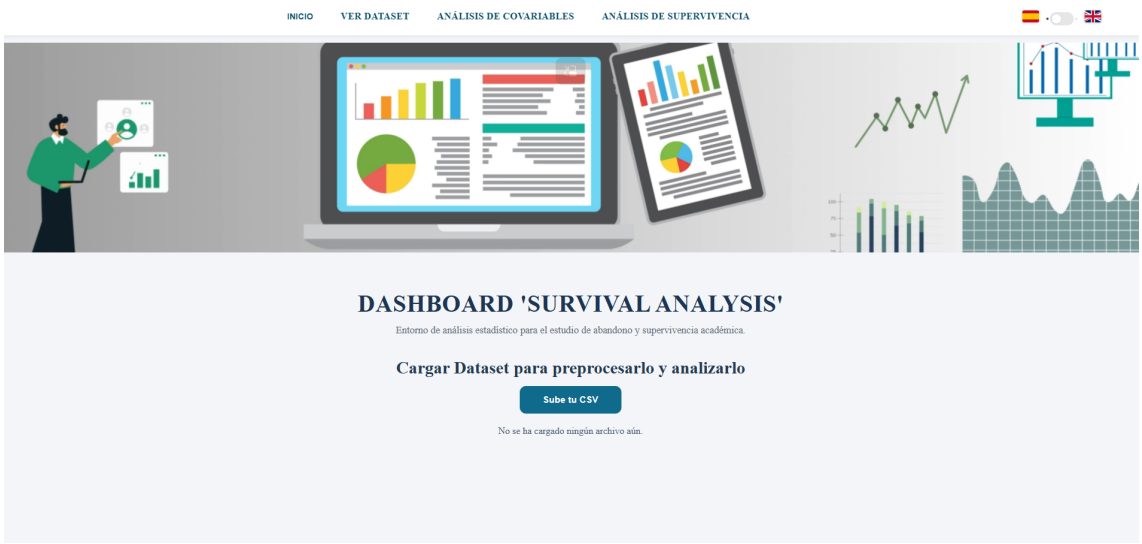

Figura 14: Pantalla principal del dashboard

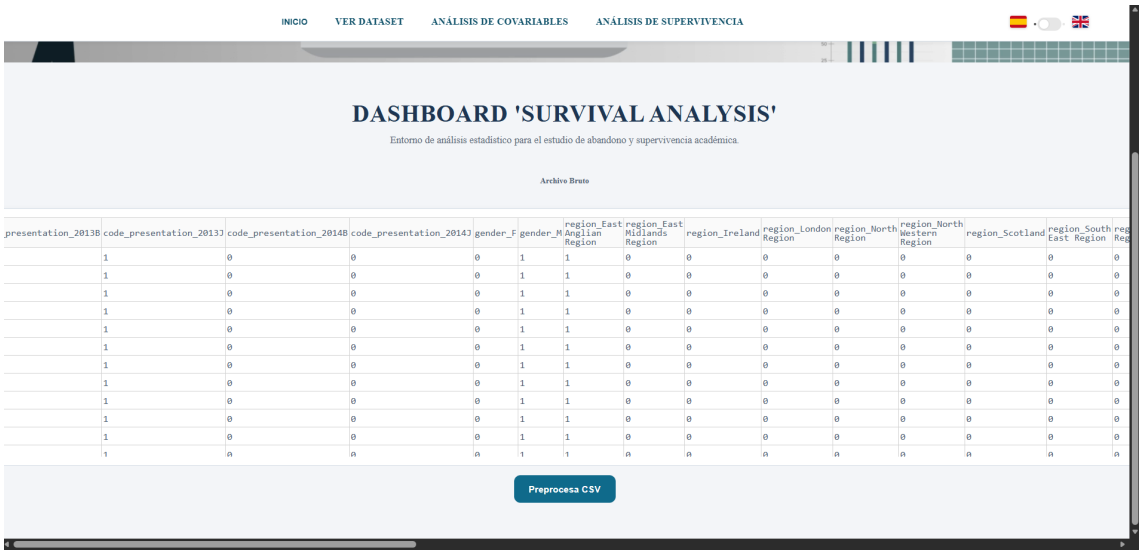

presentation_2013B	code_presentation_2013J	code_presentation_2014B	code_presentation_2014J	gender_F	gender_M	region_East Anglian Region	region_East Midlands Region	region_Ireland	region_London Region	region_North Region	region_North Western Region	region_Scotland	region_South East Region	reg Reg
	1	0	0	0	1	1	0	0	0	0	0	0	0	0
	1	0	0	0	1	1	0	0	0	0	0	0	0	0
	1	0	0	0	1	1	0	0	0	0	0	0	0	0
	1	0	0	0	1	1	0	0	0	0	0	0	0	0
	1	0	0	0	1	1	0	0	0	0	0	0	0	0
	1	0	0	0	1	1	0	0	0	0	0	0	0	0
	1	0	0	0	1	1	0	0	0	0	0	0	0	0
	1	0	0	0	1	1	0	0	0	0	0	0	0	0
	1	0	0	0	1	1	0	0	0	0	0	0	0	0
	1	0	0	0	1	1	0	0	0	0	0	0	0	0
	1	0	0	0	1	1	0	0	0	0	0	0	0	0

Figura 15: Visualización del archivo bruto cargado en el sistema

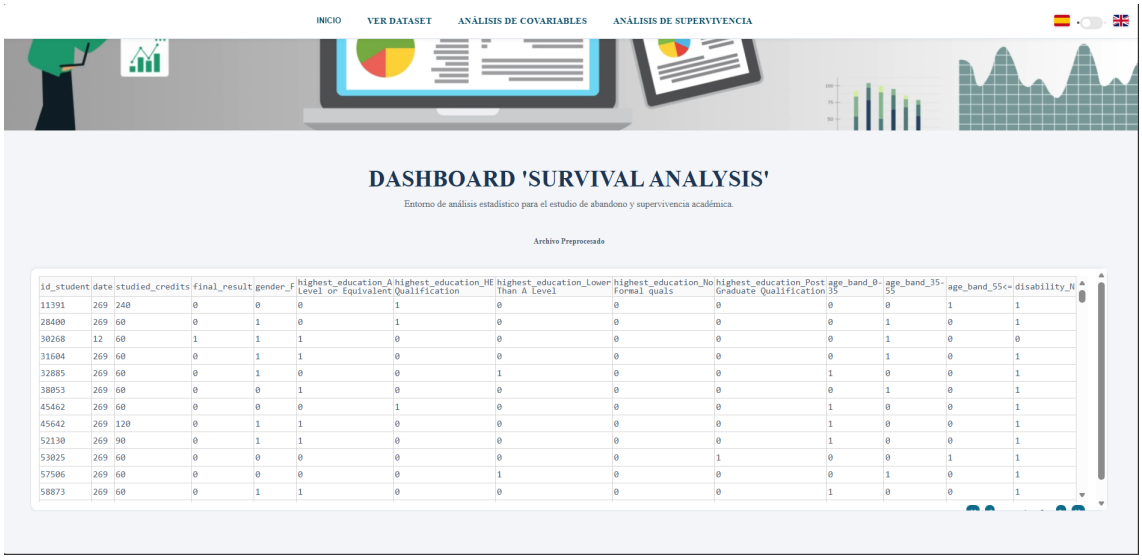

id_student	date	studied_credits	final_result	gender_F	highest_education_A Level or Equivalent	highest_education_HE Qualifications	highest_education_Lower Than A Level	highest_education_No Formal quals	highest_education_Post Graduate Qualification	age_band_0-35	age_band_35-55	age_band_55<=	disability_N
11391	269	240	0	0	0	1	0	0	0	0	0	1	1
28400	269	60	0	1	0	1	0	0	0	0	1	0	1
30268	12	60	1	1	1	0	0	0	0	0	1	0	0
31604	269	60	0	1	1	0	0	0	0	0	1	0	1
32885	269	60	0	1	0	0	1	0	0	1	0	0	1
38053	269	60	0	0	1	0	0	0	0	0	1	0	1
45462	269	60	0	0	0	1	0	0	0	1	0	0	1
45642	269	120	0	1	1	0	0	0	0	1	0	0	1
52130	269	90	0	1	1	0	0	0	0	1	0	0	1
53025	269	60	0	0	0	0	0	0	1	0	0	1	1
57506	269	60	0	0	0	0	1	0	0	0	1	0	1
58873	269	60	0	1	1	0	0	0	0	1	0	0	1

Figura 16: Visualización del archivo limpio tras el preprocesamiento

Ver dataset

La sección de visualización del dataset permite revisar los datos cargados antes y después del proceso de limpieza. Esta parte resulta útil para que el usuario pueda comprobar, de un vistazo, qué información se está utilizando realmente en los análisis posteriores.

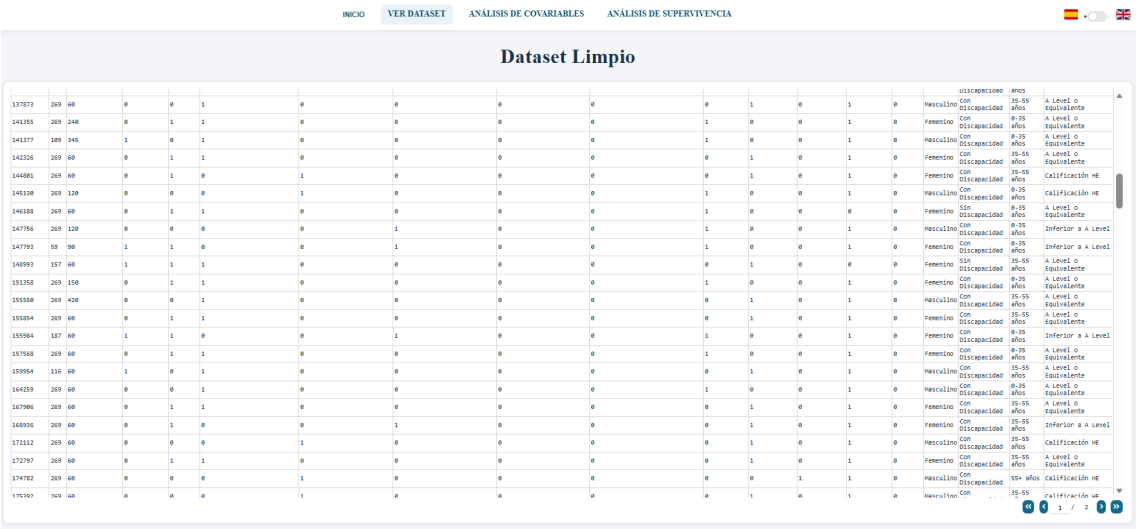

Figura 17: Vista inicial de la sección Ver dataset

Variable	Valores	Significado
Evento (final_result)	0 o 1	Representa si ocurrió el evento en el análisis de supervivencia: 1 = abandono (evento), 0 = censura (no abandono durante el seguimiento).
id_student	Entero (ID)	Identificador único del estudiante.
date	Numérico >= 0	Tiempo de seguimiento usado en supervivencia (por ejemplo, días).
final_result	0 o 1	Indicador de evento: 1 = abandono (evento), 0 = censurado/sin abandono.
gender_F	0 o 1	Género codificado: 1 = femenino, 0 = masculino.
disability_N	0 o 1	Discapacidad codificada: 1 = con discapacidad, 0 = sin discapacidad.
age_band_0-35	0 o 1	Indicador one-hot del grupo de edad 0-35.
age_band_35-55	0 o 1	Indicador one-hot del grupo de edad 35-55.
age_band_55<=	0 o 1	Indicador one-hot del grupo de edad 55=.
highest_education_A Level or Equivalent	0 o 1	Indicador one-hot de nivel educativo A Level o equivalente.
highest_education_HE Qualification	0 o 1	Indicador one-hot de titulación HE Qualification.
highest_education_Lower Than A Level	0 o 1	Indicador one-hot de nivel educativo inferior a A Level.
highest_education_No Formal quals	0 o 1	Indicador one-hot de ausencia de cualificaciones formales.
highest_education_Post Graduate Qualification	0 o 1	Indicador one-hot de estudios de posgrado.
studied_credits	Numérico	Créditos cursados por el estudiante (covariable numérica).

Figura 18: Detalle de la visualización del dataset dentro del dashboard

Análisis de covariables

El análisis de covariables permite explorar la relación entre las variables disponibles y el evento de interés. Esta pantalla sirve como apoyo previo al análisis de supervivencia, ya que ayuda a detectar qué variables pueden aportar información relevante antes de aplicar los modelos estadísticos.

Figura 19: Sección de análisis de covariables

Análisis de supervivencia

La sección de análisis de supervivencia actúa como punto de entrada a las distintas técnicas disponibles en el sistema. Desde esta pantalla el usuario puede acceder a los métodos clásicos y a las nuevas técnicas incorporadas, manteniendo una navegación centralizada y fácil de seguir.

Figura 20: Sección de análisis de supervivencia

Kaplan-Meier

Dentro del análisis de supervivencia, la sección de Kaplan-Meier permite consultar la curva de supervivencia general, aplicar filtros sobre los datos y exportar los resultados obtenidos. Es una de las vistas más importantes del sistema, ya que ofrece una primera lectura visual de la evolución de la supervivencia en el conjunto de datos.

Figura 21: Vista general del análisis Kaplan-Meier

Figura 22: Curva de supervivencia generada mediante Kaplan-Meier

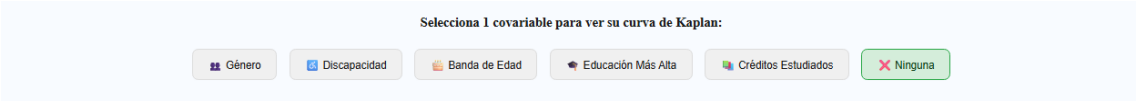

Figura 23: Filtros disponibles en el análisis Kaplan-Meier

Figura 24: Exportación a PDF de los resultados de Kaplan-Meier

Regresión de Cox

La vista de regresión de Cox permite analizar la influencia de distintas covariables sobre el tiempo hasta el evento. Además de mostrar los resultados del modelo, la interfaz incorpora filtros, gráficas asociadas y la opción de exportar la información generada.

Figura 25: Vista principal de la regresión de Cox

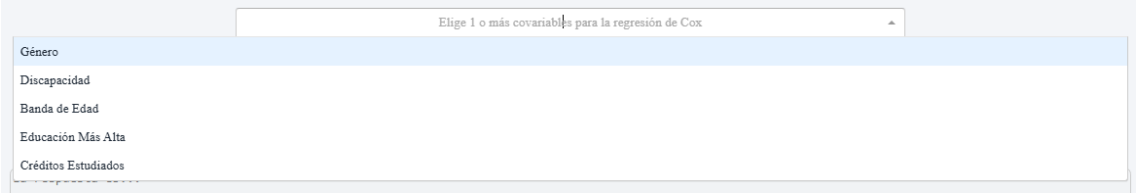

Figura 26: Filtros utilizados en la regresión de Cox

Figura 27: Gráfica generada a partir del modelo de regresión de Cox

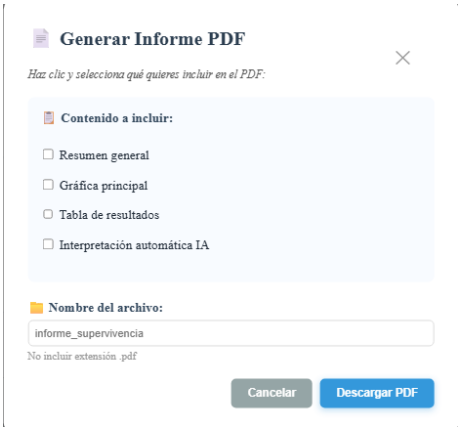

Figura 28: Botón de exportación a PDF utilizado en Cox y también en el Test de Log-Rank

Test de Log-Rank

El Test de Log-Rank se utiliza para comparar curvas de supervivencia entre grupos. En la aplicación comparte parte de la estructura visual con la regresión de Cox, especialmente en los filtros, pero orienta la salida a la comparación estadística entre categorías.

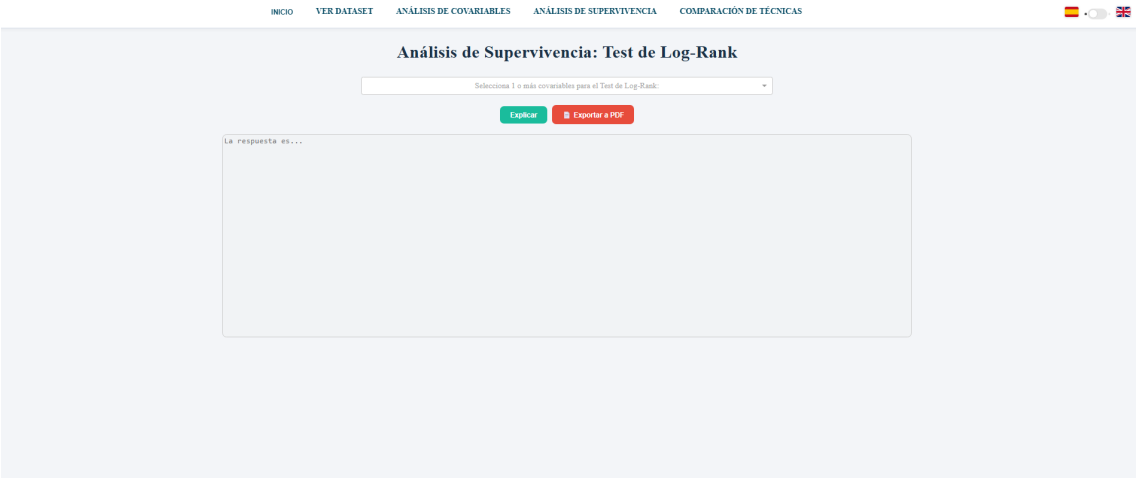

Figura 29: Vista principal del Test de Log-Rank

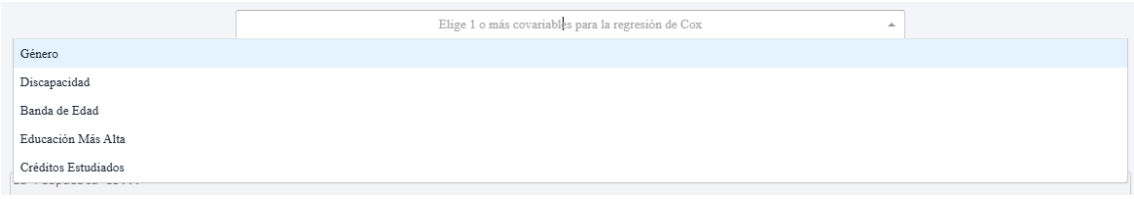

Figura 30: Filtros compartidos por Cox y el Test de Log-Rank

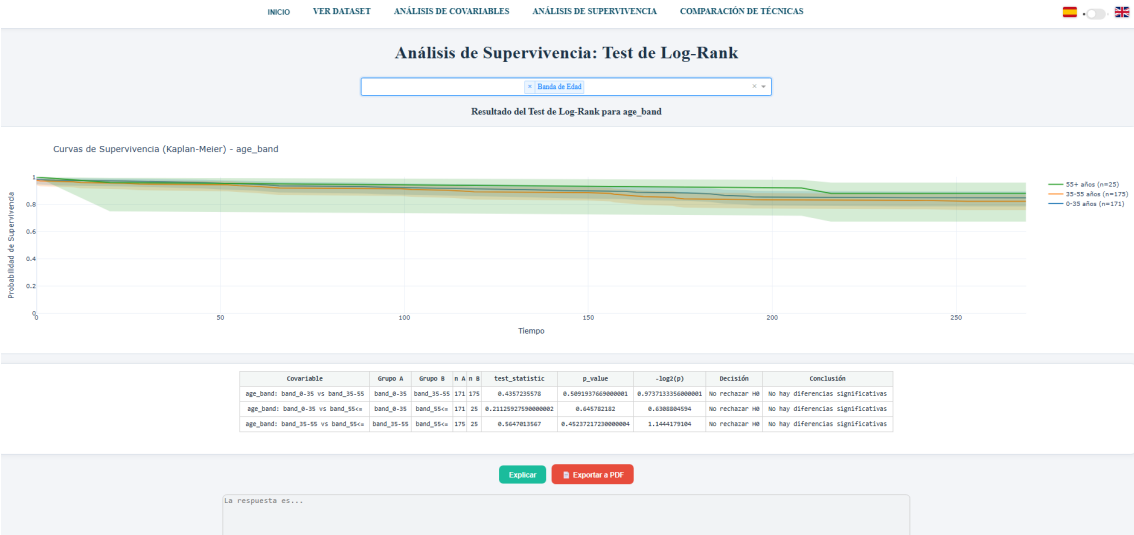

Covariable	Grupo A	Grupo B	n A	n B	test_statistic	p_value	-log2(p)	Decisión	Conclusión
age_band: band_0-35 vs band_35-55	band_0-35	band_35-55	171	175	0.4357235578	0.5091937669000001	0.9737133356000001	No rechazar H0	No hay diferencias significativas
age_band: band_0-35 vs band_55<=	band_0-35	band_55<=	171	25	0.2112592759000002	0.6457822182	0.6308004594	No rechazar H0	No hay diferencias significativas
age_band: band_35-55 vs band_55<=	band_35-55	band_55<=	175	25	0.5647013567	0.4523721723000004	1.1444179104	No rechazar H0	No hay diferencias significativas

Figura 31: Ejemplo de resultado generado mediante el Test de Log-Rank

Weibull

La técnica de Weibull amplía el análisis de supervivencia con un modelo paramétrico capaz de representar distintos comportamientos del riesgo a lo largo del tiempo. En la interfaz se muestran los resultados principales del ajuste, las visualizaciones asociadas y la opción de exportación conjunta.

Figura 32: Vista inicial del análisis mediante el modelo de Weibull

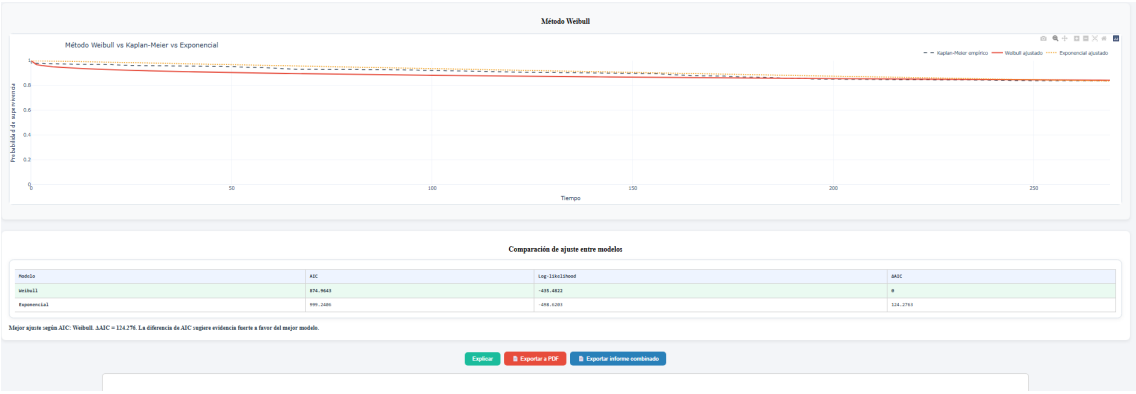

Figura 33: Resultados y visualizaciones del modelo de Weibull

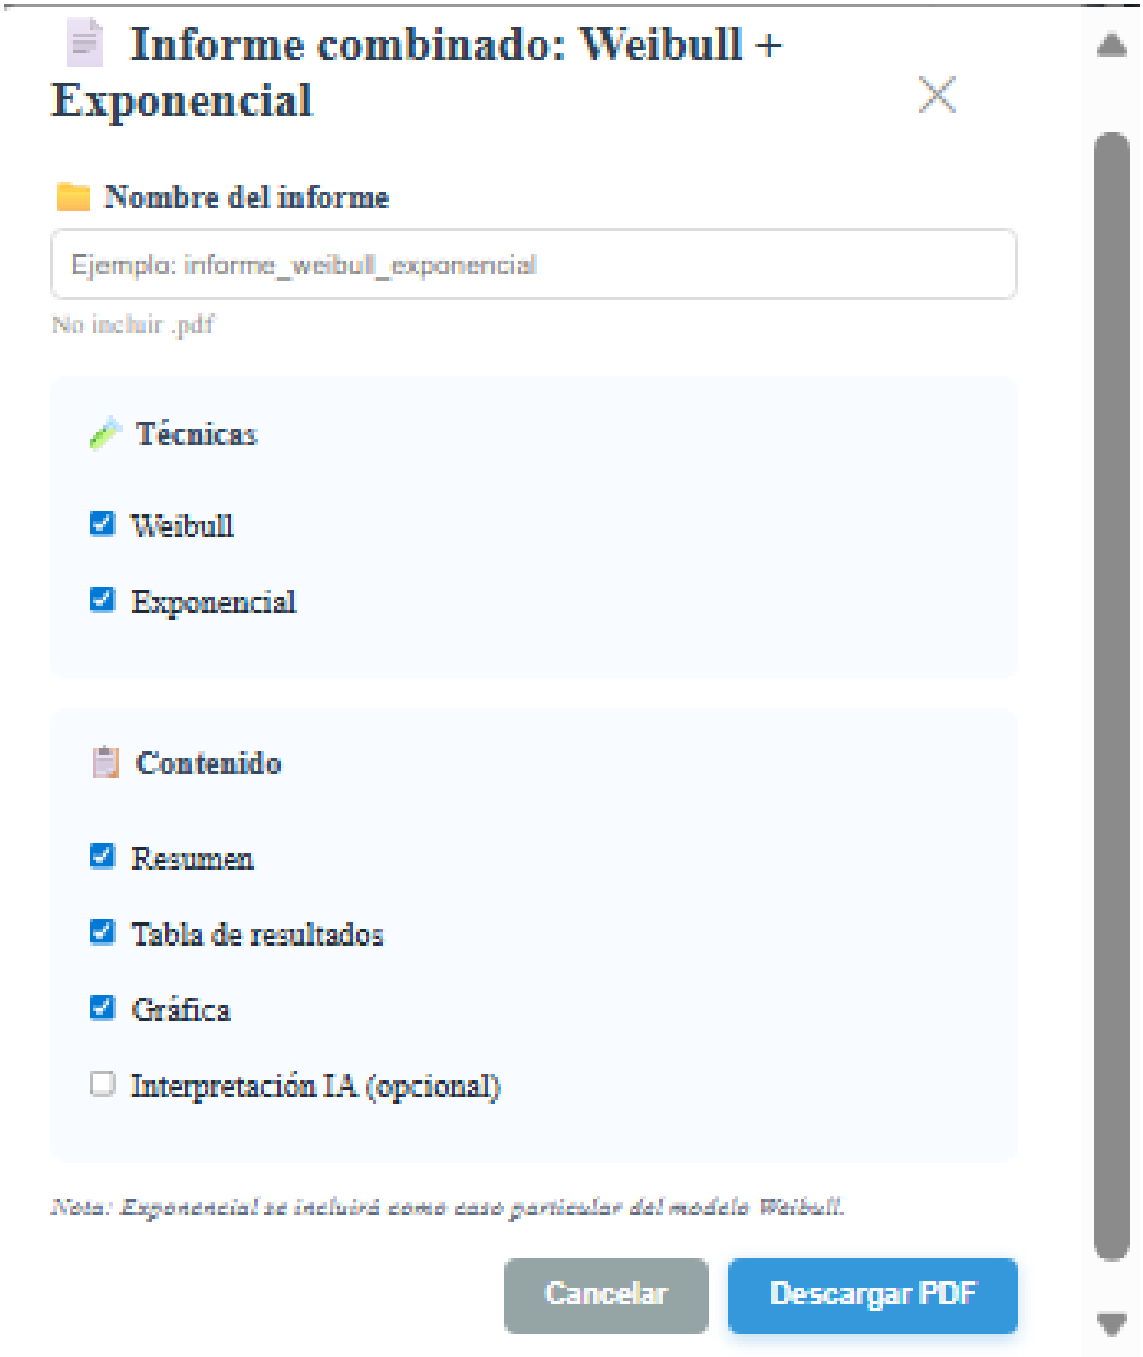

Figura 34: Botón de exportación combinada utilizado en Weibull y Exponencial, ya que ambos modelos exportan el mismo tipo de resultados

Exponencial

El modelo exponencial ofrece una aproximación paramétrica más sencilla, basada en una tasa de riesgo constante. Por eso, dentro de la aplicación resulta útil como técnica de referencia, especialmente para comparar su comportamiento frente a modelos más flexibles como Weibull o Random Survival Forest.

Figura 35: Vista inicial del análisis mediante el modelo exponencial

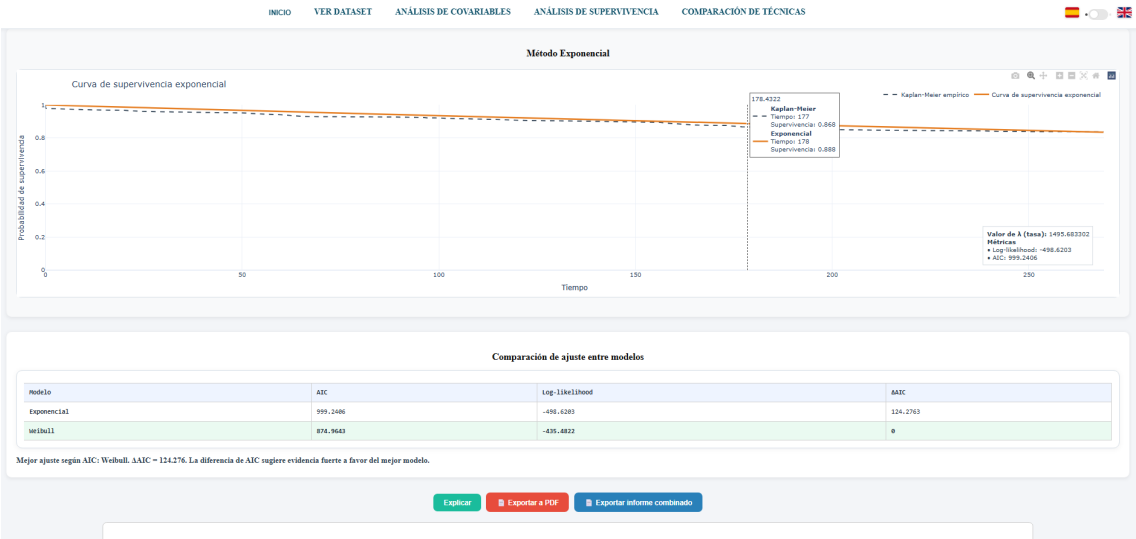

Figura 36: Resultados y visualizaciones del modelo exponencial

Random Survival Forest

Random Survival Forest incorpora una técnica basada en aprendizaje automático para estudiar relaciones más complejas entre las variables del dataset y el tiempo hasta el

evento. La interfaz recoge tanto la ejecución del modelo como los resultados gráficos y métricos necesarios para interpretar su comportamiento.

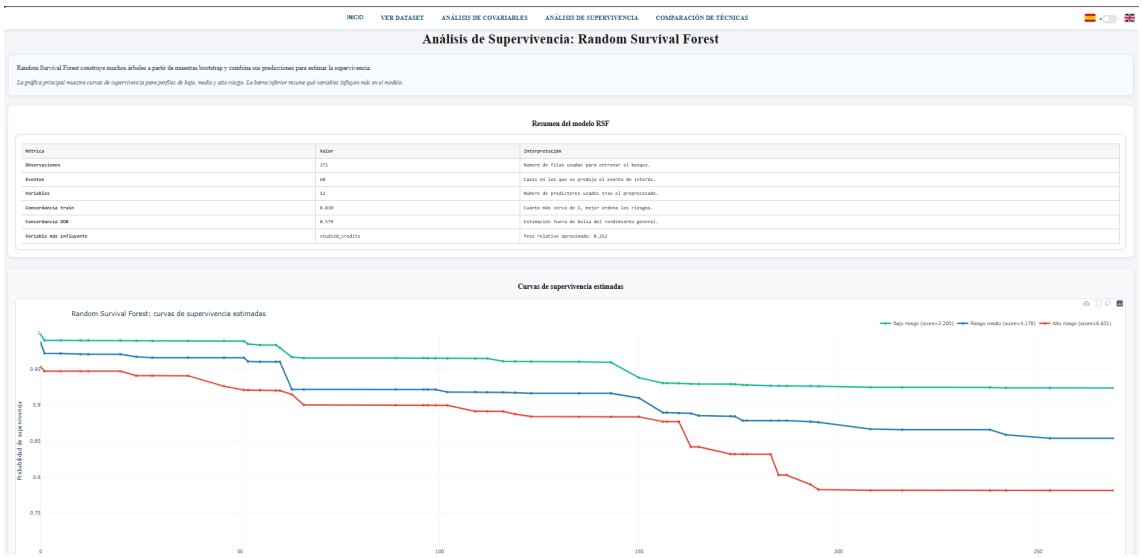

Figura 37: Vista inicial del análisis mediante Random Survival Forest

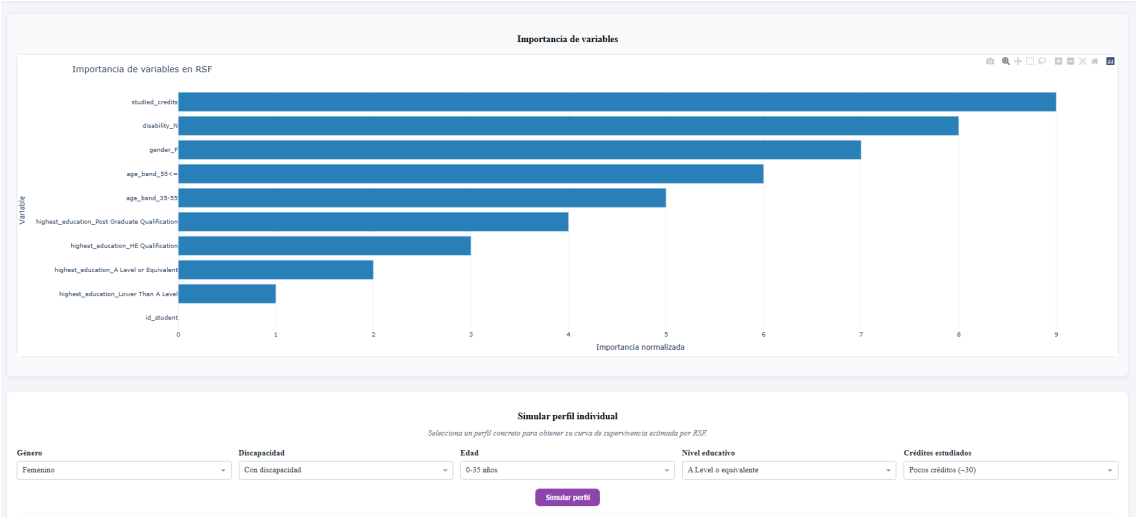

Figura 38: Resultados generales generados por Random Survival Forest

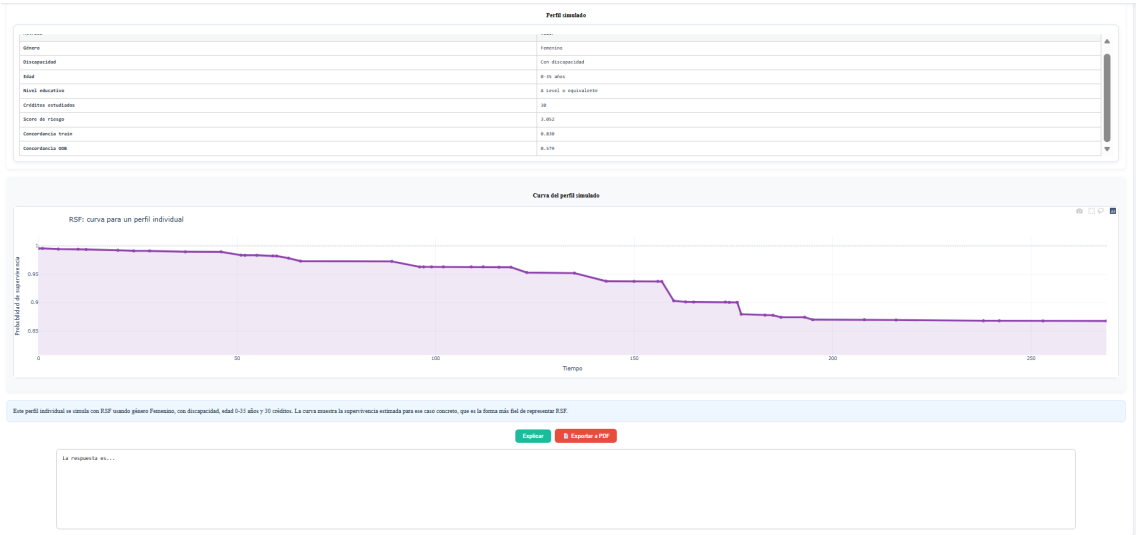

Figura 39: Visualización complementaria del análisis Random Survival Forest

Comparación de técnicas

La página de comparación de técnicas aparece al acceder a la sección de análisis de supervivencia. A diferencia de las vistas anteriores, no se trata de un modelo ejecutable, sino de una página estática pensada para orientar al usuario. En ella se resume, de forma sencilla, qué hace cada método, qué tipo de información aporta y en qué situaciones puede resultar más útil. La idea es que el usuario no tenga que elegir una técnica a ciegas, sino que cuente con una pequeña guía dentro de la propia aplicación.

Técnica	Tipo de modelo	Hipótesis	Ventajas	Limitaciones	Cuándo usarlo
Kaplan-Meier	No paramétrico	Censura no informativa; estima supervivencia empírica sin forma funcional.	Muy interpretable; útil como línea base visual.	No ajusta covariables simultáneamente.	Comparación descriptiva inicial entre grupos.
Exponencial	Paramétrico	Riesgo constante en el tiempo (hazard constante).	Simple, estable y fácil de interpretar.	Puede infraajustar si el riesgo cambia con el tiempo.	Cuando se espera comportamiento aproximadamente constante del riesgo.
Weibull	Paramétrico	Riesgo monótono (creciente o decreciente) según parámetro de forma.	Flexible y con parámetros interpretables.	Si el riesgo no es monótono puede no capturar bien el patrón.	Cuando se requiere modelo paramétrico más flexible que Exponencial.
Regresión de Cox	Semiparamétrico	Proporcionalidad de riesgos entre grupos/covariables.	Ajusta múltiples covariables sin asumir forma base del hazard.	Sensibilidad a violaciones de proporcionalidad.	Para cuantificar efecto de covariables (hazard ratios).
Log-Rank Test	Test no paramétrico	Compara igualdad global de curvas de supervivencia entre grupos.	Simple para contraste de hipótesis entre grupos.	No estima tamaño de efecto multivariable por sí solo.	Para evaluar si las curvas difieren de forma estadísticamente significativa.
Random Survival Forest	Ensamble ML	No requiere proporcionalidad ni forma paramétrica explícita.	Captura relaciones no lineales e interacciones complejas.	Menor interpretabilidad que Cox/KM.	Cuando prima capacidad predictiva y complejidad de patrones.

Figura 40: Página de comparación de técnicas de supervivencia

Figura 41: Detalle explicativo de la comparación de técnicas

Botones

La interfaz incluye distintos botones de acción que guían al usuario durante el uso de la aplicación. Algunos permiten cambiar entre vistas del dataset, otros activan funcionalidades de apoyo como la interpretación mediante inteligencia artificial, y otros se encargan de la exportación de resultados. Aunque son elementos pequeños dentro de la pantalla, la verdad es que tienen bastante peso en la experiencia de uso, porque marcan los pasos principales del flujo de trabajo.

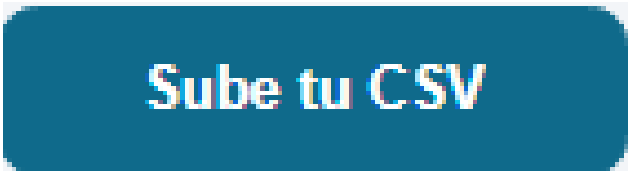

Figura 42: Botón para consultar el dataset bruto

Figura 43: Botón para consultar el dataset limpio

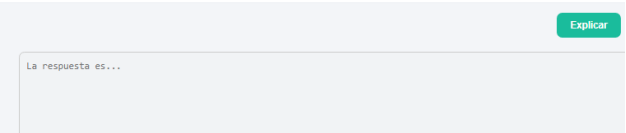

Figura 44: Botón para solicitar una interpretación mediante inteligencia artificial

Figura 45: Botón de exportación de resultados

Al pulsar el botón de exportación se abre una ventana modal en la que el usuario puede seleccionar la opción de generar informe. Una vez confirmada la acción, el sistema prepara el documento y se descarga el PDF correspondiente.

Figura 46: Botón de confirmación para generar y descargar el informe PDF

En los modelos Weibull y Exponencial se incluye además un botón de exportación combinada, ya que ambos representan una relación de caso general y caso particular dentro de los modelos paramétricos. Por su parte, Random Survival Forest incorpora un botón específico para simular perfiles, lo que permite explorar el comportamiento del modelo ante distintas combinaciones de variables.

Figura 47: Botón de exportación combinada para Weibull y Exponencial

Figura 48: Botón de simulación de perfiles en Random Survival Forest

9.3. Diagrama de clases y componentes

Al tratarse de una aplicación desarrollada principalmente con Dash, funciones de Python y callbacks, el sistema no sigue una estructura clásica basada únicamente en clases. Por ese motivo, en este apartado se plantea una vista mixta de clases y componentes, donde se representan tanto la clase principal de exportación como los módulos funcionales que sostienen el comportamiento del dashboard. Esta visión resulta más fiel al proyecto que forzar un diagrama de clases tradicional con entidades que realmente no existen en el código.

El componente central es la aplicación Dash, que actúa como núcleo de ejecución y como punto de conexión entre la interfaz, la navegación y los callbacks. A partir de ella se coordinan los componentes visuales y las respuestas del sistema ante las acciones del usuario. Por ejemplo, cuando se selecciona una técnica de análisis, el sistema recupera el dataset preparado, ejecuta el modelo correspondiente y devuelve a la interfaz los resultados que deben mostrarse.

En cuanto a clases propiamente dichas, destaca la clase responsable de construir los informes PDF. Esta clase concentra la creación del documento final, añadiendo secciones, tablas, gráficas e interpretaciones. Su existencia tiene sentido porque la generación de informes requiere mantener una estructura interna y reutilizar operaciones comunes en distintos tipos de salida. Los detalles concretos de esta clase y de los archivos implicados se describen en el capítulo de implementación.

Elemento de diseño	Descripción
`Dash App`	Núcleo de la aplicación web. Gestiona la ejecución del servidor local y la navegación entre páginas.
`Layouts`	Componentes visuales creados en `layout.py`. Definen qué ve el usuario en cada pantalla.
`Callbacks de análisis`	Funciones que responden a eventos de la interfaz y conectan la entrada del usuario con los modelos estadísticos.
`Módulos de modelos`	Funciones específicas para Kaplan-Meier, Cox, Test de Log-Rank, Exponencial, Weibull y Random Survival Forest.
`Módulo IA`	Componente encargado de enviar información del análisis al modelo local y recuperar una explicación textual.
`SurvivalAnalysisPDF Exporter`	Clase responsable de generar informes PDF reutilizando tablas, gráficos e interpretaciones.
`Traducciones`	Diccionario de textos que permite adaptar la interfaz al idioma seleccionado.

Tabla 14: Vista de diseño basada en clases y componentes del sistema

9.4. Diagramas de secuencia

Los diagramas de secuencia muestran cómo colaboran los principales componentes del sistema cuando el usuario ejecuta cada una de las funcionalidades definidas en los casos de uso. A diferencia de los diagramas de actividad, que se centran en el flujo de acciones, estos diagramas ayudan a entender qué partes internas intervienen en cada proceso: la interfaz, los callbacks, el dataset, los modelos de análisis, la generación de visualizaciones, la inteligencia artificial o la exportación de informes.

En los diagramas de secuencia se utiliza una nomenclatura descriptiva para facilitar la lectura de las interacciones. Por este motivo, algunos participantes aparecen con nombres funcionales, como “Interfaz Dash”, “Callbacks de análisis” o “Estado del dataset”, en lugar de emplear exactamente los nombres técnicos utilizados en la vista de clases y componentes. Estos participantes no deben interpretarse siempre como clases Python estrictas, sino como componentes o responsabilidades del sistema. No obstante, se corresponden con los elementos descritos anteriormente: la interfaz se relaciona con `DashApp` y `layout.py`, los callbacks con `AnalysisCallbacks`, el estado del dataset con el componente `Dataset`, y los módulos de análisis con sus correspondientes modelos.

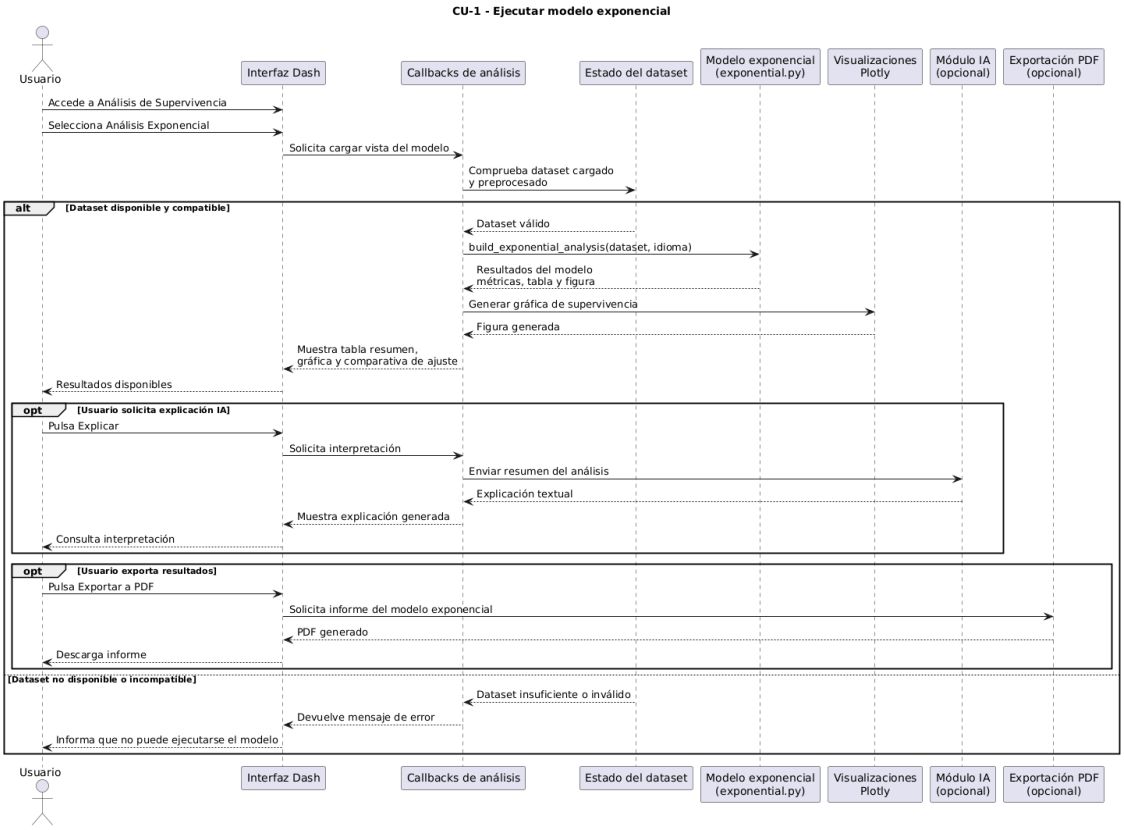

Figura 49: Diagrama de secuencia del CU-1: EjecutarModeloExponencial

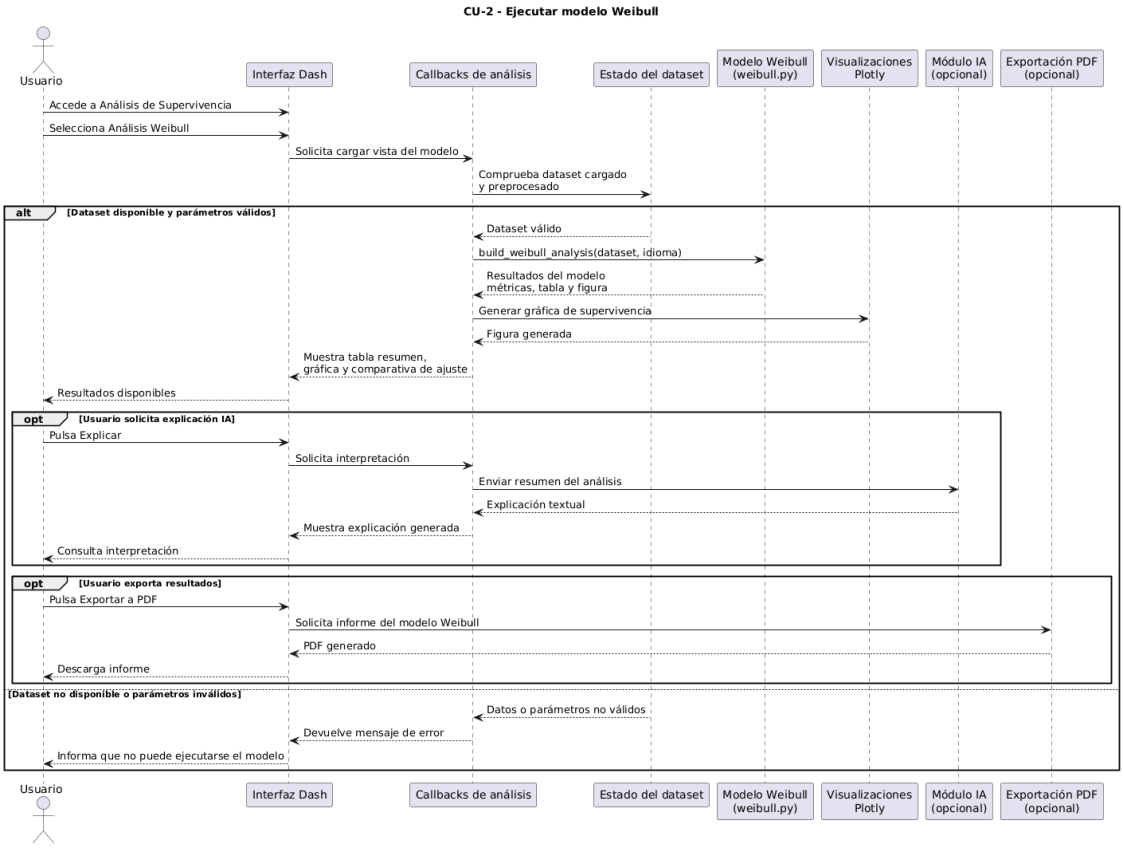

Figura 50: Diagrama de secuencia del CU-2: EjecutarModeloWeibull

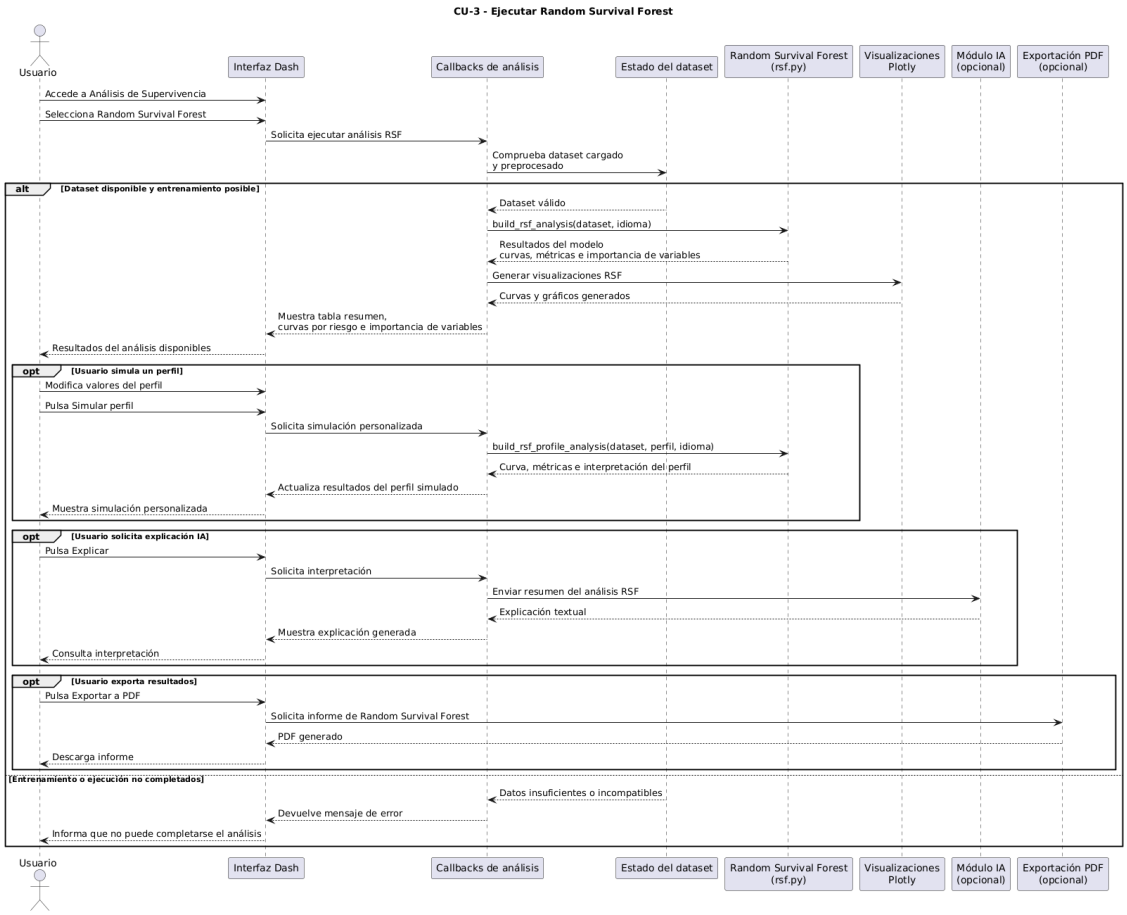

Figura 51: Diagrama de secuencia del CU-3: EjecutarRandomSurvivalForest

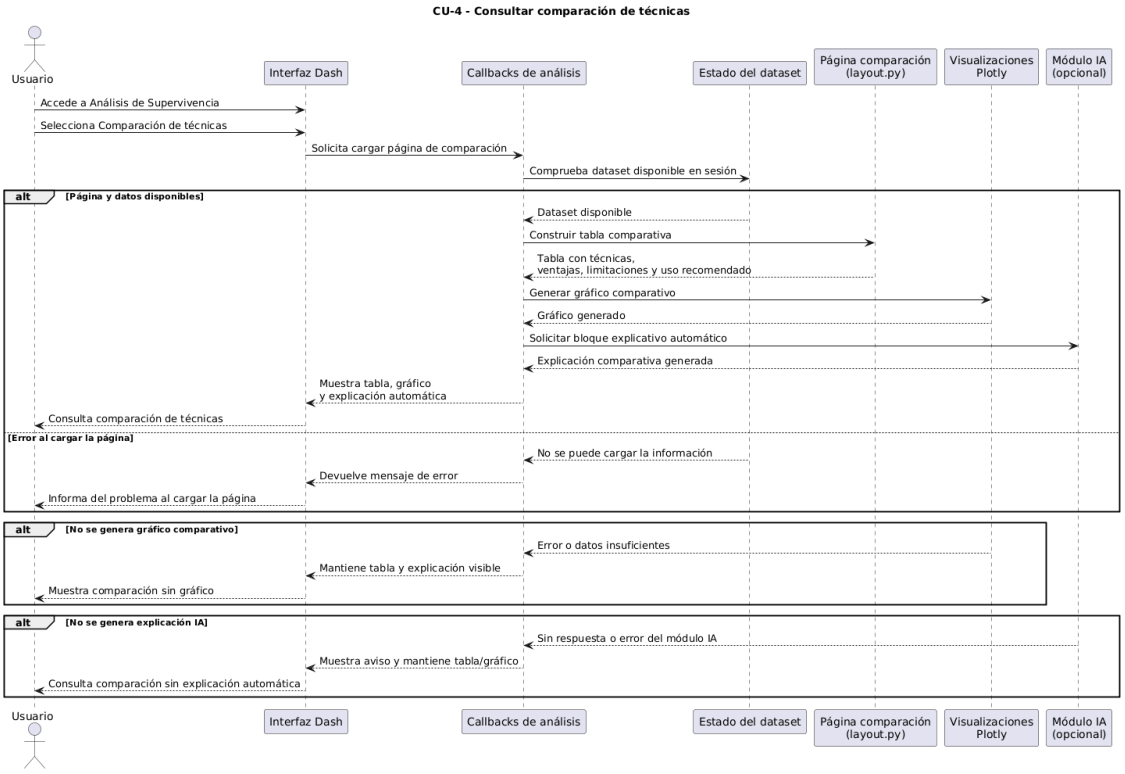

Figura 52: Diagrama de secuencia del CU-4: ConsultarComparacionDeTecnicas

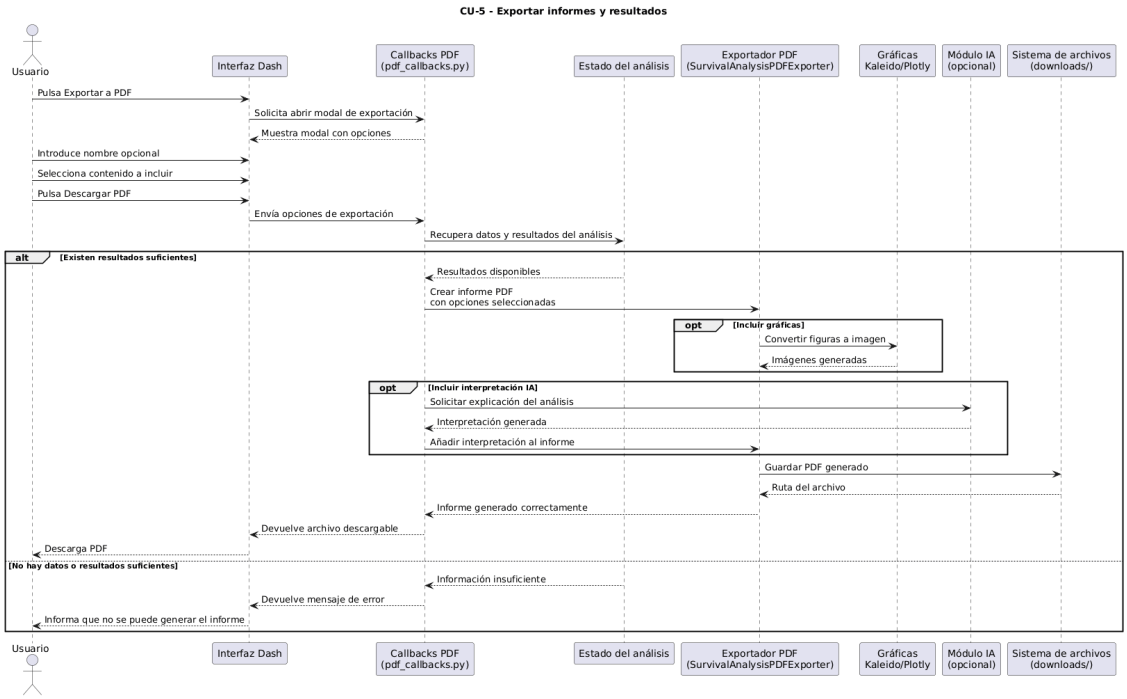

Figura 53: Diagrama de secuencia del CU-5: ExportarInformesYResultados

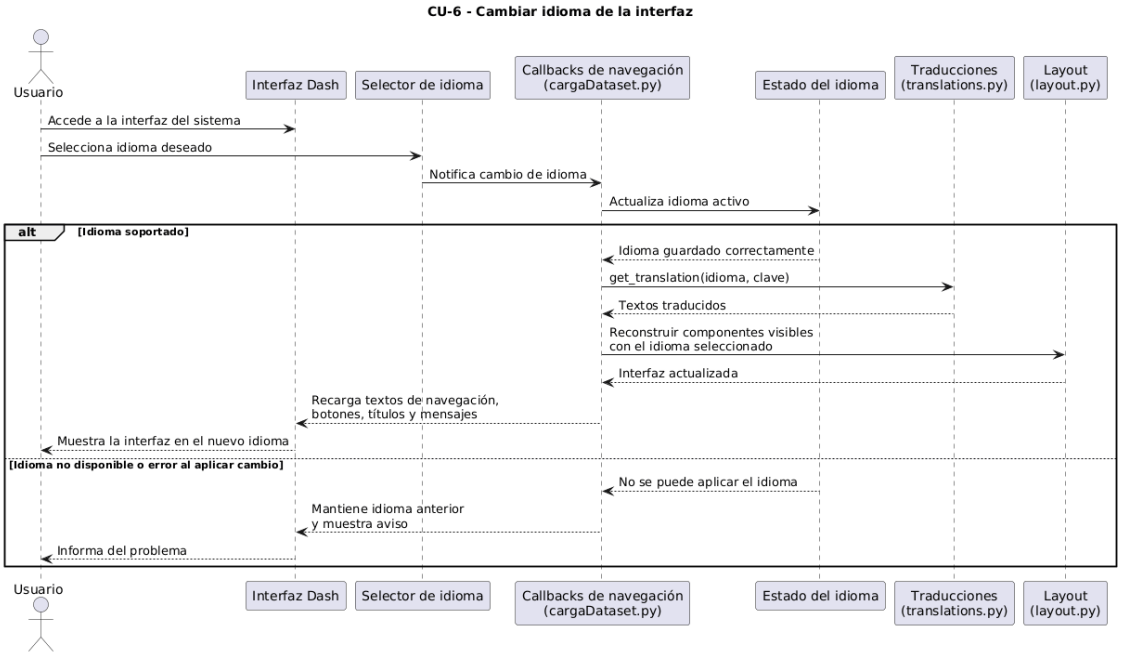

Figura 54: Diagrama de secuencia del CU-6: CambiarIdiomaInterfaz

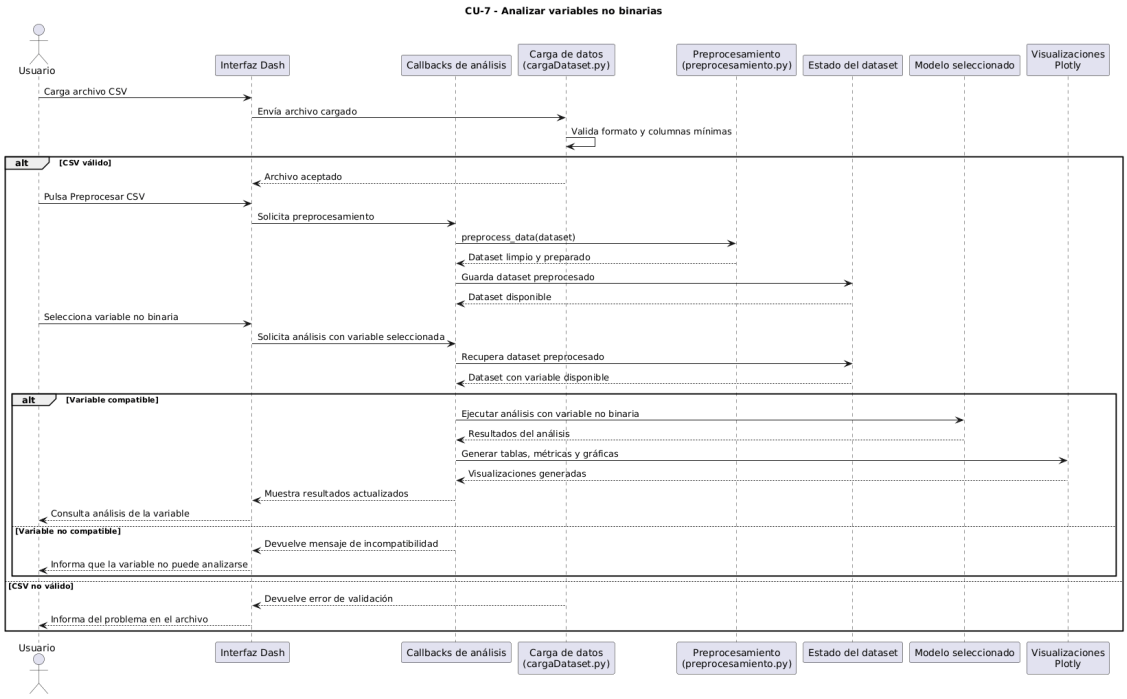

Figura 55: Diagrama de secuencia del CU-7: AnalizarVariablesNoBinarias

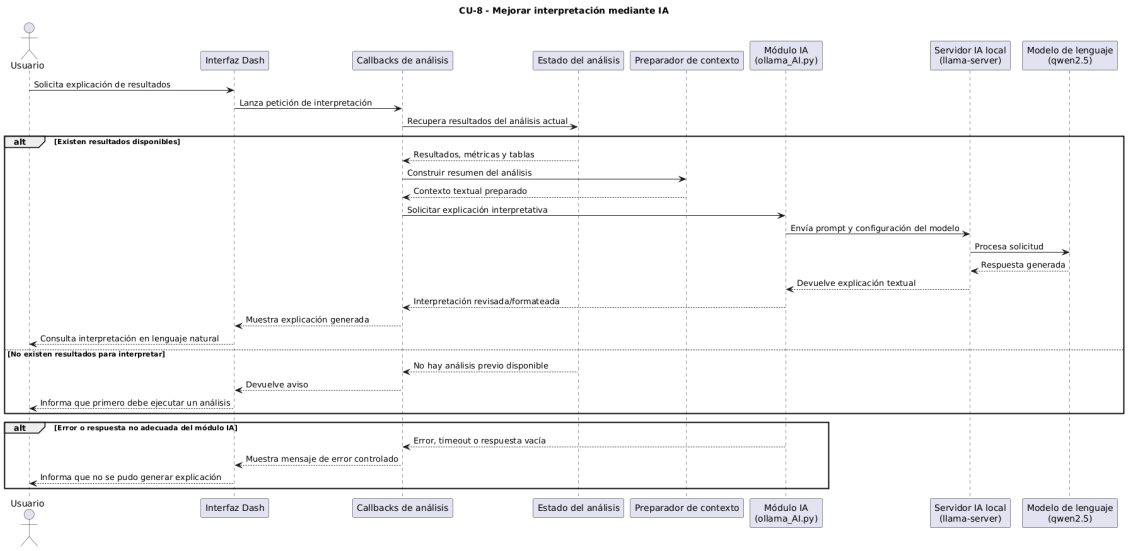

Figura 56: Diagrama de secuencia del CU-8: MejorarInterpretacionIA

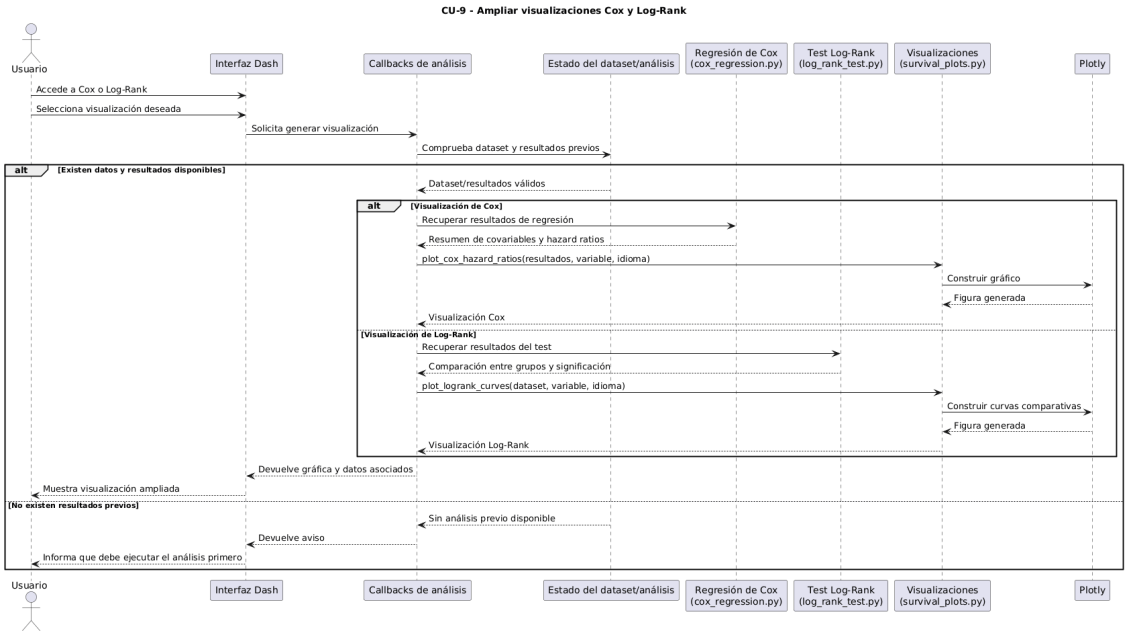

Figura 57: Diagrama de secuencia del CU-9: AmpliarVisualizacionesCoxTestLogRank

10 Implementación

Tras completar las fases de análisis y diseño, se aborda la implementación de la ampliación del dashboard. En este capítulo no se pretende repetir la arquitectura descrita anteriormente, sino explicar cómo se ha materializado en el código fuente: qué librerías se han utilizado, qué archivos concentran cada responsabilidad y cómo se han integrado los nuevos modelos, las visualizaciones, la interpretación mediante inteligencia artificial, la exportación de informes y el soporte multilingüe.

10.1. Tecnologías y librerías utilizadas

La aplicación se ha desarrollado en Python, partiendo de la base tecnológica del proyecto original. Por ese motivo, algunas librerías no se presentan como una aportación nueva, sino como parte del entorno heredado sobre el que se ha construido la ampliación. Es el caso de `Dash`, `Pandas`, `NumPy`, `Plotly`, `lifelines`, `Matplotlib` y la comunicación con un modelo local de inteligencia artificial. Todas ellas siguen siendo necesarias para que el sistema funcione, pero en este capítulo interesa distinguir entre la base ya existente y los elementos que se han reforzado o incorporado para cubrir los nuevos objetivos.

La verdad es que esta separación resulta importante, porque evita presentar como nuevo aquello que ya formaba parte del trabajo previo y permite centrar la explicación en la ampliación realizada. En concreto, se ha prestado especial atención a las librerías y componentes que hacen posible los nuevos modelos paramétricos, Random Survival Forest, las visualizaciones añadidas, la generación de informes PDF y la interpretación automática de resultados.

Tecnología o librería	Papel dentro de la ampliación
`lifelines`	Se mantiene como librería estadística principal, pero se amplía su uso mediante `ExponentialFitter` y `WeibullFitter`, necesarios para implementar los modelos Exponencial y Weibull y compararlos con Kaplan-Meier [1].
`scikit-survival`	Se incorpora para implementar Random Survival Forest, construir el objeto de supervivencia requerido por el modelo y calcular métricas como el índice de concordancia [6].
`Plotly`	Ya formaba parte de la base del dashboard, pero en esta ampliación se utiliza para generar nuevas curvas de supervivencia, comparaciones entre modelos, gráficos de importancia de variables y visualizaciones asociadas a Cox y al Test de Log-Rank.
`ReportLab` y `Kaleido`	Se utilizan para construir informes PDF con tablas, textos, cabeceras e imágenes, y para convertir las gráficas interactivas de Plotly en figuras insertables en el documento final.
`requests`	Permite mantener la comunicación con el servidor local de inteligencia artificial, enviando los resultados estadísticos y recibiendo interpretaciones textuales para la interfaz o los informes.

Tabla 15: Tecnologías con mayor peso en la ampliación implementada

El resto de librerías, como `Dash`, `Pandas` o `NumPy`, se mantienen como soporte fundamental de la aplicación: permiten construir la interfaz, almacenar estados, transformar datos y preparar las entradas que necesitan los modelos. Sin embargo, su explicación se mantiene más breve porque pertenecen principalmente a la infraestructura ya existente. La ampliación se apoya en ellas, pero aporta valor sobre todo en la nueva lógica estadística, las nuevas salidas visuales, la exportación de resultados y la interpretación asistida.

10.2. Estructura del código fuente

El código se organiza en distintos archivos Python, cada uno centrado en una responsabilidad principal. Esta organización evita concentrar toda la lógica en un único fichero y permite que los nuevos modelos añadidos en este TFG se integren sin modificar de forma agresiva el funcionamiento ya existente.

Los nombres de archivo que aparecen en este apartado se incluyen únicamente como referencia textual para facilitar su localización dentro del proyecto. No se han configurado como enlaces clicables, ya que la memoria debe poder leerse correctamente aunque el

tribunal no disponga de la misma estructura de carpetas local. Todos los archivos Python mencionados se encuentran en la raíz del repositorio de la aplicación, mientras que los recursos propios de la memoria, como imágenes, capítulos y referencias bibliográficas, se ubican dentro de la carpeta `doc/memoria_tfg`.

Archivo	**Responsabilidad principal**
`cargaDataset.py`	Inicialización de la aplicación Dash, navegación general entre páginas, cambio de idioma y registro de callbacks principales.
`layout.py`	Definición de las páginas de la interfaz, incluyendo las vistas de análisis, comparación de técnicas, visualización del dataset, modales de exportación y componentes visuales.
`analysis_callbacks.py`	Registro de callbacks asociados al análisis de datos, actualización de vistas, ejecución de modelos, interpretación de resultados y conexión entre interfaz y lógica interna.
`preprocesamiento.py`	Carga del dataset, limpieza de columnas, validación de datos críticos, selección de filas por estudiante y generación del dataset preparado para los modelos.
`exponential.py`, `weibull.py` y `rsf.py`	Implementación de las nuevas técnicas incorporadas: modelo exponencial, modelo de Weibull y Random Survival Forest.
`kaplan_meier.py`, `cox_regression.py`, `log_rank_test.py` y `survival_plots.py`	Implementación y ampliación de técnicas ya presentes en el sistema base, incluyendo nuevas visualizaciones para Cox y Test de Log-Rank.
`ollama_AI.py`	Generación de interpretaciones mediante un modelo de inteligencia artificial ejecutado en entorno local.
`pdf_callbacks.py` y `pdf_exporter.py`	Gestión de la exportación desde la interfaz y construcción de informes PDF con resultados, gráficas e interpretaciones.
`translations.py`	Diccionario de traducciones y función de acceso a los textos en castellano e inglés.
`config.py`	Definición de rutas de datos, configuración del servidor de inteligencia artificial y carga diferida de datasets.

Tabla 16: Distribución de responsabilidades en el código fuente

10.3. Carga y preprocesamiento de datos

La carga inicial del dataset se realiza mediante la función `load_dataset`, definida en `preprocesamiento.py`. Esta función lee el archivo en formato CSV con separador de punto y coma y elimina espacios sobrantes en los nombres de las columnas. Aunque es una operación sencilla, resulta importante porque evita errores posteriores derivados de nombres de columnas mal formados.

El procesamiento principal se concentra en `preprocess_data`. Esta función valida que el dataset no esté vacío y comprueba la existencia de columnas críticas como `id_student`, `date` y `final_result`. A partir de ahí, transforma `final_result` en una variable binaria, donde el abandono se representa como evento observado. Esta conversión es esencial, ya que los modelos de supervivencia necesitan una variable temporal y una variable indicadora del evento.

Una parte relevante del preprocesamiento consiste en seleccionar una única fila representativa por estudiante. Para ello, el sistema ordena los registros por identificador y fecha, y aplica una lógica distinta según el estudiante haya abandonado o no. Si no ha abandonado, se intenta conservar la observación final del periodo de estudio. Si ha abandonado, se priorizan filas con actividad registrada y, en caso contrario, se selecciona una fila representativa del inicio o del registro disponible. Esta decisión reduce duplicidades y deja un dataset más estable para los análisis posteriores.

Además, el preprocesamiento conserva tanto variables binarias como variables no binarias incorporadas en la ampliación. Entre ellas se encuentran `gender_F`, `disability_N`, los rangos de edad definidos mediante `age_band_*`, las categorías de nivel educativo previo recogidas en `highest_education_*` y la variable numérica `studied_credits`. Esta última resulta especialmente relevante porque no se trata de una variable binaria: según la técnica utilizada, el sistema puede agruparla en intervalos o cuantiles para compararla dentro de Kaplan-Meier, Cox o el Test de Log-Rank. También se eliminan columnas no necesarias y se registran advertencias cuando faltan columnas esperadas o aparecen valores nulos en campos críticos. De esta forma, el sistema no solo limpia los datos, sino que también ofrece cierto control sobre la calidad del dataset que se usará en los modelos.

10.4. Implementación de los modelos

10.4.1. Modelo exponencial

El modelo exponencial se implementa en `exponential.py` mediante la función `build_exponential_analysis`. Esta función recibe el dataset limpio, comprueba que existan las columnas `date` y `final_result`, convierte sus valores a formato numérico y

elimina registros incompletos. Si los datos no son suficientes, la función devuelve `None`, evitando que la interfaz muestre resultados inconsistentes.

Para el ajuste se utiliza `ExponentialFitter` de la librería `lifelines`. Además, se ajustan también Kaplan-Meier y Weibull para poder comparar el modelo exponencial con una estimación empírica y con su generalización paramétrica. La función calcula métricas como el valor de λ, el log-likelihood y el AIC, y devuelve tanto la gráfica de supervivencia como una tabla resumen con interpretaciones breves.

Una decisión importante de esta implementación es presentar el modelo exponencial como caso particular de Weibull cuando el parámetro de forma es igual a 1. Por eso, la función incluye una comparación directa entre ambos modelos mediante AIC. Esto no solo aporta una salida estadística, sino que ayuda al usuario a entender si la hipótesis de riesgo constante resulta razonable para los datos analizados.

10.4.2. Modelo de Weibull

El modelo de Weibull se implementa en `weibull.py` a través de `build_weibull_analysis`. Su flujo de validación es similar al del modelo exponencial: se comprueba que el dataset tenga las columnas mínimas, se convierten los valores temporales y de evento, y se descartan registros incompletos antes de ajustar el modelo.

La implementación utiliza `WeibullFitter` para obtener los parámetros de forma y escala. El parámetro de forma permite interpretar el comportamiento del riesgo a lo largo del tiempo: si es mayor que 1, el riesgo aumenta; si es menor que 1, disminuye; y si se aproxima a 1, el comportamiento se parece al modelo exponencial. Esta interpretación se incorpora directamente a la tabla de resultados, junto con métricas como la mediana de supervivencia, el log-likelihood y el AIC.

La gráfica generada compara tres curvas: Kaplan-Meier empírico, Weibull ajustado y Exponencial ajustado. Esta comparación visual permite observar si el modelo paramétrico se adapta de forma razonable al comportamiento real de los datos. Además, al igual que en el modelo exponencial, se genera una tabla comparativa entre Weibull y Exponencial para facilitar la lectura conjunta de ambos modelos.

```python
def build_weibull_analysis(df, language='es'):
    """Fit a Weibull model and build the figure and summary table."""
    if df is None or df.empty:
        return None

    required_columns = ["date", "final_result"]
    missing_columns = [column for column in required_columns if column not in df.columns]
    if missing_columns:
        return None

    working_df = df[required_columns].copy()
    working_df["date"] = pd.to_numeric(working_df["date"], errors="coerce")
    working_df["final_result"] = pd.to_numeric(working_df["final_result"], errors="coerce")
    working_df = working_df.dropna(subset=["date", "final_result"])

    if working_df.empty:
        return None

    durations = working_df["date"].astype(float).where(working_df["date"] > 0, 1e-6)
    events = working_df["final_result"].astype(int)

    if durations.nunique() < 2:
        return None

    wbf = WeibullFitter()
    wbf.fit(durations, event_observed=events, label="Weibull")

    expf = ExponentialFitter()
    expf.fit(durations, event_observed=events, label="Exponential")

    kmf = KaplanMeierFitter()
    kmf.fit(durations, event_observed=events, label="Kaplan-Meier")

    max_time = float(durations.max())
    time_grid = np.linspace(0, max_time, 200)
    fitted_survival = wbf.survival_function_at_times(time_grid).values

    fitted_times = [float(value) for value in time_grid.tolist()]
    fitted_values = [float(value) for value in fitted_survival.tolist()]

    exponential_survival = expf.survival_function_at_times(time_grid).values
    exponential_values = [float(value) for value in exponential_survival.tolist()]

    is_en = language == 'en'
```

Figura 58: Fragmento de la implementación del modelo de Weibull, donde se ajustan los modelos paramétricos y se obtienen métricas de comparación

10.4.3. Random Survival Forest

Random Survival Forest se implementa en `rsf.py`. A diferencia de los modelos paramétricos, este modelo necesita construir una matriz de características a partir de las variables disponibles en el dataset. Para ello, la función interna `_build_feature_matrix` elimina las columnas temporales y de evento, conserva variables numéricas, booleanas y categóricas, y aplica codificación mediante `get_dummies`. Así se obtiene una matriz

preparada para ser procesada por `scikit-survival`.

La función `_fit_rsf_model` crea el objeto de supervivencia mediante `Surv.from_arrays`, ajusta un `RandomSurvivalForest` con 200 árboles y calcula puntuaciones de riesgo para los estudiantes. También obtiene el índice de concordancia sobre entrenamiento y, cuando está disponible, la puntuación *out-of-bag*. Estas métricas permiten valorar de forma general la capacidad predictiva del modelo.

La función principal `build_rsf_analysis` devuelve varias salidas reutilizables por el dashboard: curvas de supervivencia para perfiles representativos, tabla de métricas, importancia de variables y gráficos asociados. Como algunas implementaciones de Random Survival Forest no siempre proporcionan importancias directas de variables, el código incorpora un cálculo alternativo basado en la correlación entre cada característica y las puntuaciones de riesgo. La verdad es que este detalle es importante, porque evita que la vista quede incompleta cuando la librería no ofrece esa información de forma directa.

Además, se incluye `build_rsf_profile_analysis`, que permite simular perfiles de estudiantes. A partir de valores por defecto obtenidos del dataset y de las selecciones realizadas por el usuario, se construye una fila de características compatible con el modelo entrenado. Con ella se estima una curva de supervivencia personalizada, lo que añade una capa interpretativa más cercana al uso práctico del sistema.

```python
def _fit_rsf_model(df: pd.DataFrame):
    feature_df, durations, events = _build_feature_matrix(df)
    if feature_df.empty or durations.nunique() < 2:
        return None

    if len(feature_df) < 5 or feature_df.shape[1] < 1:
        return None

    y = Surv.from_arrays(event=events.astype(bool).to_numpy(), time=durations.to_numpy(dtype=float))

    rsf = RandomSurvivalForest(
        n_estimators=200,
        min_samples_split=10,
        min_samples_leaf=5,
        max_features="sqrt",
        n_jobs=-1,
        random_state=42,
        oob_score=True,
    )
    rsf.fit(feature_df, y)

    risk_scores = rsf.predict(feature_df)
    train_c_index = concordance_index_censored(events.astype(bool).to_numpy(), durations.to_numpy(dtype=float), risk_scores)[0]
    oob_score = getattr(rsf, "oob_score_", None)

    return {
        "model": rsf,
        "feature_df": feature_df,
        "durations": durations,
        "events": events,
        "risk_scores": risk_scores,
        "train_c_index": float(train_c_index),
        "oob_score": None if oob_score is None else float(oob_score),
    }
```

Figura 59: Fragmento de la implementación de Random Survival Forest, incluyendo la construcción del objeto de supervivencia y el ajuste del modelo

10.4.4. Regresión de Cox y Test de Log-Rank

Aunque Cox y el Test de Log-Rank ya formaban parte del sistema base, en esta ampliación se han reforzado sus visualizaciones e integración con el resto del dashboard. La regresión de Cox se ejecuta desde `cox_regression.py`, principalmente mediante `run_cox_regression`. Esta función prepara las covariables seleccionadas, ajusta el modelo con `CoxPHFitter` y genera una tabla de resultados con coeficientes, hazard ratios y valores de significación.

El Test de Log-Rank se implementa en `log_rank_test.py`. La función `perform_log_rank_test` permite comparar curvas de supervivencia entre grupos, incluyendo estrategias específicas para variables multicategoría o variables que requieren agrupación por cuantiles. Esto encaja con uno de los objetivos de la ampliación: permitir el análisis de nuevas variables, incluidas aquellas que no son estrictamente binarias.

Las funciones de visualización asociadas se concentran en `survival_plots.py`. En concreto, `plot_logrank_curves` genera curvas comparativas entre grupos y `plot_cox_hazard_ratios` representa gráficamente los efectos estimados por el modelo de Cox. Estas gráficas se construyen con `Plotly`, lo que permite mantener el mismo estilo interactivo que el resto del dashboard.

10.5. Generación de gráficas

La generación de gráficas se ha desarrollado principalmente con `Plotly`. Esta librería se adapta bien al proyecto porque permite crear figuras interactivas que se integran directamente en componentes `dcc.Graph` de Dash. De esta manera, el usuario puede explorar curvas, valores y comparaciones sin salir de la propia aplicación.

En los modelos Exponencial y Weibull, las gráficas se construyen a partir de una rejilla temporal generada con `NumPy`. Sobre esa rejilla se calculan las probabilidades de supervivencia del modelo ajustado y se representan junto a la curva empírica de Kaplan-Meier. En Random Survival Forest, en cambio, las curvas se obtienen a partir de las funciones de supervivencia predichas por el modelo para perfiles representativos o simulados.

Además de las curvas de supervivencia, se generan visualizaciones complementarias como gráficos de importancia de variables, curvas comparativas por grupo y forest plots para la regresión de Cox. Todas estas figuras mantienen una estructura común: título, ejes, leyenda, plantilla visual clara y datos preparados para su posterior exportación a PDF.

10.6. Integración con callbacks

La conexión entre interfaz y lógica interna se realiza mediante callbacks de Dash. El archivo `cargaDataset.py` inicializa la aplicación, configura la navegación y registra los callbacks principales mediante `register_analysis_callbacks` y `register_pdf_export_callbacks`. Por su parte, `analysis_callbacks.py` concentra gran parte de las interacciones relacionadas con la carga del dataset, la ejecución de análisis y la actualización de los resultados mostrados en pantalla.

El flujo habitual es el siguiente: el usuario interactúa con un botón, filtro o selector; Dash activa el callback correspondiente; el callback recupera el dataset almacenado, llama a la función de análisis necesaria y devuelve a la interfaz tablas, gráficas, mensajes o componentes actualizados. Este patrón se repite en los distintos modelos, lo que permite que la experiencia de uso sea coherente aunque internamente cada técnica requiera un tratamiento diferente.

La interfaz se define en `layout.py` mediante funciones específicas para cada página. Entre ellas se encuentran las vistas de análisis de supervivencia, Weibull, Exponencial, Random Survival Forest, análisis de covariables y el modal de exportación a PDF. Esta separación permite construir las pantallas de forma modular y reutilizar componentes comunes, como botones, modales o tablas.

10.7. Interpretación mediante inteligencia artificial

La interpretación automática de resultados se implementa en `ollama_AI.py`. El sistema se comunica con un servidor local mediante la librería `requests`, utilizando un endpoint HTTP compatible con la estructura de la API de chat completions. La configuración del servidor y el nombre del modelo se definen en `config.py`, donde se establece `LLAMA_SERVER_URL` y `MODEL_NAME`. En la versión actual se utiliza `Qwen2.5-1.5B-Instruct` en formato `GGUF`, una variante cuantizada preparada para ejecución local [10, 11].

El modelo no se ejecuta desde un servicio externo, sino mediante `llama.cpp`, una herramienta open-source de inferencia local para modelos de lenguaje en C/C++ [12]. En concreto, se emplea el componente `llama-server.exe`, que levanta un servidor HTTP local y permite consumir el modelo a través de rutas compatibles como `/v1/chat/completions` [13]. Esta decisión permite mantener la generación de explicaciones dentro del propio equipo de trabajo, sin enviar los resultados estadísticos a un servicio remoto.

Un aspecto práctico importante es que el servidor local debe estar activo antes de solicitar una interpretación. Si `llama-server.exe` no está en ejecución o el modelo no se ha cargado correctamente, el módulo de inteligencia artificial no puede devolver una respuesta. Por ello, el código contempla este escenario para evitar que la aplicación quede bloqueada y devolver una salida controlada cuando el servicio no está disponible.

Para mejorar la calidad de las respuestas, el módulo define un prompt de sistema orientado al contexto académico del TFG. Este prompt indica al modelo que debe redactar explicaciones claras, basadas únicamente en los resultados proporcionados y sin usar listas. Además, si la salida generada parece una enumeración, el sistema intenta reescribirla como prosa académica mediante `_rewrite_to_prose_if_needed`. Este pequeño control ayuda a que las interpretaciones encajen mejor con el tono del informe.

La función `generate_interpretation_for_pdf` construye prompts específicos según el tipo de análisis: Kaplan-Meier, Cox, Test de Log-Rank, Weibull o Exponencial. Para cada caso se recopilan datos resumen y tablas de resultados, y se envían al modelo para obtener una explicación textual. De esta manera, la IA actúa como una capa de apoyo interpretativo sobre resultados ya calculados por el sistema, no como sustituto de los modelos estadísticos.

```python
def _academic_system_prompt(language='es'):
    if language == 'en':
        return (
            "You are a survival-analysis assistant for an academic thesis. "
            "Write in formal, clear, evidence-based prose using only provided results. "
            "Return 2-3 short paragraphs with no bullet points and no numbered lists."
        )
    return (
        "Eres un asistente de análisis de supervivencia para un TFG. "
        "Redacta en prosa académica clara y basada en evidencias, usando solo resultados proporcionados. "
        "Devuelve 2-3 párrafos breves, sin viñetas ni listas numeradas."
    )
```

Figura 60: Definición del prompt académico utilizado para orientar las respuestas generadas por el módulo de inteligencia artificial

```python
def _call_llm(prompt, max_tokens, temperature=DEFAULT_TEMPERATURE, timeout=REQUEST_TIMEOUT_S, language='es'):
    """Invoca llama-server con parámetros homogéneos y salida académica consistente."""
    payload = {
        "model": MODEL_NAME,
        "messages": [
            {"role": "system", "content": _academic_system_prompt(language)},
            {"role": "user", "content": prompt}
        ],
        "temperature": temperature,
        "max_tokens": max_tokens,
        "stream": False,
    }
    response = requests.post(LLAMA_SERVER_URL, json=payload, timeout=timeout)
    response.raise_for_status()
    result = response.json()
    content = result['choices'][0]['message']['content'].strip()
    return _rewrite_to_prose_if_needed(content, max_tokens=max_tokens, language=language, timeout=timeout)
```

Figura 61: Llamada al modelo local de inteligencia artificial mediante una petición HTTP y tratamiento posterior de la respuesta generada

10.8. Exportación de informes

La exportación de informes se divide en dos partes. Por un lado, `pdf_callbacks.py` gestiona la interacción con la interfaz: apertura de modales, selección de contenido, validación de interpretaciones y descarga del archivo generado. Por otro lado, `pdf_exporter.py` contiene la lógica encargada de construir el documento PDF.

El elemento central de la exportación es la clase `SurvivalAnalysisPDFExporter`. Esta clase configura los estilos del documento, añade cabeceras, textos, tablas, gráficas e interpretaciones, y genera el archivo final. Para ello utiliza `ReportLab`, que permite construir PDFs de forma programática, y `Plotly` junto con `Kaleido`, que facilita convertir las figuras en imágenes aptas para ser insertadas en el informe.

El sistema contempla una exportación general para los análisis de supervivencia y una exportación combinada para Weibull y Exponencial. Esta última tiene sentido

porque ambos modelos están relacionados: el exponencial puede entenderse como un caso particular del Weibull. Por ello, el informe combinado permite presentar sus métricas y comparaciones en un mismo documento.

Como resultado de este proceso, el sistema no genera una simple captura de pantalla, sino un informe estructurado. El documento incluye una cabecera identificativa, el tipo de análisis realizado, tablas resumen con los valores obtenidos, métricas relevantes y, cuando procede, gráficas exportadas desde Plotly mediante `Kaleido`. Además, si se ha solicitado una interpretación mediante inteligencia artificial, esta también puede incorporarse al informe para acompañar los resultados con una explicación textual más cercana.

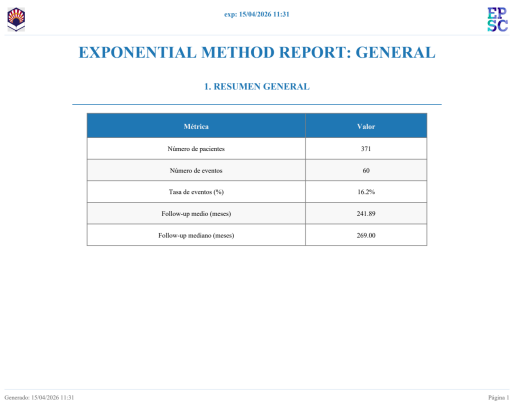

exp: 15/04/2026 11:31

EXPONENTIAL METHOD REPORT: GENERAL

1. RESUMEN GENERAL

Métrica	Valor
Número de pacientes	371
Número de eventos	60
Tasa de eventos (%)	16.2%
Follow-up medio (meses)	241.89
Follow-up mediano (meses)	269.00

Generado: 15/04/2026 11:31 Página 1

Informe del modelo exponencial

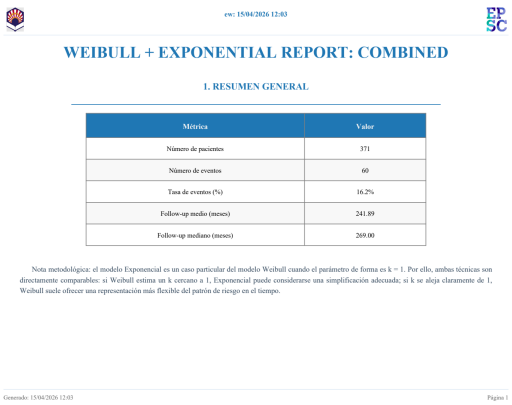

ew: 15/04/2026 12:03

WEIBULL + EXPONENTIAL REPORT: COMBINED

1. RESUMEN GENERAL

Métrica	Valor
Número de pacientes	371
Número de eventos	60
Tasa de eventos (%)	16.2%
Follow-up medio (meses)	241.89
Follow-up mediano (meses)	269.00

Nota metodológica: el modelo Exponencial es un caso particular del modelo Weibull cuando el parámetro de forma es k = 1. Por ello, ambas técnicas son directamente comparables: si Weibull estima un k cercano a 1, Exponencial puede considerarse una simplificación adecuada; si k se aleja claramente de 1, Weibull suele ofrecer una representación más flexible del patrón de riesgo en el tiempo.

Generado: 15/04/2026 12:03 Página 1

Informe combinado Weibull-Exponencial

Figura 62: Ejemplos de informes PDF generados por el sistema a partir de distintos análisis

10.9. Internacionalización del Dash

El soporte multilingüe se implementa mediante el archivo `translations.py`. Este módulo contiene un diccionario de textos en castellano e inglés y expone la función `get_translation`, que recibe el idioma actual y la clave del texto solicitado. Con este mecanismo, la interfaz puede cambiar de idioma sin duplicar la lógica de las páginas.

El idioma se gestiona desde `cargaDataset.py`, donde se actualizan los textos de navegación y se pasa el idioma activo a las funciones de layout y análisis. A su vez, los modelos y las exportaciones reciben el parámetro `language`, lo que permite adaptar títulos, etiquetas, captions, tablas e interpretaciones. Esta decisión evita que el cambio de idioma sea solo superficial y hace que afecte también a los resultados generados por el sistema.

```python
def get_translation(lang, key):
    """
    Obtiene una traducción basada en el idioma y la clave.

    ✅ ERROR #5: Manejo seguro de traducciones faltantes
    - Valida que el idioma exista
    - Retorna clave como fallback si traducción no existe
    - Loguea advertencias para debugging
    """
    # Validar idioma
    if lang not in translations:
        print(f"⚠️  [TRANSLATION] Idioma '{lang}' no soportado, usando 'es'")
        lang = 'es'

    # Obtener traducción
    translation = translations.get(lang, {}).get(key, None)

    # Si no existe, retornar la clave como fallback
    if translation is None:
        print(f"⚠️  [TRANSLATION] Clave '{key}' no encontrada para idioma '{lang}'")
        return key

    return translation
```

Figura 63: Implementación del sistema de traducciones empleado en la internacionalización del dashboard

10.10. Aspectos destacables de la implementación

Uno de los aspectos más relevantes de la implementación es que las nuevas técnicas se han añadido como módulos independientes. Exponencial, Weibull y Random Survival Forest cuentan con sus propios archivos y funciones de construcción de resultados, pero devuelven estructuras parecidas: figura, tabla resumen, métricas e interpretación. Esto facilita que los callbacks puedan integrarlas sin tener que tratar cada técnica como un caso completamente aislado.

También destaca la separación entre análisis, visualización, IA y exportación. Los modelos no generan directamente el PDF, ni la interfaz contiene la lógica estadística completa. Cada parte tiene su lugar, y eso hace que el sistema sea más mantenible. Si en el futuro se quisiera añadir otra técnica de supervivencia, el camino natural sería crear un nuevo módulo de análisis, una página en `layout.py`, los callbacks correspondientes y, si procede, una rutina de exportación.

Por último, la implementación mantiene compatibilidad con el trabajo previo, pero añade funcionalidades que amplían claramente su alcance: nuevas variables, nuevos modelos, nuevas visualizaciones, interpretación más controlada mediante IA, exportación

mejorada y soporte multilingüe. En conjunto, el código resultante no sustituye el dashboard original, sino que lo extiende de forma progresiva y coherente con los objetivos del TFG.

11 Pruebas

Una vez finalizada la implementación de la aplicación, resulta fundamental verificar que las funcionalidades desarrolladas producen los resultados esperados. El objetivo de este capítulo es comprobar, caso por caso, que el sistema responde correctamente tanto ante situaciones válidas como ante escenarios erróneos o incompletos. De esta forma, no solo se valida que la funcionalidad exista, sino también que se comporte de manera controlada cuando las condiciones de ejecución no son adecuadas.

11.1. CU-1: EjecutarModeloExponencial

Prueba válida

Caso de prueba	Ejecutar el modelo exponencial con un dataset previamente cargado, válido y preprocesado.
Objetivo de la prueba	Verificar que el sistema permite aplicar el modelo exponencial como técnica de análisis de supervivencia y que muestra los resultados generados de forma comprensible para el usuario.
Resultado esperado	El sistema carga la vista del modelo, valida la existencia del dataset, ajusta el modelo exponencial y muestra la curva de supervivencia, la tabla de métricas y la comparación con otros ajustes, dejando los resultados disponibles para su interpretación o exportación.
Resultado obtenido	El sistema ejecuta correctamente el análisis exponencial y muestra los resultados asociados, incluyendo la representación gráfica de la supervivencia y las métricas principales del modelo, como el parámetro λ, el AIC y el log-likelihood.
Problemas encontrados	No se han encontrado problemas durante la ejecución de la prueba válida.
Solución	No es necesario aplicar ninguna acción correctiva.

Tabla 17: Prueba válida del CU-1: EjecutarModeloExponencial

Figura 64: Evidencia de ejecución correcta del CU-1: EjecutarModeloExponencial

Prueba errónea

Caso de prueba	Intentar ejecutar el modelo exponencial sin disponer de un dataset cargado o con datos insuficientes para ajustar el análisis.
Objetivo de la prueba	Comprobar que el sistema no genera resultados estadísticos inválidos cuando no se cumplen las condiciones mínimas necesarias para ejecutar el modelo.
Resultado esperado	El sistema debe impedir la ejecución del análisis o devolver una salida controlada, evitando mostrar gráficas, métricas o interpretaciones que puedan inducir a error.
Resultado obtenido	El sistema no completa el análisis cuando los datos no son válidos o no contienen información suficiente, manteniendo un comportamiento controlado y evitando presentar resultados inconsistentes.
Problemas encontrados	No se han encontrado fallos críticos. El comportamiento observado es coherente con la validación implementada en el modelo.
Solución	No se requiere ninguna corrección. La acción adecuada es cargar y preprocesar un dataset válido antes de ejecutar el modelo exponencial.

Tabla 18: Prueba errónea del CU-1: EjecutarModeloExponencial

11.2. CU-2: EjecutarModeloWeibull

Prueba válida

Caso de prueba	Ejecutar el modelo de Weibull con un dataset previamente cargado, válido y preprocesado.
Objetivo de la prueba	Verificar que el sistema permite aplicar el modelo de Weibull como técnica paramétrica de análisis de supervivencia, mostrando los resultados necesarios para estudiar el comportamiento del riesgo a lo largo del tiempo.
Resultado esperado	El sistema carga la vista del modelo, comprueba que existe un dataset disponible, ajusta el modelo de Weibull y muestra la tabla resumen, la gráfica de supervivencia y la comparativa de ajuste. Además, los resultados deben quedar disponibles para su interpretación mediante IA o para su exportación a PDF.
Resultado obtenido	El sistema ejecuta correctamente el análisis de Weibull y presenta los resultados asociados al modelo, incluyendo la curva de supervivencia, los parámetros principales del ajuste y las métricas de comparación necesarias para valorar su comportamiento frente a otros modelos.
Problemas encontrados	No se han encontrado problemas durante la ejecución de la prueba válida.
Solución	No es necesario aplicar ninguna acción correctiva.

Tabla 19: Prueba válida del CU-2: EjecutarModeloWeibull

Figura 65: Evidencia de ejecución correcta del CU-2: EjecutarModeloWeibull

<u>Prueba errónea</u>

Caso de prueba	Intentar ejecutar el modelo de Weibull sin disponer de un dataset cargado, con datos insuficientes o con información no compatible con el ajuste del modelo.
Objetivo de la prueba	Comprobar que el sistema controla los errores de entrada y evita generar resultados estadísticos cuando no se cumplen las condiciones mínimas para ajustar correctamente el modelo de Weibull.
Resultado esperado	El sistema debe impedir la ejecución completa del análisis o devolver una respuesta controlada, informando de que no es posible calcular el modelo con los datos disponibles y evitando mostrar métricas o gráficas incorrectas.
Resultado obtenido	El sistema no genera resultados cuando el dataset no está disponible o no contiene información suficiente para realizar el ajuste, manteniendo un comportamiento coherente con las validaciones definidas en el flujo alternativo del caso de uso.
Problemas encontrados	No se han encontrado fallos críticos. El sistema responde de forma controlada ante la ausencia de datos válidos.
Solución	No se requiere ninguna corrección. La acción adecuada es cargar y preprocesar un dataset válido antes de ejecutar el modelo de Weibull.

Tabla 20: Prueba errónea del CU-2: EjecutarModeloWeibull

11.3. CU-3: EjecutarRandomSurvivalForest

Prueba válida

Caso de prueba	Ejecutar el modelo Random Survival Forest con un dataset previamente cargado, válido y preprocesado.
Objetivo de la prueba	Verificar que el sistema permite aplicar Random Survival Forest como técnica de aprendizaje automático para análisis de supervivencia, mostrando tanto los resultados generales del modelo como la información asociada a la simulación de perfiles.
Resultado esperado	El sistema debe cargar la vista del modelo, entrenar Random Survival Forest con los datos disponibles y mostrar la tabla resumen, las curvas de supervivencia por niveles de riesgo, la importancia de variables y el panel de simulación de perfil con valores iniciales. Además, debe permitir recalcular el perfil y dejar disponibles las acciones de explicación mediante IA y exportación a PDF.
Resultado obtenido	El sistema ejecuta correctamente el análisis con Random Survival Forest y presenta los resultados esperados, incluyendo las estimaciones de supervivencia, la información sobre variables relevantes y el bloque de simulación de perfil para explorar escenarios concretos de forma interactiva.
Problemas encontrados	No se han encontrado problemas durante la ejecución de la prueba válida.
Solución	No es necesario aplicar ninguna acción correctiva.

Tabla 21: Prueba válida del CU-3: EjecutarRandomSurvivalForest

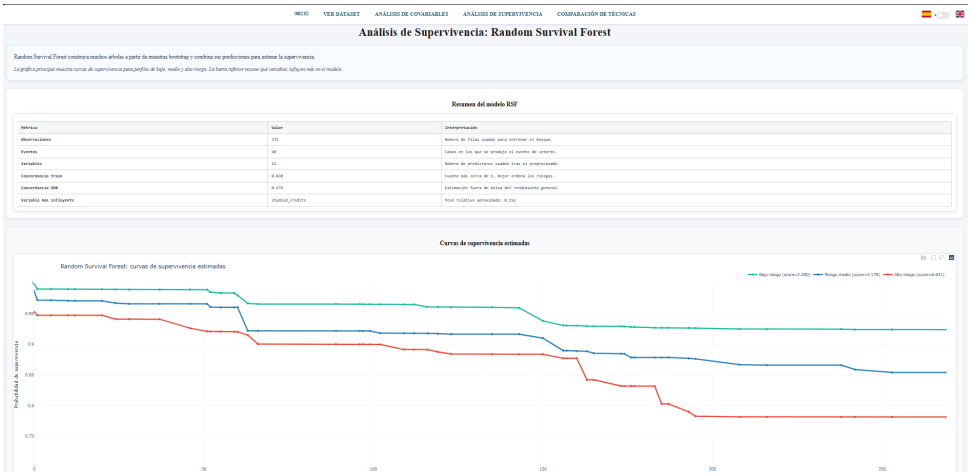

Figura 66: Evidencia de ejecución correcta del CU-3: EjecutarRandomSurvivalForest

Prueba errónea

Caso de prueba	Intentar ejecutar Random Survival Forest sin disponer de un dataset cargado, con datos insuficientes o con variables no válidas para entrenar el modelo.
Objetivo de la prueba	Comprobar que el sistema controla los errores que pueden impedir el entrenamiento o la ejecución del modelo, evitando mostrar resultados incompletos, métricas inconsistentes o simulaciones de perfil no fiables.
Resultado esperado	El sistema debe detener la ejecución del análisis o devolver una respuesta controlada cuando no sea posible entrenar Random Survival Forest con los datos disponibles, informando al usuario de la imposibilidad de completar el proceso.
Resultado obtenido	El sistema no completa el entrenamiento cuando los datos no cumplen las condiciones mínimas necesarias y mantiene un comportamiento controlado, sin presentar curvas, tablas o simulaciones que puedan interpretarse como resultados válidos.
Problemas encontrados	No se han encontrado fallos críticos. El comportamiento observado es coherente con el flujo alternativo definido para el caso de uso.
Solución	No se requiere ninguna corrección. La acción adecuada es cargar y preprocesar un dataset válido, con las variables necesarias, antes de ejecutar Random Survival Forest.

Tabla 22: Prueba errónea del CU-3: EjecutarRandomSurvivalForest

11.4. CU-4: ConsultarComparacionDeTecnicas

Prueba válida

Caso de prueba	Acceder a la página de comparación de técnicas desde la sección de Análisis de supervivencia con un dataset disponible en sesión.
Objetivo de la prueba	Verificar que el sistema permite consultar la página comparativa de técnicas y que muestra correctamente la información de apoyo para interpretar las diferencias entre los métodos implementados.
Resultado esperado	El sistema debe cargar la página de comparación, mostrar la tabla comparativa con las características principales de cada técnica, generar la visualización de puntuaciones orientativas y presentar un bloque explicativo que resuma las diferencias entre modelos y su contexto de uso recomendado.
Resultado obtenido	El sistema carga correctamente la página de comparación de técnicas y muestra la información prevista, incluyendo la tabla de métodos, la representación comparativa y el contenido explicativo asociado, facilitando al usuario una visión conjunta de los modelos disponibles.
Problemas encontrados	No se han encontrado problemas durante la ejecución de la prueba válida.
Solución	No es necesario aplicar ninguna acción correctiva.

Tabla 23: Prueba válida del CU-4: ConsultarComparacionDeTecnicas

Figura 67: Evidencia de ejecución correcta del CU-4: ConsultarComparacionDeTecnicas

Prueba errónea

Caso de prueba	Intentar acceder a la página de comparación de técnicas cuando no existe un dataset disponible en sesión o cuando alguno de los elementos comparativos no puede generarse correctamente.
Objetivo de la prueba	Comprobar que el sistema mantiene un comportamiento controlado si no puede cargar la página completa, generar la visualización comparativa o producir el bloque explicativo automático.
Resultado esperado	El sistema debe informar al usuario si la página no puede cargarse. Si el problema afecta solo a una parte concreta, debe mantener visible el resto de la información disponible, como la tabla comparativa, y omitir únicamente el elemento que no haya podido generarse.
Resultado obtenido	El sistema responde de forma controlada ante situaciones incompletas, evitando dejar la vista en un estado inconsistente y conservando la información comparativa disponible cuando no es posible generar alguno de los elementos auxiliares.
Problemas encontrados	No se han encontrado fallos críticos. El comportamiento observado es coherente con los flujos alternativos definidos para este caso de uso.
Solución	No se requiere ninguna corrección. La acción adecuada es acceder a la funcionalidad desde la sección correspondiente y disponer de los datos necesarios para completar la comparación.

Tabla 24: Prueba errónea del CU-4: ConsultarComparacionDeTecnicas

11.5. CU-5: ExportarInformesYResultados

Prueba válida

Caso de prueba	Exportar a PDF los resultados generados previamente por uno de los módulos de análisis del sistema.
Objetivo de la prueba	Verificar que el sistema permite generar un informe reutilizable a partir de los resultados, tablas, gráficas e interpretaciones disponibles en la aplicación.
Resultado esperado	El sistema debe abrir el modal de exportación al pulsar el botón correspondiente, permitir introducir opcionalmente el nombre del archivo y seleccionar el contenido que se desea incluir. Tras confirmar la operación, debe validar que existen resultados suficientes, generar el informe en formato PDF y entregar el archivo para su descarga.
Resultado obtenido	El sistema muestra correctamente la opción de exportación, permite confirmar la generación del informe y produce el archivo PDF con los bloques seleccionados, dejando los resultados disponibles para documentación o análisis posteriores.
Problemas encontrados	No se han encontrado problemas durante la ejecución de la prueba válida.
Solución	No es necesario aplicar ninguna acción correctiva.

Tabla 25: Prueba válida del CU-5: ExportarInformesYResultados

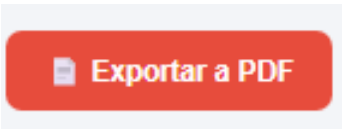

Botón de exportación

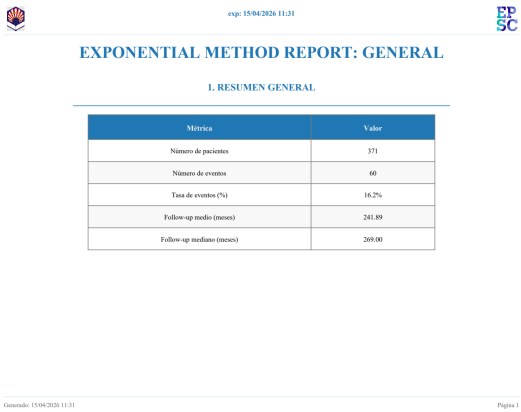

Informe PDF generado

Figura 68: Evidencia de exportación correcta del CU-5: ExportarInformesYResultados

<u>Prueba errónea</u>

Caso de prueba	Intentar generar un informe PDF sin disponer de resultados previos o cuando el sistema no puede construir el archivo solicitado.
Objetivo de la prueba	Comprobar que el sistema valida la existencia de información suficiente antes de generar el documento y que responde de forma controlada si la exportación no puede completarse.
Resultado esperado	El sistema debe impedir la generación del PDF cuando no existan datos o resultados exportables, mostrando un mensaje de error o evitando entregar un archivo incompleto.
Resultado obtenido	El sistema no genera el informe cuando no se cumplen las condiciones necesarias para la exportación y mantiene un comportamiento controlado, evitando la descarga de documentos vacíos o inconsistentes.
Problemas encontrados	No se han encontrado fallos críticos. El comportamiento observado es coherente con la validación previa a la generación del archivo.
Solución	No se requiere ninguna corrección. La acción adecuada es ejecutar previamente un análisis válido y disponer de resultados antes de utilizar la funcionalidad de exportación.

Tabla 26: Prueba errónea del CU-5: ExportarInformesYResultados

11.6. CU-6: CambiarIdiomaInterfaz

Prueba válida

Caso de prueba	Cambiar el idioma de la interfaz desde el selector disponible en la barra de navegación.
Objetivo de la prueba	Verificar que el sistema permite seleccionar otro idioma disponible y que actualiza los textos visibles de la interfaz sin alterar el funcionamiento general de la aplicación.
Resultado esperado	El sistema debe mostrar los idiomas disponibles, procesar la selección realizada por el usuario y recargar los textos visibles de la interfaz en el idioma elegido, manteniendo accesibles las mismas secciones y funcionalidades del dashboard.
Resultado obtenido	El sistema aplica correctamente el cambio de idioma y actualiza los textos de navegación, botones, títulos y mensajes principales, conservando el estado funcional de la aplicación y permitiendo continuar el uso normal del sistema.
Problemas encontrados	No se han encontrado problemas durante la ejecución de la prueba válida.
Solución	No es necesario aplicar ninguna acción correctiva.

Tabla 27: Prueba válida del CU-6: CambiarIdiomaInterfaz

Prueba errónea

Caso de prueba	Intentar aplicar un idioma no disponible o provocar una situación en la que el sistema no pueda cargar correctamente los textos traducidos.
Objetivo de la prueba	Comprobar que el sistema mantiene un comportamiento estable cuando no puede aplicar el idioma seleccionado, evitando dejar la interfaz con textos incompletos o mezclados de forma incoherente.
Resultado esperado	El sistema debe conservar el idioma anterior y, en caso necesario, mostrar un aviso al usuario indicando que no ha sido posible aplicar el cambio solicitado.
Resultado obtenido	El sistema mantiene la interfaz en un estado coherente cuando no puede aplicar una traducción, conservando el idioma previo y evitando que la navegación o las funcionalidades principales queden afectadas.
Problemas encontrados	No se han encontrado fallos críticos. El comportamiento observado es coherente con el flujo alternativo definido para este caso de uso.
Solución	No se requiere ninguna corrección. La acción adecuada es seleccionar uno de los idiomas disponibles y mantener correctamente definidas las traducciones del sistema.

Tabla 28: Prueba errónea del CU-6: CambiarIdiomaInterfaz

11.7. CU-7: AnalizarVariablesNoBinarias

Prueba válida

Caso de prueba	Cargar un dataset que contiene variables adicionales o no binarias y analizarlas desde los módulos de covariables o supervivencia.
Objetivo de la prueba	Verificar que el sistema conserva las variables no binarias soportadas durante el preprocesamiento y permite utilizarlas en los análisis correspondientes, aplicando las transformaciones necesarias según la técnica seleccionada.
Resultado esperado	El sistema debe validar la estructura del dataset, mantener las variables compatibles, permitir su selección en la interfaz y ejecutar el análisis utilizando dichas variables, mostrando tablas, métricas y gráficas actualizadas.
Resultado obtenido	El sistema permite trabajar con variables no binarias compatibles, las integra en el flujo de análisis y muestra los resultados generados de forma coherente, facilitando la interpretación del efecto de dichas variables sobre el estudio realizado.
Problemas encontrados	No se han encontrado problemas durante la ejecución de la prueba válida.
Solución	No es necesario aplicar ninguna acción correctiva.

Tabla 29: Prueba válida del CU-7: AnalizarVariablesNoBinarias

Figura 69: Evidencia de análisis de variables en el CU-7: AnalizarVariablesNoBinarias

<u>Prueba errónea</u>

Caso de prueba	Intentar analizar una variable no compatible con la técnica seleccionada o un dataset que no contiene variables adicionales válidas para el análisis.
Objetivo de la prueba	Comprobar que el sistema valida las variables seleccionadas antes de ejecutar el análisis y evita generar resultados cuando la variable no puede transformarse o utilizarse correctamente.
Resultado esperado	El sistema debe informar al usuario de que la variable no es compatible con el análisis seleccionado o impedir la ejecución del proceso, evitando mostrar tablas, métricas o gráficas basadas en datos no válidos.
Resultado obtenido	El sistema responde de forma controlada cuando una variable no es apta para el análisis, evitando resultados inconsistentes y manteniendo el flujo de trabajo en un estado estable.
Problemas encontrados	No se han encontrado fallos críticos. El comportamiento observado es coherente con la validación de variables definida en el flujo alternativo.
Solución	No se requiere ninguna corrección. La acción adecuada es seleccionar variables compatibles o cargar un dataset que contenga variables válidas para el análisis.

Tabla 30: Prueba errónea del CU-7: AnalizarVariablesNoBinarias

11.8. CU-8: MejorarInterpretacionIA

Prueba válida

Caso de prueba	Solicitar una interpretación mediante inteligencia artificial a partir de resultados generados previamente por un análisis del sistema.
Objetivo de la prueba	Verificar que el sistema recopila correctamente la información relevante del análisis, la envía al módulo de inteligencia artificial y muestra una explicación comprensible para el usuario.
Resultado esperado	El sistema debe permitir solicitar la explicación, construir el resumen de entrada con los resultados disponibles, enviarlo al módulo de IA y presentar en la interfaz una respuesta textual coherente, útil y relacionada con el análisis realizado.
Resultado obtenido	El sistema genera la interpretación solicitada y la muestra en pantalla, ofreciendo una explicación más clara de los resultados obtenidos y facilitando su lectura por parte del usuario.
Problemas encontrados	No se han encontrado problemas durante la ejecución de la prueba válida.
Solución	No es necesario aplicar ninguna acción correctiva.

Tabla 31: Prueba válida del CU-8: MejorarInterpretacionIA

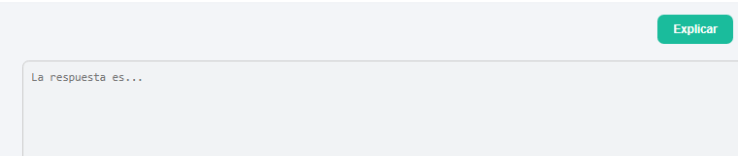

Figura 70: Evidencia de acceso a la interpretación mediante IA del CU-8: MejorarInterpretacionIA

<u>Prueba errónea</u>

Caso de prueba	Solicitar una interpretación cuando no existen resultados previos suficientes o cuando el módulo de inteligencia artificial no está disponible.
Objetivo de la prueba	Comprobar que el sistema controla los errores asociados a la generación de respuestas y evita mostrar explicaciones vacías, incompletas o no relacionadas con el análisis.
Resultado esperado	El sistema debe informar al usuario de que no ha sido posible generar una respuesta adecuada, manteniendo la interfaz estable y sin bloquear el resto de funcionalidades.
Resultado obtenido	El sistema responde de forma controlada cuando la IA no puede generar una interpretación válida, evitando presentar una explicación incorrecta y conservando el funcionamiento normal de la aplicación.
Problemas encontrados	No se han encontrado fallos críticos. El comportamiento observado es coherente con el flujo alternativo definido para este caso de uso.
Solución	No se requiere ninguna corrección. La acción adecuada es disponer de resultados válidos y comprobar que el módulo de inteligencia artificial se encuentra disponible antes de solicitar la interpretación.

Tabla 32: Prueba errónea del CU-8: MejorarInterpretacionIA

Medición de rendimiento

Además de comprobar que el módulo de inteligencia artificial genera respuestas válidas, se realizó una medición específica de rendimiento. La verdad es que esta prueba resulta importante porque la IA no debe convertirse en una espera incómoda dentro del flujo de análisis; su función es acompañar la interpretación de los resultados, no interrumpir el trabajo del usuario. Para ello, se ejecutaron cinco consultas por cada técnica de análisis disponible, utilizando el servidor local `llama-server` y el modelo `Qwen2.5-1.5B-Instruct` en formato `GGUF`. Los resultados se registraron automáticamente mediante el script `benchmark_ia.py`, quedando almacenados en el archivo `benchmarks/ia_benchmark_20260506_175802.csv`.

Elemento	Valor utilizado en la prueba
Modelo evaluado	`qwen2.5-1.5b-instruct` mediante `llama-server`.
Modelo del sistema previo	Llama 3 mediante Ollama, tomado como referencia tecnológica del TFG anterior.
Equipo de pruebas	Ordenador personal descrito en el apartado de recursos hardware: Lenovo 82KU, AMD Ryzen 7 5700U with Radeon Graphics, 8 GB de memoria RAM, Windows 11 Home de 64 bits y tarjeta gráfica AMD Radeon Graphics integrada.
Modo de ejecución	Inferencia local en CPU, con servidor HTTP en `http://127.0.0.1:8000`.
Número de consultas	30 consultas medidas en total: 5 por cada una de las 6 técnicas de análisis.

Tabla 33: Configuración utilizada para medir el rendimiento del módulo de inteligencia artificial

Técnica	N	Tiempo medio (s)	Tiempo máximo (s)	RAM máx. aprox. (MB)
Kaplan-Meier	5	3.877	5.340	1013.32
Regresión de Cox	5	8.553	12.468	1049.43
Test Log-Rank	5	4.566	4.927	1052.55
Weibull	5	6.361	8.591	1073.43
Exponencial	5	5.352	7.558	1097.62
Random Survival Forest	5	3.976	4.526	1098.16
Media global	30	**5.448**	**12.468**	**1098.16**

Tabla 34: Resultados de rendimiento del modelo de inteligencia artificial por técnica de análisis

Los resultados muestran que el modelo actual ofrece tiempos de respuesta asumibles para un uso interactivo. La media global se sitúa en 5.448 segundos, con un máximo de 12.468 segundos en una consulta asociada a la regresión de Cox, que es precisamente una de las técnicas que genera entradas más densas para la explicación. El consumo máximo aproximado de memoria se mantiene alrededor de 1.1 GB, una cifra razonable para una ejecución local en un equipo portátil con recursos limitados.

En comparación con el enfoque del sistema previo, basado en Llama 3 mediante Ollama, esta nueva configuración apuesta por un modelo más ligero y por una ejecución local controlada mediante `llama-server`. Aunque la comparación exacta con el TFG anterior depende del equipo y de la configuración concreta usada en aquel entorno, la medición realizada confirma que la solución actual responde de forma estable en todas las técnicas evaluadas y que puede integrarse en el dashboard sin romper la continuidad del análisis.

11.9. CU-9: AmpliarVisualizacionesCox TestLogRank

Prueba válida

Caso de prueba	Generar nuevas visualizaciones asociadas a los análisis de regresión de Cox y Test de Log-Rank con resultados previamente disponibles.
Objetivo de la prueba	Verificar que el sistema permite acceder a las opciones de visualización, procesar los resultados activos y mostrar en pantalla las representaciones gráficas ampliadas para facilitar la interpretación del análisis.
Resultado esperado	El sistema debe mostrar las opciones de visualización disponibles, obtener los resultados correspondientes a la configuración activa y generar la gráfica solicitada, dejándola visible para su consulta, interpretación o exportación posterior.
Resultado obtenido	El sistema genera correctamente las visualizaciones asociadas a Cox y al Test de Log-Rank, mostrando las gráficas en la interfaz y permitiendo al usuario analizar de forma más clara los resultados obtenidos.
Problemas encontrados	No se han encontrado problemas durante la ejecución de la prueba válida.
Solución	No es necesario aplicar ninguna acción correctiva.

Tabla 35: Prueba válida del CU-9: AmpliarVisualizacionesCoxTestLogRank

Figura 71: Evidencia de visualización ampliada del CU-9: AmpliarVisualizacionesCoxTestLogRank

Prueba errónea

Caso de prueba	Intentar generar una visualización de Cox o Test de Log-Rank sin haber ejecutado previamente el análisis correspondiente o sin resultados disponibles.
Objetivo de la prueba	Comprobar que el sistema valida la existencia de resultados previos antes de construir la gráfica y que informa al usuario cuando no es posible generar la visualización solicitada.
Resultado esperado	El sistema debe impedir la generación de la gráfica cuando no existan datos suficientes y mostrar un aviso indicando que es necesario ejecutar previamente el análisis de Cox o el Test de Log-Rank.
Resultado obtenido	El sistema mantiene un comportamiento controlado cuando no existen resultados previos, evitando mostrar visualizaciones vacías o incoherentes y guiando al usuario hacia la ejecución previa del análisis necesario.
Problemas encontrados	No se han encontrado fallos críticos. El comportamiento observado es coherente con el flujo alternativo definido para este caso de uso.
Solución	No se requiere ninguna corrección. La acción adecuada es ejecutar primero el análisis correspondiente y, una vez generados los resultados, solicitar la visualización deseada.

Tabla 36: Prueba errónea del CU-9: AmpliarVisualizacionesCoxTestLogRank

12 Discusión y conclusiones finales

Este último capítulo recoge una visión global del trabajo realizado. Se valora el grado de cumplimiento de los objetivos planteados inicialmente, las dificultades encontradas durante el desarrollo y las posibles líneas de mejora que podrían abordarse en el futuro. La verdad es que este cierre resulta especialmente importante en un proyecto de ampliación, porque permite distinguir con más claridad qué aportaba ya el sistema original y qué se ha incorporado para hacerlo más completo, flexible y útil.

El trabajo desarrollado ha partido de una aplicación previa orientada al análisis de supervivencia aplicado al abandono académico universitario. Sobre esa base se han añadido nuevos modelos, nuevas visualizaciones, soporte multilingüe, exportación de informes, análisis de variables no binarias y una integración más cuidada con la interpretación mediante inteligencia artificial. En conjunto, la aplicación resultante no sustituye el dashboard anterior, sino que lo amplía de forma progresiva y coherente con los objetivos definidos en el anteproyecto.

12.1. Análisis de los objetivos iniciales

El objetivo general del Trabajo de Fin de Grado consistía en ampliar y mejorar una aplicación interactiva para el análisis de supervivencia en el contexto del abandono académico. Ese objetivo puede considerarse cumplido. El sistema incorpora nuevas técnicas analíticas, mejora la interpretación de resultados y ofrece una experiencia de uso más completa. Además, las pruebas realizadas por caso de uso permiten comprobar que las funcionalidades principales responden correctamente tanto en situaciones válidas como ante escenarios erróneos o incompletos.

Una de las mejoras principales ha sido el módulo de interpretación mediante inteligencia artificial. La aplicación permite solicitar explicaciones asociadas a los resultados obtenidos y presentarlas dentro de la interfaz. Esto aporta una capa interpretativa adicional, útil para usuarios que no necesariamente dominan todos los detalles estadísticos de los modelos. Aun así, se ha mantenido un enfoque prudente: la IA se utiliza como apoyo a la interpretación, no como sustituto del análisis estadístico.

También se ha incorporado soporte multilingüe en castellano e inglés. Esta mejora afecta tanto a elementos visibles de la interfaz como a etiquetas, mensajes y resultados generados

por el sistema. Aunque pueda parecer una funcionalidad secundaria, en la práctica mejora la accesibilidad de la herramienta y facilita que pueda utilizarse en contextos académicos más amplios.

Otro objetivo relevante era ampliar el conjunto de variables utilizadas en el análisis. Para ello, se han considerado covariables personales y académicas como el género, la discapacidad, el tramo de edad, el nivel educativo previo y los créditos estudiados. La inclusión de `studied_credits` resulta especialmente significativa. No es una variable binaria, y eso obliga al sistema a aplicar estrategias de agrupación o transformación según la técnica utilizada. Con ello se amplía la capacidad explicativa del dashboard y se evita limitar el análisis a variables demasiado simples.

En cuanto a las técnicas estadísticas, se han incorporado modelos paramétricos como Exponencial y Weibull, junto con Random Survival Forest como enfoque basado en aprendizaje automático. Estas técnicas complementan a Kaplan-Meier, la regresión de Cox y el Test de Log-Rank ya presentes en la base del sistema. Gracias a esta combinación, el usuario puede comparar aproximaciones más sencillas, modelos paramétricos y métodos más flexibles, obteniendo una visión más rica del fenómeno de abandono.

Por último, se ha mejorado la exportación de resultados mediante la generación de informes PDF. Esta funcionalidad permite reutilizar tablas, métricas, gráficas e interpretaciones fuera de la aplicación, algo muy útil para documentación, revisión académica o comunicación de resultados. Las pruebas realizadas muestran que la exportación funciona de forma controlada cuando existen resultados disponibles y que el sistema evita generar informes vacíos cuando no se cumplen las condiciones necesarias.

12.2. Problemas encontrados en el desarrollo

Durante el desarrollo no todos los cambios presentaron el mismo nivel de dificultad. Algunas mejoras pudieron integrarse de forma bastante directa, mientras que otras exigieron más revisión, pruebas y ajustes. Por este motivo, no se recogen problemas para cada objetivo de manera individual, sino únicamente aquellas dificultades que tuvieron un peso real en la construcción de la aplicación.

Una de las primeras dificultades fue ampliar una aplicación ya existente sin romper su funcionamiento previo. Al tratarse de una evolución del trabajo anterior, no bastaba con añadir archivos nuevos. Cada funcionalidad debía encajar con los callbacks, las páginas de Dash, el estado del dataset y las salidas que ya estaban definidas. Esto obligó a revisar con calma la estructura del sistema y a mantener una separación razonable entre interfaz, análisis, visualización, exportación e interpretación.

La preparación de los datos también tuvo bastante peso. Las nuevas técnicas no podían aplicarse directamente sobre cualquier tabla. Antes era necesario validar columnas, transformar tipos, eliminar registros incompletos y controlar los casos en los que no había información suficiente para ajustar un modelo. Además, algunas variables estaban codificadas de forma binaria, mientras que otras aparecían como categorías múltiples o valores numéricos. En especial, `studied_credits` exigió un tratamiento distinto, ya que no podía gestionarse como una variable binaria simple.

Otra parte delicada fue la integración de librerías y modelos con requisitos diferentes. Los modelos Exponencial y Weibull se apoyan en `lifelines`, mientras que Random Survival Forest utiliza `scikit-survival`. Esta última técnica resultó más exigente. Necesita construir una matriz de características y trabajar con estructuras específicas para datos censurados. Además, no siempre se dispone de importancias de variables de forma directa, por lo que fue necesario contemplar alternativas para que la vista no quedara incompleta. En el caso de la regresión de Cox, también podían aparecer problemas de convergencia según las covariables seleccionadas, por lo que se incorporaron mecanismos de control como regularización o simplificación del conjunto de variables.

La exportación de informes PDF fue otro punto que requirió atención. No se trataba solo de descargar una imagen. El sistema tenía que generar documentos con tablas, gráficos, textos e interpretaciones, y hacerlo además de forma estable. Para ello fue necesario combinar las figuras de Plotly con herramientas como `Kaleido` y `ReportLab`, controlando tamaños, orientación de páginas y contenido seleccionado por el usuario. Además, el sistema debía comportarse bien tanto cuando existían resultados completos como cuando solo había salidas parciales.

Por último, la interpretación mediante inteligencia artificial añadió una dependencia práctica adicional. El modelo Qwen se ejecuta de forma local mediante `llama-server`, lo que evita depender de un servicio externo, pero también implica que el servidor debe estar iniciado antes de solicitar una explicación. Por ello fue necesario contemplar errores de conexión, tiempos de espera y respuestas vacías, de manera que la aplicación no quedara bloqueada si el módulo de IA no estaba disponible.

12.3. Conclusiones y posibles mejoras

Como conclusión general, el proyecto ha permitido transformar una aplicación centrada en técnicas clásicas de supervivencia en una herramienta más amplia para el estudio del abandono académico. La incorporación de modelos paramétricos, aprendizaje automático, nuevas variables, exportación de informes e interpretación mediante IA aporta más profundidad al análisis. También mejora la utilidad práctica del sistema.

Uno de los aspectos más positivos es que la ampliación mantiene una relación clara con el sistema original. No se ha planteado una reconstrucción desde cero, sino una evolución gradual. Esto resulta importante porque permite conservar las funcionalidades ya existentes y, al mismo tiempo, añadir nuevas capacidades sin perder coherencia. La aplicación sigue siendo reconocible, pero ahora ofrece más opciones para explorar los datos y comparar resultados.

También destaca la mejora en la interpretación de los resultados. Las nuevas visualizaciones, la comparación de técnicas y los informes exportables ayudan a que el análisis no se quede únicamente en cálculos internos. El usuario puede ver curvas, tablas, métricas, explicaciones y documentos finales. Eso hace que el sistema sea más útil como herramienta de apoyo académico.

Aun así, todavía existen líneas de mejora posibles. Una de ellas sería ampliar el conjunto de variables analizadas, incorporando con más profundidad información sobre actividad en la plataforma, intentos previos, módulos cursados, región o indicadores socioeconómicos. Estas variables aparecen en el conjunto de datos y podrían aportar información adicional si se estudian con cuidado.

Otra mejora interesante sería incorporar validaciones más avanzadas de los modelos. Por ejemplo, podrían añadirse métricas comparativas adicionales, validación cruzada o análisis de estabilidad de resultados. Esto permitiría valorar con más precisión qué técnica se comporta mejor según el tipo de datos y el objetivo del usuario.

También sería útil mejorar la interpretación generada por inteligencia artificial, permitiendo respuestas más contextualizadas según el modelo utilizado, las variables seleccionadas y el perfil del usuario. En una futura versión, la IA podría actuar de forma más guiada, explicando no solo qué resultado se ha obtenido, sino qué precauciones deben tenerse al interpretarlo.

Por último, se podría avanzar hacia una versión más robusta de la aplicación desde el punto de vista de despliegue. Actualmente el sistema funciona como una herramienta local, pero podría evolucionar hacia una aplicación desplegada en servidor, con gestión de usuarios, persistencia de análisis y almacenamiento de informes generados. Esto abriría la puerta a un uso más real en contextos académicos o institucionales.

En definitiva, el trabajo realizado cumple los objetivos planteados y deja una base preparada para futuras ampliaciones. El resultado es una herramienta más completa, más interpretable y más flexible para estudiar el abandono académico desde la perspectiva del análisis de supervivencia. Y es que, más allá de las técnicas concretas implementadas, la principal aportación del proyecto está en acercar modelos estadísticos complejos a una interfaz comprensible y útil para explorar un problema educativo real.

Bibliografía

[1] Cameron Davidson-Pilon. lifelines: survival analysis in Python. *Journal of Open Source Software*, 4(40):1317, 2019. doi: 10.21105/joss.01317. URL https://doi.org/10.21105/joss.01317.

[2] Christopher Jackson. flexsurv: A platform for parametric survival modeling in R. *Journal of Statistical Software*, 70(8):1–33, 2016. doi: 10.18637/jss.v070.i08. URL https://www.jstatsoft.org/article/view/v070i08.

[3] Michaelg2015. Exponential survival functions. https://commons.wikimedia.org/wiki/File:Exponential_survival_functions.svg, 2016. Imagen publicada en Wikimedia Commons bajo licencia Creative Commons Attribution-Share Alike 4.0 International. Último acceso: 5 de mayo de 2026.

[4] Calimo. Weibull probability density function. https://commons.wikimedia.org/wiki/File:Weibull_PDF.svg, 2010. Imagen publicada en Wikimedia Commons. Último acceso: 5 de mayo de 2026.

[5] Hemant Ishwaran, Udaya B. Kogalur, Eugene H. Blackstone, and Michael S. Lauer. Random survival forests. *The Annals of Applied Statistics*, 2(3):841–860, 2008. doi: 10.1214/08-AOAS169. URL https://projecteuclid.org/journals/annals-of-applied-statistics/volume-2/issue-3/Random-survival-forests/10.1214/08-AOAS169.full.

[6] Sebastian Pölsterl. scikit-survival: A library for time-to-event analysis built on top of scikit-learn. *Journal of Machine Learning Research*, 21(212):1–6, 2020. URL https://jmlr.org/papers/v21/20-729.html.

[7] scikit-survival developers. Using Random Survival Forests. https://scikit-survival.readthedocs.io/en/v0.14.0/user_guide/random-survival-forest.html, s. f. Documentación oficial de scikit-survival. Último acceso: 5 de mayo de 2026.

[8] Alfonso Muñoz Cuesta. Repositorio del Trabajo Fin de Grado. https://github.com/alfonsoMunozCuesta/TFG.git, 2026. Último acceso: 5 de mayo de 2026.

[9] Roger S. Pressman and Bruce R. Maxim. *Ingeniería del Software: Un enfoque práctico*. McGraw-Hill, 8 edition, 2015.

[10] An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, Huan Lin, Jian Yang, Jianhong

Tu, Jianwei Zhang, Jianxin Yang, Jiaxi Yang, Jingren Zhou, Junyang Lin, Kai Dang, Keming Yang, Keqin Chen, Kexin Yang, Mingfeng Xue, Na Li, Pei Zhang, Peng Wang, Rui Men, Ruize Gao, Runji Lin, Shijie Wang, Shuai Bai, Sinan Tan, Tianhang Zhu, Tianhao Li, Tianyu Liu, Wenbin Ge, Xiaodong Deng, Xiaohuan Zhou, Xingzhang Ren, Xinyu Ren, Xipin Wei, Xuancheng Ren, Yang Liu, Yang Fan, Yang Yao, Yichang Zhang, Yu Wan, Yunfei Chu, Yuqiong Liu, Zeyu Cui, Zhenru Zhang, and Zhihao Fan. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024. URL `https://arxiv.org/abs/2412.15115`.

[11] Qwen Team. Qwen2.5-1.5B-Instruct-GGUF. `https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct-GGUF`, 2024. Repositorio oficial del modelo en formato GGUF. Último acceso: 5 de mayo de 2026.

[12] ggml-org. llama.cpp: LLM inference in C/C++. `https://github.com/ggml-org/llama.cpp`, 2026. Repositorio oficial. Último acceso: 5 de mayo de 2026.

[13] ggml-org. llama.cpp server documentation. `https://github.com/ggml-org/llama.cpp/blob/master/tools/server/README.md`, 2026. Documentación oficial de llama-server. Último acceso: 5 de mayo de 2026.

ANEXO A

MANUAL DE USUARIO

A Anexo del Manual de Usuario

A.1. Introducción

Este manual recoge, paso a paso, el proceso de instalación, puesta en marcha y uso de la aplicación desarrollada para el análisis de supervivencia aplicado al abandono académico universitario. La idea es que cualquier usuario pueda arrancarla sin perderse entre archivos, comandos o pantallas intermedias.

La aplicación se ejecuta como un dashboard web local construido con Dash. Esto significa que no es necesario desplegarla en un servidor externo para utilizarla: el usuario inicia el programa en su propio equipo y accede a la interfaz desde un navegador mediante una dirección local. Desde ahí puede cargar el dataset, preprocesarlo, consultar los datos, ejecutar diferentes técnicas de análisis de supervivencia, generar interpretaciones y exportar informes en formato PDF. En la práctica, todo el flujo de trabajo queda reunido en una misma herramienta.

El módulo de inteligencia artificial es opcional. La aplicación puede funcionar sin él, manteniendo disponibles la carga de datos, los análisis estadísticos, las gráficas y la exportación de informes. Ahora bien, si se desea utilizar la generación automática de explicaciones, es necesario arrancar previamente el servidor local de IA mediante el script correspondiente.

A.2. Instalación

A.2.1. Requisitos previos

Antes de ejecutar la aplicación, conviene comprobar con calma que el equipo dispone de los siguientes elementos. Es un paso sencillo, pero evita muchos errores posteriores:

- Sistema operativo Windows. Es el entorno principal para el que se han preparado los scripts de arranque.
- Python instalado. El proyecto se ha desarrollado y probado con Python 3.13.2, por lo que se recomienda utilizar esa misma versión para reproducir el entorno con mayor seguridad.
- Gestor de paquetes `pip`, incluido normalmente con Python. En Windows, la forma más fiable de utilizarlo es mediante `python -m pip`.

- Navegador web actualizado, por ejemplo Google Chrome, Microsoft Edge o Firefox.
- Código fuente del proyecto descargado en una carpeta local.
- Conexión a Internet durante la instalación de dependencias, salvo que se disponga previamente de los paquetes descargados.

Las librerías necesarias se encuentran recogidas en el archivo `requirements.txt`. Entre las dependencias principales se incluyen:

- `dash==2.0.0` y `dash-daq==0.6.0`, utilizadas para construir la interfaz web.
- `pandas==2.2.3` y `numpy==2.2.3`, utilizadas para la carga y transformación de datos.
- `plotly==6.2.0` y `matplotlib==3.10.1`, utilizadas para la generación de gráficas.
- `lifelines==0.30.0`, utilizada para Kaplan-Meier, Cox, Weibull y Exponencial.
- `scikit-survival==0.27.0`, utilizada para Random Survival Forest.
- `reportlab==4.0.8` y `kaleido==0.2.1`, utilizadas para la exportación de informes PDF.
- `requests==2.32.3`, utilizada para la comunicación con el servidor local de inteligencia artificial.
- `Pillow==11.1.0`, utilizada como soporte para el tratamiento de imágenes.

Para utilizar el módulo de inteligencia artificial se requiere, además, disponer de `llama-server.exe` y de un modelo en formato `GGUF`. En la configuración actual se utiliza un modelo Qwen2.5 Instruct cuantizado. La verdad es que esta parte puede parecer la más delicada de la instalación, pero solo afecta a las explicaciones automáticas: el resto del dashboard puede usarse sin tener activa la IA.

A.2.2. Descarga del código

El código fuente del proyecto se obtiene desde el repositorio de GitHub correspondiente. Para ello existen dos caminos habituales: descargar el proyecto como archivo comprimido ZIP o clonar el repositorio mediante Git. La primera opción es más directa; la segunda resulta más cómoda si se quiere mantener el proyecto conectado con el repositorio.

Opción 1: descarga como archivo comprimido ZIP. La primera opción consiste en acceder al repositorio desde el navegador, pulsar sobre el botón `Code` y seleccionar la opción `Download ZIP`. Tras la descarga, se debe descomprimir el archivo en una carpeta local. Esta alternativa es la más sencilla si el usuario solo quiere ejecutar la aplicación, probar el dashboard y no necesita modificar el repositorio.

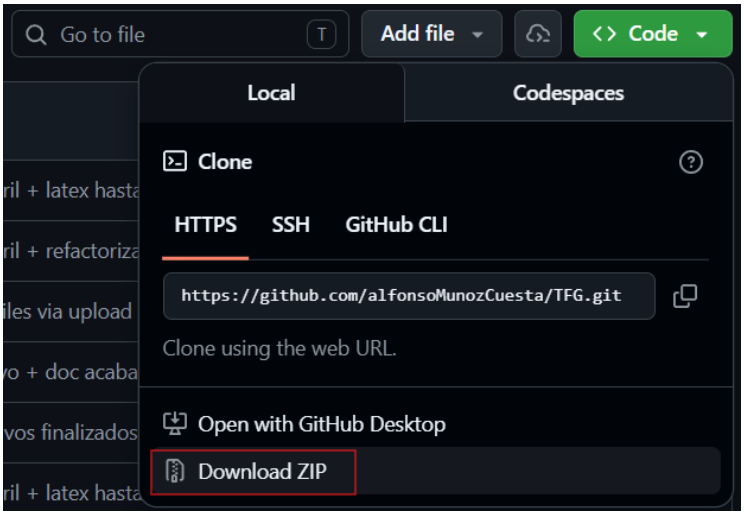

Figura 72: Descarga del proyecto desde GitHub como archivo ZIP

Opción 2: clonación del repositorio mediante Git. La segunda opción consiste en clonar el repositorio mediante Git. Para ello, el usuario debe tener Git instalado y ejecutar desde una terminal el siguiente comando:

```
git clone https://github.com/alfonsoMunozCuesta/TFG.git
```

Esta alternativa es recomendable si se desea mantener el proyecto vinculado a GitHub, actualizarlo posteriormente o trabajar con control de versiones. Además, resulta especialmente útil si el proyecto va a revisarse o ampliarse más adelante.

Una vez descargado, se debe abrir una terminal en la carpeta raíz del proyecto, es decir, en la carpeta donde se encuentran archivos como `cargaDataset.py`, `requirements.txt`, `START_DASH_APP.bat` y `START_LLAMA_SERVER.bat`.

A.2.3. Instalación de las librerías de Python requeridas

Se recomienda instalar las dependencias dentro de un entorno virtual para no mezclar las librerías del proyecto con las del sistema. Es una pequeña precaución, pero ayuda bastante a mantener el entorno limpio. Desde la carpeta raíz del proyecto, se pueden ejecutar los siguientes comandos en PowerShell:

```
python -m venv .venv
.\.venv\Scripts\Activate.ps1
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
```

El último comando instala todas las librerías declaradas en `requirements.txt`. La verdad es que esta parte conviene hacerla con un poco de cuidado, porque `scikit-survival` es una dependencia más sensible que otras librerías habituales. En este proyecto se ha fijado la versión `0.27.0`, que es la utilizada durante las pruebas con Python 3.13.2.

A.2.4. Ejecución de la aplicación

Una vez instaladas las dependencias, la aplicación puede iniciarse desde la carpeta raíz del proyecto mediante:

```
python cargaDataset.py
```

También puede utilizarse el script de arranque preparado para Windows:

```
.\START_DASH_APP.bat
```

Ambas opciones arrancan el servidor local de Dash. Cuando el proceso se inicia correctamente, la aplicación queda disponible en el navegador a través de la siguiente dirección. Es, por así decirlo, la puerta de entrada al dashboard:

```
http://127.0.0.1:8050
```

Para detener la aplicación basta con volver a la terminal donde se está ejecutando y pulsar `Ctrl+C`. Si se utiliza el archivo `START_DASH_APP.bat`, la ventana mostrará también un mensaje final antes de cerrarse.

A.2.5. Ejecución del módulo de inteligencia artificial

El módulo de inteligencia artificial se ejecuta de forma independiente al dashboard. Para utilizarlo, debe abrirse una terminal adicional en la carpeta raíz del proyecto y ejecutar:

```
.\START_LLAMA_SERVER.bat
```

Este script inicia `llama-server` en la dirección local `http://127.0.0.1:8000`. La aplicación Dash se comunica con ese servidor cuando el usuario solicita una interpretación automática desde la interfaz o al generar un informe PDF con explicación de IA. Por eso, si se quiere usar esta parte, ambas ventanas deben permanecer abiertas.

Por defecto, el script espera encontrar el modelo y el ejecutable en las siguientes rutas relativas al proyecto:

- `models/qwen2.5-1.5b-instruct-q4_k_m.gguf`
- `tools/llama.cpp/llama-server.exe`

Estos dos archivos no se incluyen directamente en el repositorio por su tamaño y por tratarse de recursos externos al código fuente. Por ese motivo, deben entregarse aparte, por ejemplo mediante una carpeta compartida en Drive, y copiarse manualmente en las rutas indicadas antes de arrancar el servidor de inteligencia artificial. Es un paso pequeño, pero importante: si alguno de los dos archivos no está en su sitio, el dashboard seguirá funcionando, aunque la generación de explicaciones mediante IA no estará disponible.

Los enlaces de descarga empleados para esta instalación son los siguientes:

- Modelo GGUF: enlace de descarga del modelo.
- Ejecutable `llama-server.exe`: enlace de descarga del ejecutable.

Si el usuario tiene el modelo o el ejecutable en otra ubicación, puede modificar las variables `MODEL_PATH` y `LLAMA_SERVER` antes de ejecutar el script. Si el servidor de IA no está activo, la aplicación seguirá funcionando con normalidad, aunque no se generarán explicaciones automáticas.

A.2.6. Desinstalación del proyecto

La aplicación no requiere un proceso de desinstalación complejo, ya que se ejecuta desde la carpeta del proyecto. Para retirarla del equipo basta con cerrar la aplicación, borrar la carpeta del proyecto y, si se creó un entorno virtual, eliminar también la carpeta `.venv`. No deja una instalación repartida por el sistema.

Si se descargaron por separado el modelo GGUF o `llama-server.exe`, estos archivos también pueden eliminarse manualmente si ya no van a utilizarse. En caso de haber instalado dependencias dentro de un entorno virtual, no es necesario desinstalar cada librería una por una, ya que al borrar dicho entorno se eliminan de forma conjunta.

A.3. Interfaz de usuario

Una vez iniciada la aplicación y abierta la dirección local en el navegador, el usuario accede a la interfaz principal del dashboard. La aplicación está organizada en distintas páginas conectadas mediante una barra de navegación superior. Desde ella se puede volver

al inicio, consultar el dataset, acceder al análisis de covariables, entrar en los módulos de análisis de supervivencia y comparar técnicas. La navegación está pensada para que el recorrido sea bastante natural: primero se cargan los datos, después se revisan y, finalmente, se analizan.

Las capturas incluidas en este manual tienen una función práctica: muestran al usuario qué pantalla debe localizar durante el flujo de uso. El capítulo de diseño recoge la distribución visual y los componentes de la interfaz con mayor detalle, mientras que este anexo se centra en acompañar el uso real de la aplicación, casi como una guía de trabajo.

A.3.1. Pantalla principal

La pantalla principal es el punto de entrada de la aplicación. En ella se muestra el área de carga del archivo CSV y el botón que permite iniciar el preprocesamiento del dataset. Esta vista concentra el primer paso importante del flujo de trabajo: seleccionar el archivo de datos que después utilizarán todos los módulos del sistema.

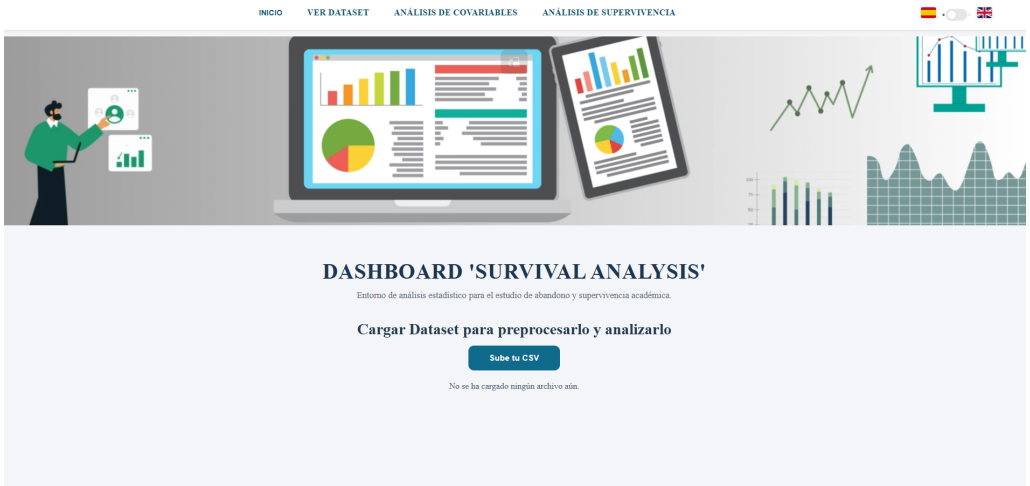

Figura 73: Pantalla principal de la aplicación

Antes de acceder a los módulos de análisis, es necesario cargar y preprocesar un dataset válido. Si el usuario intenta entrar en una sección que requiere datos sin haber completado este paso, la aplicación muestra un mensaje informativo indicando que primero debe cargarse el dataset académico. Es una protección sencilla, pero evita trabajar sobre datos vacíos o incompletos.

A.3.2. Selector de idioma

La interfaz incorpora un selector de idioma situado en la barra superior. Este control permite alternar entre español e inglés sin reiniciar la aplicación. Al modificar el idioma, se actualizan los textos principales de navegación, botones, mensajes y módulos de análisis.

El idioma seleccionado también se tiene en cuenta en varias salidas generadas por el sistema, como interpretaciones textuales o informes PDF. De esta forma, el cambio de idioma no afecta únicamente a los menús, sino también a parte del contenido producido por la aplicación, algo importante cuando los resultados van a compartirse con otras personas.

Figura 74: Botón que cambia el idioma de la aplicación

A.3.3. Carga del dataset

Para comenzar el análisis, el usuario debe cargar un archivo CSV desde la pantalla principal. La aplicación está preparada para trabajar con un dataset académico que contenga las columnas necesarias para el análisis de supervivencia. Entre las variables fundamentales se encuentran el identificador del estudiante, el tiempo observado y el resultado final que permite determinar si se ha producido el evento de abandono.

La carga se realiza seleccionando el archivo desde el explorador del sistema o arrastrándolo sobre el área correspondiente. Una vez cargado, la aplicación valida que el archivo tenga un formato compatible y que contenga los campos mínimos requeridos. Si el archivo es válido, se muestra una confirmación y el usuario puede continuar con el preprocesamiento sin tener que revisar manualmente toda la estructura del CSV.

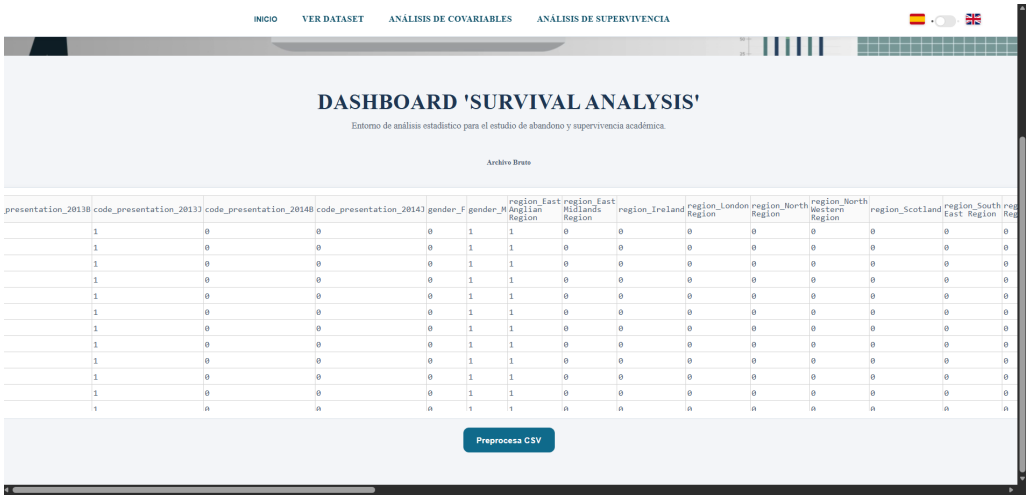

Figura 75: Archivo CSV cargado antes de iniciar el preprocesamiento

Si el archivo no es correcto, está vacío o no contiene las columnas esperadas, el sistema muestra un mensaje de error. En ese caso, el usuario debe revisar el archivo y repetir la carga con un dataset compatible.

A.3.4. Preprocesamiento del dataset

Tras cargar un archivo válido, el usuario debe pulsar el botón de preprocesamiento. Este paso prepara el dataset para que pueda ser utilizado por las técnicas de análisis de supervivencia. Durante el proceso se validan columnas, se transforman variables, se eliminan registros no válidos y se genera una versión limpia de los datos. Es una especie de filtro previo: antes de analizar, el sistema deja los datos en una forma más estable.

Figura 76: Confirmación del dataset preprocesado

Cuando el preprocesamiento finaliza correctamente, la aplicación permite acceder al resto de módulos. A partir de ese momento, el dataset limpio queda disponible para consultar los datos, ejecutar análisis de covariables, aplicar técnicas de supervivencia y generar informes. En otras palabras, es el punto en el que el dashboard queda realmente preparado para trabajar.

A.3.5. Navegación entre módulos

La navegación principal se realiza desde la barra superior de la aplicación. Los accesos disponibles permiten desplazarse entre las partes principales del dashboard:

- `INICIO`: vuelve a la pantalla principal de carga del dataset.
- `VER DATASET`: muestra el dataset limpio y la descripción de las variables.
- `ANÁLISIS DE COVARIABLES`: permite explorar variables académicas y personales antes de aplicar técnicas de supervivencia.
- `ANÁLISIS DE SUPERVIVENCIA`: da acceso a Kaplan-Meier, Regresión de Cox, Test Log-Rank, Weibull, Exponencial y Random Survival Forest.
- `COMPARACIÓN DE TÉCNICAS`: permite revisar una comparación general entre los métodos disponibles.

Al volver a la pantalla inicial, la aplicación puede solicitar confirmación para evitar perder el dataset cargado y los análisis realizados. Esta medida reduce el riesgo de abandonar accidentalmente el flujo de trabajo activo, algo que puede pasar con facilidad cuando se está explorando varias secciones seguidas.

A.4. Visualización del dataset

Después de completar el preprocesamiento, el usuario puede acceder a la sección de visualización del dataset. Esta parte permite revisar los datos cargados y comprobar la estructura del dataset limpio que utilizarán los modelos de supervivencia. Es un paso recomendable antes de lanzarse al análisis, porque ayuda a detectar si algo no encaja.

A.4.1. Consulta del dataset cargado

La consulta del dataset cargado permite comprobar que el archivo original se ha incorporado correctamente a la aplicación. Esta revisión es útil para detectar posibles problemas iniciales, como columnas ausentes, separadores incorrectos o valores inesperados, antes de continuar con el análisis.

En esta fase el usuario debe verificar que el dataset corresponde al archivo esperado y que contiene las variables necesarias para el análisis. Si el archivo no cumple la estructura requerida, el sistema no permitirá continuar correctamente con el flujo de análisis.

A.4.2. Consulta del dataset preprocesado

Una vez aplicado el preprocesamiento, el usuario puede consultar el dataset limpio. Esta versión es la que se utiliza internamente para ejecutar las técnicas de análisis de supervivencia. En ella se han tratado las variables necesarias y se han preparado los datos para su uso en los modelos estadísticos.

La vista de dataset muestra una tabla con los registros disponibles y permite revisar el resultado del proceso de limpieza. Además, la aplicación incluye una descripción de las variables principales para facilitar la interpretación de los campos utilizados por los modelos. Esto ayuda a no tratar las columnas como nombres sueltos, sino como información con significado dentro del problema académico.

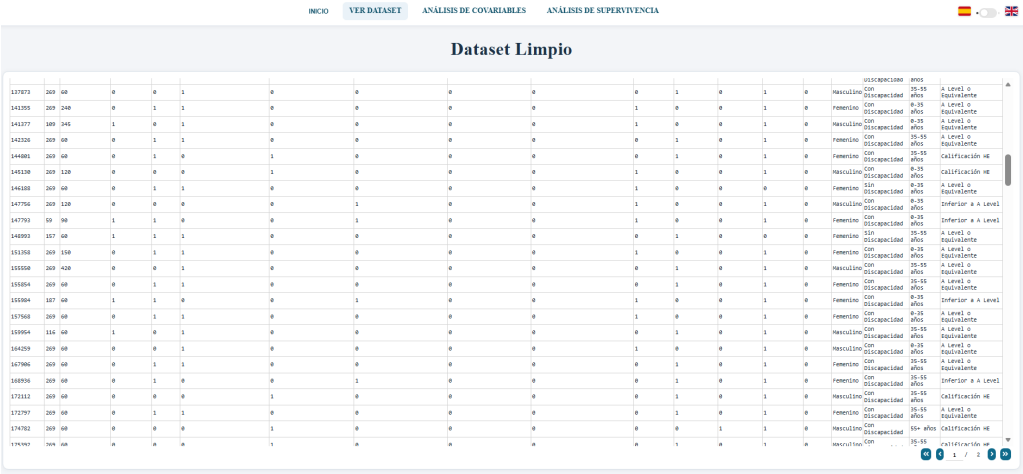

Figura 77: Consulta del dataset limpio desde la sección de visualización

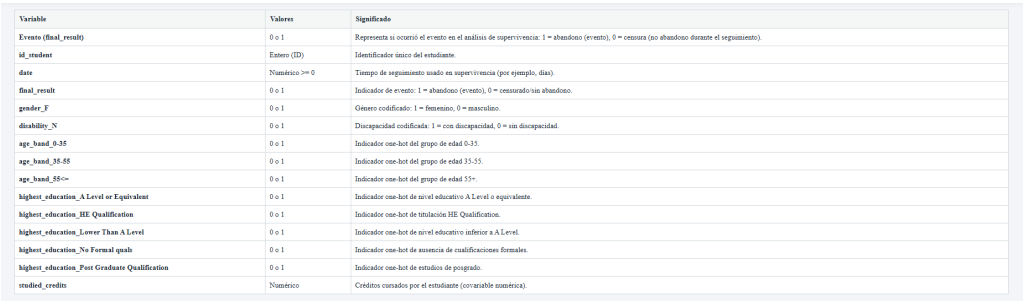

Variable	Valores	Significado
Evento (final_result)	0 o 1	Representa si ocurrió el evento en el análisis de supervivencia: 1 = abandono (evento), 0 = censura (no abandono durante el seguimiento).
id_student	Entero (ID)	Identificador único del estudiante.
date	Numérico >= 0	Tiempo de seguimiento usado en supervivencia (por ejemplo, días).
final_result	0 o 1	Indicador de evento: 1 = abandono (evento), 0 = censurado/sin abandono.
gender_F	0 o 1	Género codificado: 1 = femenino, 0 = masculino.
disability_N	0 o 1	Discapacidad codificada: 1 = con discapacidad, 0 = sin discapacidad.
age_band_0-35	0 o 1	Indicador one-hot del grupo de edad 0-35.
age_band_35-55	0 o 1	Indicador one-hot del grupo de edad 35-55.
age_band_55<=	0 o 1	Indicador one-hot del grupo de edad 55+.
highest_education_A Level or Equivalent	0 o 1	Indicador one-hot de nivel educativo A Level o equivalente.
highest_education_HE Qualification	0 o 1	Indicador one-hot de titulación HE Qualification.
highest_education_Lower Than A Level	0 o 1	Indicador one-hot de nivel educativo inferior a A Level.
highest_education_No Formal quals	0 o 1	Indicador one-hot de ausencia de cualificaciones formales.
highest_education_Post Graduate Qualification	0 o 1	Indicador one-hot de estudios de posgrado.
studied_credits	Numérico	Créditos cursados por el estudiante (covariable numérica).

Figura 78: Descripción de variables disponible para interpretar el dataset

A.5. Análisis de covariables

El análisis de covariables permite explorar de forma inicial la relación entre distintas variables del dataset y el abandono académico. Esta sección sirve como paso previo a los modelos de supervivencia, ya que ayuda a identificar patrones generales en función de características personales o académicas del alumnado. No ofrece todavía una conclusión definitiva, pero sí una primera lectura muy útil.

A.5.1. Selección de covariables

Para utilizar esta sección, el usuario debe seleccionar el tipo de análisis de covariable que desea visualizar. La aplicación permite revisar variables como género, discapacidad, tramo de edad, nivel educativo previo y créditos estudiados. También puede mostrarse una visión general del abandono total.

La selección se realiza mediante los controles disponibles en la página. Al cambiar la opción seleccionada, la aplicación actualiza automáticamente la información mostrada para reflejar el análisis correspondiente.

Figura 79: Selección de covariables para la exploración descriptiva

A.5.2. Interpretación de tablas y gráficas

Los resultados del análisis de covariables se presentan mediante tablas, gráficos e interpretaciones textuales. Las gráficas permiten comparar de forma visual la distribución del abandono entre grupos, mientras que las tablas resumen ofrecen valores concretos que ayudan a interpretar cada variable.

La interpretación debe realizarse como una exploración descriptiva inicial. Es decir, esta sección permite observar diferencias entre grupos, pero no sustituye a los modelos de supervivencia posteriores. Para estudiar el comportamiento temporal del abandono y comparar curvas o riesgos, el usuario debe acudir a las técnicas específicas de análisis de supervivencia. La idea es mirar primero el terreno antes de entrar en el análisis más profundo.

A.6. Técnicas de análisis de supervivencia

La sección de análisis de supervivencia agrupa los métodos estadísticos disponibles en la aplicación. Para utilizar cualquiera de ellos es necesario haber cargado y preprocesado previamente el dataset. Desde esta página, el usuario puede acceder a los distintos modelos y pruebas mediante los botones o enlaces internos de navegación.

Figura 80: Página de acceso a las técnicas de análisis de supervivencia

A.6.1. Kaplan-Meier

El módulo Kaplan-Meier permite estimar la función de supervivencia del alumnado a lo largo del tiempo. Al acceder a esta sección se muestra una curva general de supervivencia, que representa la probabilidad estimada de permanencia en función del tiempo observado. Es una de las formas más directas de ver cómo evoluciona el abandono conforme avanza el periodo estudiado.

El usuario puede seleccionar distintas covariables para comparar curvas entre grupos. Entre las opciones disponibles se encuentran género, discapacidad, tramo de edad, nivel

educativo previo y créditos estudiados. Al elegir una covariable, la gráfica se actualiza para mostrar las curvas correspondientes a cada grupo.

La curva generada permite observar diferencias en la permanencia estimada entre grupos. Una caída más pronunciada de la curva indica una mayor concentración de eventos de abandono en menor tiempo. El usuario también puede solicitar una explicación mediante IA y exportar el análisis a PDF cuando existan resultados disponibles. De este modo, la gráfica no se queda solo como una visualización puntual, sino que puede convertirse en parte de un informe.

Figura 81: Resultado esperado al generar una curva Kaplan-Meier estratificada

A.6.2. Regresión de Cox

La regresión de Cox permite analizar el efecto de una o varias covariables sobre el riesgo de abandono. En esta pantalla, el usuario selecciona las variables que desea incluir en el modelo y ejecuta el análisis. El resultado principal se expresa mediante el Hazard Ratio, que ayuda a interpretar si una covariable se asocia con un aumento o una reducción del riesgo.

Tras ejecutar el modelo, la aplicación muestra una tabla con los coeficientes, valores de significación y medidas asociadas. Además, puede generarse una visualización tipo forest plot que facilita comparar el efecto relativo de las covariables seleccionadas.

Figura 82: Visualización de los efectos obtenidos tras ejecutar la regresión de Cox

Para interpretar los resultados, se debe prestar atención al Hazard Ratio y al p-valor. Un Hazard Ratio superior a 1 indica mayor riesgo relativo de abandono, mientras que un valor inferior a 1 apunta a un posible efecto protector. El p-valor ayuda a valorar si la asociación observada es estadísticamente significativa. La lectura conjunta de ambos valores es importante, porque una cifra aislada puede resultar engañosa si no se mira dentro del contexto del modelo.

A.6.3. Test Log-Rank

El Test Log-Rank permite comparar curvas de supervivencia entre grupos y determinar si existen diferencias estadísticamente significativas entre ellas. Para utilizarlo, el usuario selecciona la variable o covariable que desea comparar y ejecuta la prueba. Resulta especialmente útil cuando una diferencia visual parece clara, pero se quiere comprobar con un contraste estadístico.

El sistema muestra los resultados de la comparación, incluyendo el estadístico de prueba y el p-valor. Si el p-valor es inferior al umbral habitual de 0.05, puede considerarse que existen diferencias estadísticamente significativas entre las curvas comparadas.

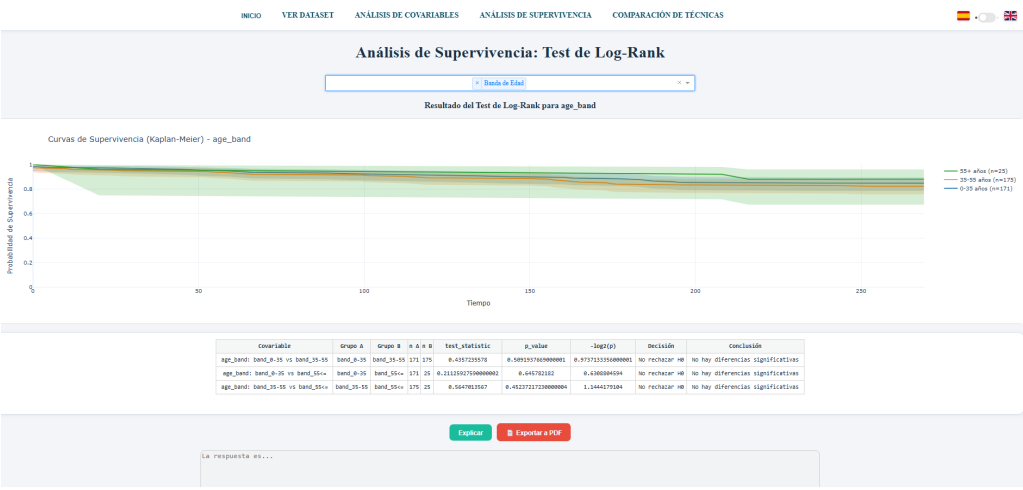

Figura 83: Resultado mostrado al comparar grupos mediante el Test Log-Rank

Este análisis funciona muy bien como complemento de Kaplan-Meier, ya que no solo permite visualizar diferencias entre curvas, sino también contrastarlas mediante una prueba estadística. Primero se observa la curva; después, se comprueba si esa diferencia tiene respaldo numérico.

A.6.4. Modelo Weibull

El modelo Weibull es una técnica paramétrica de análisis de supervivencia. A diferencia de Kaplan-Meier, que estima la curva de forma empírica, Weibull ajusta una distribución al comportamiento temporal de los datos. Esta aproximación permite interpretar parámetros del modelo y comparar su ajuste con otros métodos, algo útil cuando se busca una lectura más estructurada del fenómeno.

Al ejecutar el análisis, la aplicación muestra la curva ajustada y una tabla resumen con métricas del modelo. Entre los elementos relevantes se encuentran los parámetros de forma y escala, la mediana de supervivencia, el log-likelihood y el AIC. El parámetro de forma permite valorar si el riesgo aumenta, disminuye o se mantiene aproximadamente constante a lo largo del tiempo.

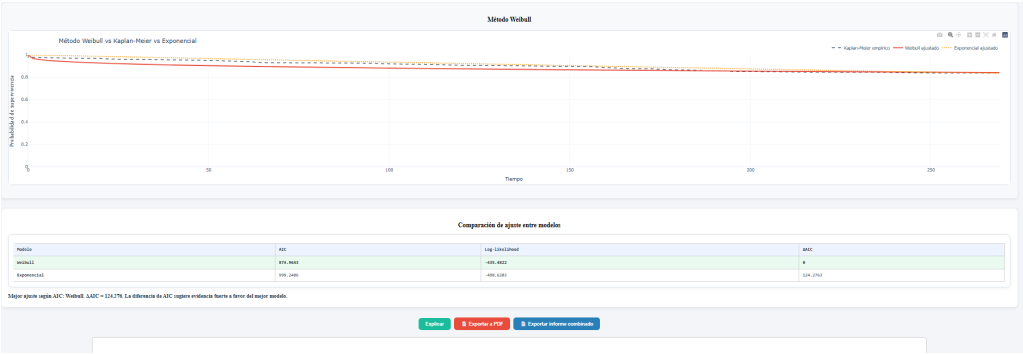

Figura 84: Resultados que debe revisar el usuario tras ejecutar el modelo Weibull

A.6.5. Modelo Exponencial

El modelo Exponencial es otro modelo paramétrico de supervivencia. Su característica principal es que asume un riesgo constante a lo largo del tiempo. Por este motivo, resulta útil como modelo sencillo de referencia frente a otros enfoques más flexibles, como Weibull o Kaplan-Meier. La verdad es que su interés está precisamente en esa sencillez: permite comprobar si una hipótesis básica encaja razonablemente con los datos.

Al ejecutar el análisis, la aplicación presenta la curva del modelo exponencial y una tabla resumen con sus métricas principales. El usuario puede comparar visualmente el ajuste exponencial con la estimación empírica de Kaplan-Meier para valorar si la hipótesis de riesgo constante resulta razonable.

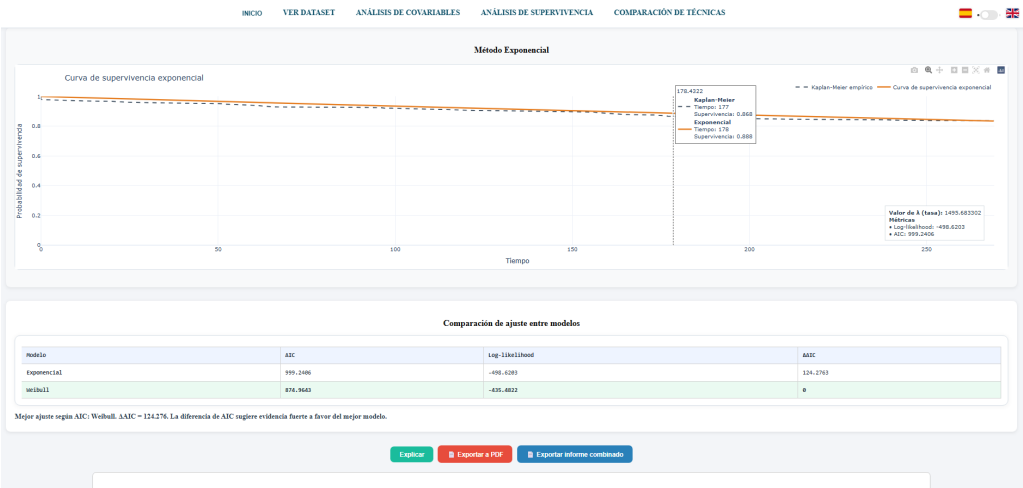

Figura 85: Resultados que debe revisar el usuario tras ejecutar el modelo Exponencial

A.6.6. Random Survival Forest

Random Survival Forest es un modelo de aprendizaje automático adaptado a datos de supervivencia. Su objetivo es estimar el riesgo y la supervivencia teniendo en cuenta múltiples variables de entrada. En la aplicación, este módulo permite entrenar el modelo, revisar métricas generales, consultar la importancia de variables y simular perfiles. Es el enfoque más flexible de los incluidos en el dashboard, aunque también exige una interpretación más cuidadosa.

Tras ejecutar el modelo, se muestran curvas de supervivencia para distintos perfiles de riesgo, junto con métricas como el índice de concordancia. Estas salidas permiten valorar la capacidad del modelo para diferenciar perfiles con mayor o menor riesgo de abandono.

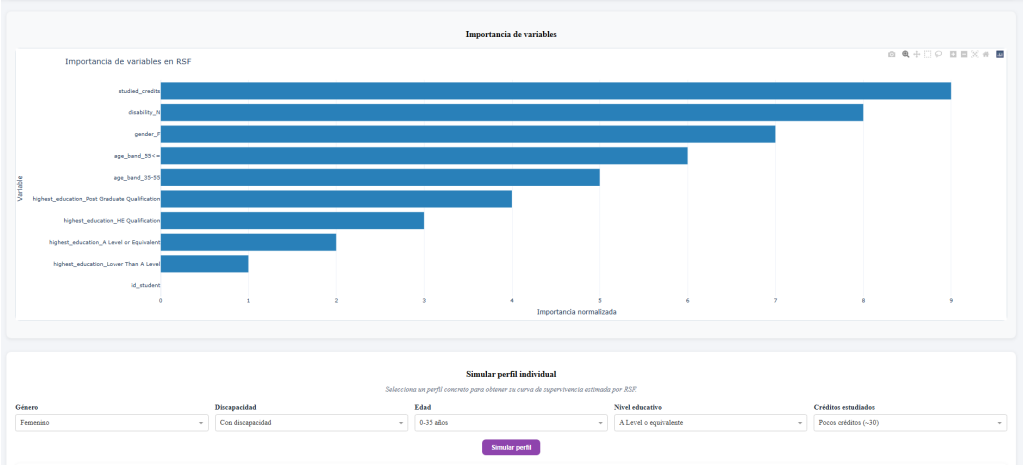

Figura 86: Curvas y métricas generadas por Random Survival Forest

El módulo también permite revisar la importancia de variables y simular un perfil específico. Esta funcionalidad ayuda a interpretar qué características tienen mayor influencia en la predicción y cómo varía la supervivencia estimada ante un caso concreto. Por ejemplo, permite observar cómo cambia la curva si se modifican determinados rasgos académicos del estudiante.

A.6.7. Comparación de técnicas

La comparación de técnicas ofrece una vista conjunta de los métodos incluidos en la aplicación. Esta sección ayuda al usuario a distinguir el propósito de cada técnica, sus ventajas y sus limitaciones. Es especialmente útil cuando se desea decidir qué resultado utilizar como referencia principal en un análisis, porque no todos los métodos responden exactamente a la misma pregunta.

La aplicación permite revisar de forma comparativa los modelos clásicos, paramétricos y de aprendizaje automático. Esta visión conjunta facilita entender que cada método responde a una pregunta distinta: Kaplan-Meier estima curvas, Log-Rank compara grupos, Cox analiza riesgos relativos, Weibull y Exponencial ajustan modelos paramétricos, y Random Survival Forest incorpora capacidad predictiva con múltiples variables.

Técnica	Tipo de modelo	Hipótesis	Ventajas	Limitaciones	Cuándo usarlo
Kaplan-Meier	No paramétrico	Censura no informativa; estima supervivencia empírica sin forma funcional.	Muy interpretable; útil como línea base visual.	No ajusta covariables simultáneamente.	Comparación descriptiva inicial entre grupos.
Exponencial	Paramétrico	Riesgo constante en el tiempo (hazard constante).	Simple, estable y fácil de interpretar.	Puede infraajustar si el riesgo cambia con el tiempo.	Cuando se espera comportamiento aproximadamente constante del riesgo.
Weibull	Paramétrico	Riesgo monótono (creciente o decreciente) según parámetro de forma.	Flexible y con parámetros interpretables.	Si el riesgo no es monótono puede no capturar bien el patrón.	Cuando se requiere modelo paramétrico más flexible que Exponencial.
Regresión de Cox	Semiparamétrico	Proporcionalidad de riesgos entre grupos/covariables.	Ajusta múltiples covariables sin asumir forma base del hazard.	Sensibilidad a violaciones de proporcionalidad.	Para cuantificar efecto de covariables (hazard ratios).
Log-Rank Test	Test no paramétrico	Compara igualdad global de curvas de supervivencia entre grupos.	Simple para contraste de hipótesis entre grupos.	No estima tamaño de efecto multivariable por sí solo.	Para evaluar si las curvas difieren de forma estadísticamente significativa.
Random Survival Forest	Ensamble ML	No requiere proporcionalidad ni forma paramétrica explícita.	Captura relaciones no lineales e interacciones complejas.	Menor interpretabilidad que Cox/KM.	Cuando prima capacidad predictiva y complejidad de patrones.

Figura 87: Vista utilizada para consultar la comparación entre técnicas disponibles

A.7. Interpretación con inteligencia artificial

La aplicación incorpora un módulo opcional de inteligencia artificial para generar explicaciones textuales de los resultados estadísticos. Esta funcionalidad actúa como apoyo interpretativo y no sustituye a las tablas, curvas ni métricas calculadas por los modelos. Su papel es ayudar a leer los resultados con más claridad, no decidir por el usuario.

A.7.1. Arranque del servidor local de IA

Para utilizar la interpretación automática, el servidor local de IA debe estar iniciado antes de solicitar una explicación desde el dashboard. Para ello, se abre una terminal en la carpeta raíz del proyecto y se ejecuta:

```
.\START_LLAMA_SERVER.bat
```

Este servidor se ejecuta de forma independiente a la aplicación Dash. Por tanto, si se desea usar la IA, deben mantenerse abiertas dos terminales: una con `llama-server` y otra con la aplicación Dash iniciada mediante `python cargaDataset.py` o mediante `START_DASH_APP.bat`. Puede parecer un detalle menor, pero si una de las dos se cierra, la parte de IA dejará de responder.

Si el servidor no está activo, la aplicación sigue funcionando. En ese caso, las técnicas estadísticas y las gráficas continúan disponibles, pero no se generarán respuestas automáticas de IA.

A.7.2. Generación de explicaciones automáticas

Las explicaciones automáticas pueden solicitarse desde los módulos de análisis mediante los botones de interpretación disponibles en la interfaz. Al pulsar el botón correspondiente, la aplicación recopila los resultados calculados y los envía al modelo local para obtener una explicación redactada en lenguaje natural. Así, el usuario no parte solo de una tabla o una curva, sino también de un texto que ayuda a ordenar la lectura.

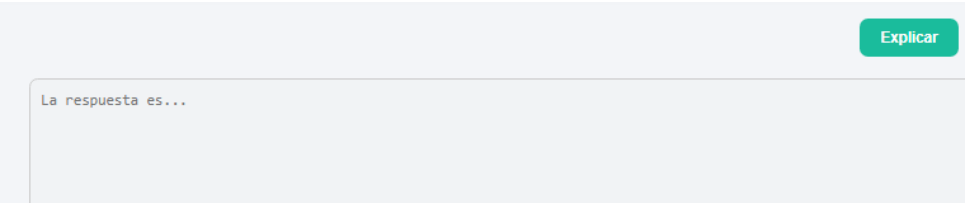

Figura 88: Botón de interpretación mediante inteligencia artificial

La respuesta generada se muestra en la propia página del análisis. Además, si el usuario selecciona la opción correspondiente al exportar un informe PDF, la interpretación puede incluirse dentro del documento generado.

```
def _academic_system_prompt(language='es'):
    if language == 'en':
        return (
            "You are a survival-analysis assistant for an academic thesis. "
            "Write in formal, clear, evidence-based prose using only provided results. "
            "Return 2-3 short paragraphs with no bullet points and no numbered lists."
        )
    return (
        "Eres un asistente de análisis de supervivencia para un TFG. "
        "Redacta en prosa académica clara y basada en evidencias, usando solo resultados proporcionados. "
        "Devuelve 2-3 párrafos breves, sin viñetas ni listas numeradas."
    )
```

Figura 89: Ejemplo de explicación generada para apoyar la interpretación de resultados

A.7.3. Limitaciones de las interpretaciones generadas

Las respuestas generadas por inteligencia artificial deben entenderse como una ayuda para redactar e interpretar los resultados, no como una conclusión automática definitiva. El usuario debe revisar siempre que el texto sea coherente con las tablas, curvas y métricas mostradas en pantalla. Esta revisión es importante, porque la interpretación final sigue dependiendo del análisis estadístico y del criterio de quien utiliza la herramienta.

El modelo trabaja con la información que recibe desde la aplicación. Si los resultados son incompletos, si no se ha ejecutado correctamente el análisis o si el servidor local no está disponible, la explicación puede no generarse. Además, aunque el sistema intenta

restringir la respuesta a los datos proporcionados, es recomendable contrastar cualquier interpretación con los valores estadísticos originales.

A.8. Exportación de informes PDF

La aplicación permite exportar informes PDF desde los distintos módulos de análisis. Esta funcionalidad facilita conservar los resultados principales de cada técnica, incluyendo tablas, gráficas, resúmenes e interpretaciones generadas mediante IA cuando el usuario así lo selecciona. Es especialmente útil cuando se quiere guardar una evidencia del análisis o compartir los resultados sin depender de la interfaz.

A.8.1. Selección de contenido del informe

Para generar un informe, el usuario debe pulsar el botón de exportación disponible en el módulo correspondiente. A continuación se abre una ventana modal donde se puede indicar el nombre del informe y seleccionar qué elementos se desean incluir.

Figura 90: Botón que inicia la exportación desde un módulo de análisis

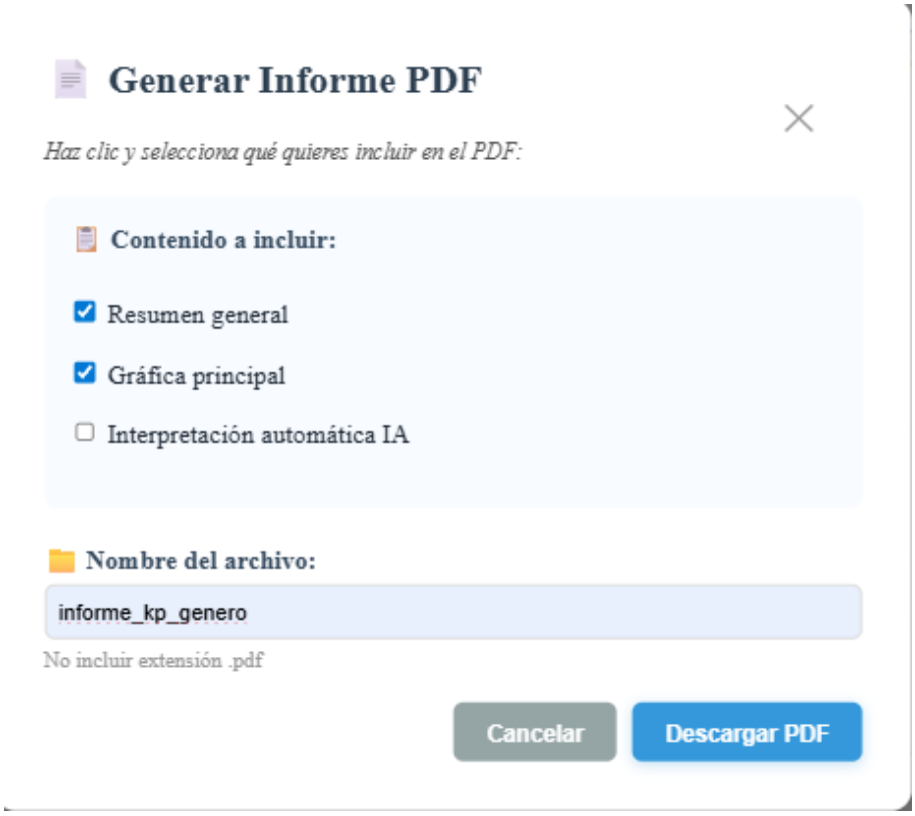

Figura 91: Opciones de contenido para el informe PDF

Las opciones disponibles pueden variar según el módulo, pero normalmente permiten incluir resumen, tabla de resultados, gráfica e interpretación automática. En algunos casos, como los modelos Weibull y Exponencial, también puede generarse un informe combinado.

A.8.2. Generación y descarga del PDF

Una vez seleccionadas las opciones deseadas, el usuario debe confirmar la exportación. El sistema valida que existan resultados suficientes y genera el informe PDF. Si no se han calculado resultados o si falta algún elemento necesario, la aplicación muestra un mensaje de aviso. De esta forma se evita descargar documentos vacíos o poco útiles.

El documento generado incluye los elementos seleccionados y mantiene una estructura orientada a la lectura del análisis: título del informe, información general, resultados, gráficas e interpretación cuando procede.

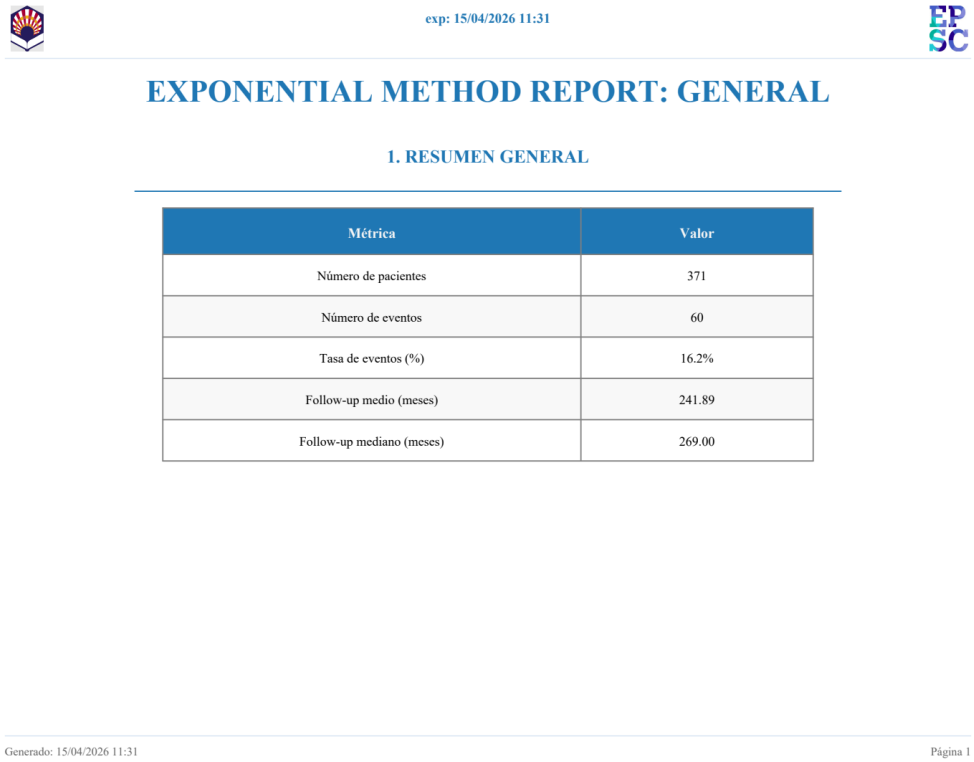

exp: 15/04/2026 11:31

EXPONENTIAL METHOD REPORT: GENERAL

1. RESUMEN GENERAL

Métrica	Valor
Número de pacientes	371
Número de eventos	60
Tasa de eventos (%)	16.2%
Follow-up medio (meses)	241.89
Follow-up mediano (meses)	269.00

Generado: 15/04/2026 11:31 Página 1

Figura 92: Ejemplo de informe PDF generado a partir de los resultados seleccionados

A.8.3. Ubicación de los informes generados

Los informes generados se almacenan en la carpeta `downloads/` del proyecto. Desde esa ubicación pueden abrirse, copiarse o adjuntarse como cualquier otro documento PDF.

Se recomienda asignar nombres descriptivos a los informes para identificar fácilmente la técnica utilizada y el contenido exportado. Por ejemplo, pueden emplearse nombres como `informe_kaplan_genero`, `cox_covariables` o `comparacion_weibull_exponencial`. Este pequeño hábito ahorra tiempo cuando se generan varios PDFs durante una misma sesión de análisis.

A.9. Errores frecuentes

Durante el uso de la aplicación pueden aparecer errores relacionados con la carga del dataset, la instalación de dependencias, el arranque del servidor o la generación de informes. Esta sección resume las incidencias más habituales y la forma recomendada de

actuar. No todos los avisos indican un fallo grave; muchas veces solo señalan que falta completar un paso previo.

A.9.1. Problemas al cargar el dataset

Si el sistema rechaza el archivo cargado, se debe comprobar que se trata de un archivo CSV válido y que contiene las columnas obligatorias. También conviene revisar el separador utilizado, la codificación del archivo y que las columnas críticas no estén vacías. A veces el problema no está en los datos en sí, sino en pequeños detalles de formato que impiden que la aplicación los lea correctamente.

Figura 93: Mensaje mostrado cuando el archivo cargado no corresponde al dataset esperado

Si el archivo se ha modificado manualmente, es recomendable compararlo con el formato esperado por la aplicación antes de volver a cargarlo. Un cambio mínimo en el nombre de una columna puede ser suficiente para que el sistema no la reconozca.

A.9.2. Problemas al acceder a módulos sin preprocesar

Algunas secciones del dashboard necesitan que el dataset haya sido cargado y preprocesado previamente. Si el usuario intenta acceder a un módulo de análisis sin haber completado ese paso, la aplicación muestra un aviso indicando que primero debe cargarse el dataset académico y pulsarse la opción de preprocesamiento.

Figura 94: Aviso mostrado al acceder a una sección que requiere el dataset preprocesado

Para resolver este caso, el usuario debe volver a la pantalla de inicio, cargar el archivo CSV correcto y ejecutar el preprocesamiento. Una vez finalizado correctamente, las secciones de análisis quedarán habilitadas para trabajar con el dataset limpio. Es el mismo flujo inicial, simplemente repetido con los datos preparados de forma adecuada.

A.9.3. Problemas durante la instalación de dependencias

Si aparece un error durante la instalación de librerías, el primer paso es comprobar la versión de Python utilizada. Para este proyecto se ha empleado Python 3.13.2 junto con `scikit-survival==0.27.0`. La dependencia que puede requerir más atención es precisamente `scikit-survival`, ya que trabaja con componentes científicos especializados y puede ser más sensible al entorno.

También se recomienda actualizar `pip` antes de instalar las dependencias y utilizar un entorno virtual limpio. Muchas instalaciones fallidas se solucionan simplemente empezando desde un entorno sin librerías mezcladas.

A.9.4. Problemas al arrancar la aplicación

Si la aplicación no arranca, se debe comprobar que la terminal está situada en la carpeta raíz del proyecto y que las dependencias se han instalado correctamente. También debe verificarse que el archivo `cargaDataset.py` existe en esa carpeta. Es un error frecuente abrir la terminal en una ruta distinta y ejecutar el comando desde ahí.

Si el puerto `8050` estuviera ocupado por otro proceso, puede ser necesario cerrar la ejecución anterior de la aplicación o reiniciar la terminal.

A.9.5. Problemas con el módulo de inteligencia artificial

Si no se genera una interpretación automática, lo más habitual es que el servidor local de IA no esté iniciado. En ese caso, debe ejecutarse `START_LLAMA_SERVER.bat` y comprobar que `llama-server` queda escuchando en `http://127.0.0.1:8000`. Mientras ese servidor no esté activo, el dashboard seguirá funcionando, pero no tendrá a quién pedirle la explicación.

También debe comprobarse que existen el modelo GGUF y el ejecutable `llama-server.exe` en las rutas configuradas. Si el usuario utiliza rutas propias, debe ajustar las variables `MODEL_PATH` y `LLAMA_SERVER`.

A.9.6. Problemas al generar informes PDF

Si el PDF no se genera, se debe verificar que el análisis correspondiente se ha ejecutado previamente y que existen resultados válidos para exportar. Algunas opciones del informe, como incluir gráficas o interpretación IA, requieren que esos elementos estén disponibles antes de confirmar la descarga. En resumen, el informe solo puede guardar aquello que ya se ha calculado.

Si el problema está relacionado con las gráficas, puede estar asociado a la conversión de figuras mediante `kaleido`. En ese caso, conviene revisar que las dependencias se hayan instalado correctamente desde `requirements.txt`.

A.10. Flujo completo recomendado

El flujo de uso recomendado para trabajar con la aplicación es el siguiente. Seguir este orden ayuda a avanzar sin saltarse pasos importantes:

1. Iniciar la aplicación con `python cargaDataset.py` o con `START_DASH_APP.bat`.
2. Abrir en el navegador la dirección `http://127.0.0.1:8050`.
3. Cargar el archivo CSV desde la pantalla principal.
4. Preprocesar el dataset para generar la versión limpia.
5. Revisar el dataset en la sección de visualización.
6. Explorar las covariables para obtener una primera lectura descriptiva.
7. Ejecutar las técnicas de análisis de supervivencia necesarias.
8. Solicitar interpretaciones mediante IA si el servidor local está activo.
9. Exportar los resultados relevantes a PDF.

Este orden permite avanzar desde la carga de datos hasta la obtención de resultados exportables de forma controlada. Aunque el usuario puede navegar libremente por la interfaz, la mayoría de módulos requieren que el dataset haya sido cargado y preprocesado previamente. La verdad es que, si se respeta este flujo, la aplicación resulta bastante más cómoda de usar.

ANEXO B

MANUAL DE CÓDIGO FUENTE

B Anexo del Manual de código fuente

B.1. Introducción

Este anexo corresponde al manual de código fuente de la aplicación...